Universidad Nacional Autónoma de México

Facultad de Estudios Superiores Acatlán

Matemáticas Aplicadas y Computación

Procesos Estocásticos

Cadenas de Markov Discretas

Prof. Dr. César Galindo

Alumno: Ricardo López Ramírez

Índice

1. Cadenas de Markov a tiempo discreto — Fundamentos **1**
1.1. Propiedad de Markov y funciones armónicas . . . 1
1.2. Caminata aleatoria en $\mathbb{Z}$ . . . 5
1.3. Clasificación de Estados y Comunicación . . . 10
1.4. Tiempo esperado de llegada . . . 16
1.5. Probabilidad de ruina (jugador) . . . 21

2. Medidas estacionarias, recurrencia y ergodicidad **27**
2.1. Existencia, unicidad y tiempo de retorno . . . 27
2.2. Cadena de nacimiento y muerte discreta . . . 32
2.3. Convergencia al equilibrio . . . 37
2.4. Caminata aleatoria en Z^d . . . 42
2.5. Caminata aleatoria en grafos finitos. . . . 47

3. Martingalas, potencial y función de Green **51**
3.1. Teorema de paro opcional . . . 51
3.2. Problema de Dirichlet discreto . . . 55
3.3. Función de Green y ecuación de Poisson . . . 60
3.4. Tiempo de cubrimiento de una gráfica . . . 64
3.5. Capacidad y probabilidad de absorción . . . 69
3.6. Movimiento browniano como límite de la caminata . . . 74

4. Cadenas de Markov a tiempo continuo **78**
4.1. Generador y semigruppo . . . 78
4.2. Proceso de Poisson . . . 82
4.3. Proceso de nacimiento–muerte con absorción . . . 86
4.4. Ecuaciones de Kolmogorov hacia adelante . . . 90
4.5. Cola M/M/1 . . . 94
4.6. Reversibilidad en tiempo continuo . . . 98
4.7. Cadena encajada y construcción . . . 102

5. Teoremas límite **106**
5.1. Teorema central del límite para cadenas. . . . 106
5.2. Grandes desviaciones . . . 109

6. Aplicaciones **112**
6.1. Epidemia SIS . . . 114
6.2. Cola M/M/s . . . 117
6.3. Modelo de Ising y dinámica de Glauber . . . 119
6.4. Cadena de Metropolis–Hastings . . . 122
6.5. Caminata aleatoria en árboles . . . 125
6.6. Modelo PageRank . . . 127
6.7. Modelo de ruina multiclase . . . 129
6.8. Simulación Monte Carlo vía cadenas de Markov (MCMC). . . . 131
6.9. Proceso de decaimiento radioactivo . . . 133
6.10. Proceso de Yule (nacimiento puro). . . . 135
6.11. Modelo SIR a tiempo continuo . . . 138
6.12. Modelo de filas en tándem . . . 140
6.13. Canal de comunicación binario . . . 142
6.14. Modelo de inventario . . . 144
6.15. Proceso de degradación y mantenimiento. . . . 146
6.16. Modelo de compartimentos farmacocinéticos . . . 148
6.17. Ley de Benford y caminatas en grupos abelianos . . . 150
6.18. Modelo de recombinación genética . . . 152
6.19. Red de colas de Jackson . . . 154

7. Bibliografía de referencia **156**

1. Cadenas de Markov a tiempo discreto — Fundamentos

1.1. Propiedad de Markov y funciones armónicas

Ejercicio 1.1. Propiedad de Markov

Sea $(X_n)_{n\geq 0}$ una cadena de Markov en S con probabilidades $p(x,y)$. Demuestre la propiedad de Markov: para toda $f : S \to \mathbb{R}$ acotada $\forall n \geq 0$:

$$E^x[f(X_{n+1}) \mid X_0, X_1, \ldots, X_n] = E^x[f(X_{n+1}) \mid X_n]$$

Por la definición de ESPERANZA CONDICIONAL.

El valor esperado condicional de una función aplicada a una variable aleatoria

discreta (X_{n+1}) es igual a la suma de la función evaluada en cada posible *estado* $y \in S$, multiplicada por la probabilidad de llegada

Demostración. Por la definición de **esperanza condicional** para variables discretas:

$$E^x\left[f(X_{n+1}) \mid X_0, X_1, \ldots, X_n\right] = \sum_{y\in S} f(y) * \mathbb{P}(X_{n+1} = y \mid x_0 \ldots x_n)$$

Punto Clave

La propiedad de Markov dicta que el futuro (X_{n+1}) solo depende del presente (X_n), ignorando el pasado $(X_0, \ldots, X_{n-1})$.

Notación

La notación estándar de la probabilidad de transición de un estado x a un estado (x_n) a un estado y en un paso se denota como:

$$\boxed{\mathbb{P}\left(x_n, y\right)} = \mathbb{P}(X_{n+1} = y \mid X_n)$$

Sustituyendo, obtenemos la conclusión deseada:

$$E^x\left[f(X_{n+1}) \mid X_0, X_1, \ldots, X_n\right] = \sum_{y} f(y) * \mathbb{P}\left(x_n, y\right)$$

□

Ejercicio 1.2. Funciones Armónicas y Martingalas

Una función h es *armónica* en $A \subseteq S$ si $\sum_{y \in S} p(x,y)h(y) = h(x)$ para todo $x \in A$. Demuestre que $(h(X_n))_{n \geq 0}$ es una martingala si h es armónica en todo S.

Se plantea el objetivo $Y_n = h(x_n)$ es una Martingala, debemos probar que su valor esperado condicional dado el pasado es igual a su valor actual.

Punto Clave

Para que $Y_n = h(X_n)$ sea una **Martingala**, debe cumplir: $E[Y_{n+1} \mid X_0, \ldots, X_n] = Y_n$.

Demostración. Calculamos el valor esperado condicional:

$$E[h(X_{n+1}) \mid X_0, \ldots, X_n] \overset{\text{Markov}}{=} E[h(X_{n+1}) \mid X_n]$$

Usando la definición de esperanza para la transición desde el estado actual $X_n = x$:

$$E[h(X_{n+1}) \mid X_n = x] = \sum_{y \in S} p(x,y)h(y)$$

Como h es **armónica**:

$$\sum_{y \in S} p(x,y)h(y) = h(x) \implies h(X_n)$$

$\therefore$ $(h(X_n))_{n \geq 0}$ es una Martingala. $\square$

Ejercicio 1.3. Función Armónica constante

Deduzca que toda función armónica acotada en una cadena irreducible sobre un espacio finito es constante.

Demostración. unción Armónica Constante (Principio del Máximo)

- La existencia de un máximo: Como el espacio de estados S es finito, cualquier función evaluada en este espacio tiene que alcanzar un valor máximo en algún lugar. Sea x^* el estado donde la función h alcanza su valor máximo absoluto, al cual llamaremos M:

$$h(x^*) = M$$

  para cualquier otro estado $y \in S$, se cumple que $h(y) \leq M$.

- Aplicar la propiedad armónica en el máximo: Por definición que h es una función armónica, lo que significa que el valor en cualquier estado es el promedio ponderado de sus vecinos.

  Una función armónica $h(x^*) = M$. Alcanza su valor máximo en M, Aplicando esta regla al estado máximo x^*, obtenemos:

$$M = h(x^*) = \sum_{y \in S} p(x^*, y)h(y)$$

- Si el promedio de un grupo de números es igual al valor máximo permitido, la única forma de que eso suceda es que todos y cada uno de los números de ese grupo sean también el máximo. Por lo tanto:

$$p(x^*, y) > 0 \implies h(y) = M$$

- La cadena es irreducible. Esto significa que todos los estados se comunican; puedes llegar de cualquier estado a cualquier otro estado en un número finito de pasos. Si desde x^* saltamos a sus vecinos, todos ellos deben tener valor M. valor máximo se propaga a absolutamente todos los estados del espacio S.

$$\therefore \forall x \in S, h(x) = M$$

  como la función vale lo mismo M en todos los estados, h es una función constante.

$\square$

Ejercicio 1.4. Propiedad de Markov Fuerte

Enuncie la propiedad de Markov fuerte en un tiempo de paro T y dé una condición suficiente para que $E^x[h(X_T)] = h(x)$.

- **1. Propiedad de Markov Fuerte:** La propiedad de Markov clásica establece que el futuro depende del presente en tiempos fijos n. La **Propiedad de Markov Fuerte** extiende este concepto a tiempos aleatorios conocidos como *tiempos de paro*.

  Sea T un tiempo de paro tal que $\mathbb{P}(T < \infty) = 1$. Condicionado al evento $\{X_T = y\}$, el proceso futuro $(X_{T+n})_{n\geq 0}$ es una cadena de Markov con las mismas probabilidades de transición $p(x, y)$ que la original, e independiente de la historia pasada $(X_0, X_1, \ldots, X_{T-1})$.

Interpretación

Esto implica que la cadena se reinicia en el instante T. No importa la regla que hayamos usado para detenernos; al llegar al tiempo de paro, el proceso olvida su trayectoria previa.

- **2. Condición suficiente para $E^x[h(X_T)] = h(x)$:** A partir del inciso (b), sabemos que si h es armónica, entonces $M_n = h(X_n)$ es una martingala. Para garantizar que el valor esperado al detenernos coincida con el valor inicial, invocamos el **Teorema de Paro Opcional de Doob**.

Teorema 1.1. Condición Suficiente (Teorema de Doob)

Para que se cumpla la igualdad $E^x[h(X_T)] = h(x)$, una condición suficiente es que:

- La función h sea **acotada** en todo el espacio de estados S. Es decir, existe $M > 0$ tal que $|h(y)| \leq M$ para todo $y \in S$.
- El tiempo de paro sea casi seguramente finito: $\mathbb{P}^x(T < \infty) = 1$.

1.2. Caminata aleatoria en $\mathbb{Z}$

Ejercicio 1.5. Caminata aleatoria en Z

Sea (X_n) la caminata aleatoria en $\mathbb{Z}$:

$$X_0 = 0, X_{n+1} = X_n + \xi_{n+1} \text{ con } \xi_i, i.i.d. P(\xi = +1) = p, P(\xi = -1) = q = 1 - p$$

Calcule $E^0[X_n]$ y $E^0[X_n^2]$

Tu posición en el paso n es la suma de todos los saltos que se han dado desde el origen.

$$X_n = \sum_{i=1}^{n} \xi_i$$

donde cada salto ξ_i es independiente y toma valores $+1$ con probabilidad p y -1 con probabilidad q.

- Esperanza de un salto.
$$E[\xi_i] = (+1) \cdot p + (-1) \cdot q = p - q$$
- Esperanza del salto al cuadrado.
$$E[\xi_i^2] = (+1)^2 \cdot p + (-1)^2 \cdot q = p + q = 1$$
- Cálculo de
$$E^0[X_n]$$
Sustituimos X_n por la suma de sus saltos y aplicamos la linealidad de la esperanza.
$$E^0 = E[\sum_{i=1}^{n} \xi_i] = \sum_{i=1}^{n} E[\xi_i] = \sum_{i=1}^{n} E[\xi_i]$$
Sustituyendo el valor de $E[\xi_i] = p - q$:
$$E^0[X_n] = \sum_{i=1}^{n} (p - q)$$
Como se esta sumando la misma constante $(p - q)$ exactamente n veces.
$$E^0[X_n] = n(p - q)$$
- Si $p > q$, tu posición esperada crece linealmente hacia la derecha. Si el juego es justo $(p = q)$, tu posición esperada es 0.
- Cálculo de
$$E^0[X_n^2]$$
Sustituimos X_n^2 por la suma de sus saltos y aplicamos la linealidad de la esperanza.
$$E^0 = E\left[\left(\sum_{i=1}^{n} \xi_i\right)^2\right]$$
Cuando se eleva al cuadrado la suma de los saltos, se obtiene:
$$E^0[X_n^2] = E\left[\sum_{i=1}^{n} \xi_i^2 + \sum_{i \neq j} \xi_i \xi_j\right]$$

Aplicando la linealidad de la esperanza, separamos los términos:

$$\sum_{i=1}^{n} E[\xi_i^2] + \sum_{i \neq j} E[\xi_i \xi_j]$$

Dado que los saltos son independientes, el producto de dos saltos diferentes tiene esperanza

- Sustituimos los valores base que calculamos al principio.
- $$E[\xi_i^2] = 1$$
- $$E[\xi_i \xi_j] = E[\xi_i]E[\xi_j] = (p-q)(p-q) = (p-q)^2$$
$$E^0\left[X_n^2\right] = \sum_{i=1}^{n} *(1) + \sum_{i \neq j} *(p-q)^2$$

La primera suma tiene n términos, y la segunda suma tiene $n(n-1)$ términos (ya que es la cantidad de pares distintos de índices).

$$E^0[X_n^2] = n + n(n-1)(p-q)^2$$

Ejercicio 1.6. Caminata Simétrica y Recurrencia

Para $p = q = \frac{1}{2}$, demuestre que $p^{2n}(0,0) = \binom{2n}{n}/4^n \sim (\pi n)^{-1/2}$ y que $\sum_n p^n(0,0) = +\infty$ (la cadena es recurrente).

Demostración. Esta demostración se divide en tres etapas: el cálculo combinatorio exacto, la aproximación asintótica de Stirling y el análisis de convergencia de la serie.

1. **Cálculo exacto de $p^{2n}(0,0)$:** Sea X_n la posición en el tiempo n. Para que $X_{2n} = 0$, la trayectoria debe consistir en exactamente n saltos a la derecha $(+1)$ y n saltos a la izquierda (-1).

   - El número total de trayectorias posibles de longitud $2n$ es 2^{2n}.
   - El número de trayectorias que regresan al origen es el número de formas de elegir n posiciones para los saltos positivos entre los $2n$ pasos totales: $\binom{2n}{n}$.
   - Como $p = q = 1/2$, cada trayectoria tiene probabilidad $(1/2)^{2n} = 1/4^n$.

   Por lo tanto:
   $$p^{2n}(0,0) = \mathbb{P}(X_{2n} = 0 \mid X_0 = 0) = \binom{2n}{n}\left(\frac{1}{4^n}\right)$$

2. **Aproximación asintótica de Stirling:** Utilizamos la *Fórmula de Stirling*: $k! \sim \sqrt{2\pi k}\left(\frac{k}{e}\right)^k$. Aplicamos esto al coeficiente binomial $\binom{2n}{n} = \frac{(2n)!}{(n!)^2}$:

   - Numerador: $(2n)! \sim \sqrt{4\pi n}\left(\frac{2n}{e}\right)^{2n} = 2\sqrt{\pi n}\frac{2^{2n}n^{2n}}{e^{2n}}$.
   - Denominador: $(n!)^2 \sim \left(\sqrt{2\pi n}\frac{n^n}{e^n}\right)^2 = 2\pi n\frac{n^{2n}}{e^{2n}}$.

   Dividiendo ambos términos obtenemos:
   $$\binom{2n}{n} \sim \frac{2\sqrt{\pi n}\cdot 2^{2n}\cdot n^{2n}/e^{2n}}{2\pi n\cdot n^{2n}/e^{2n}} = \frac{2^{2n}}{\sqrt{\pi n}} = \frac{4^n}{\sqrt{\pi n}}$$

   Sustituyendo en la probabilidad $p^{2n}(0,0)$:
   $$p^{2n}(0,0) \sim \frac{1}{4^n}\left(\frac{4^n}{\sqrt{\pi n}}\right) = \frac{1}{\sqrt{\pi n}} = (\pi n)^{-1/2}$$

3. **Criterio de Recurrencia:** Un estado i es recurrente si y solo si $\sum_{m=1}^{\infty} p^m(i,i) = \infty$. Para la caminata aleatoria, notamos que $p^m(0,0) = 0$ si m es impar. Por lo tanto, la serie se reduce a los términos pares:
   $$\sum_{n=1}^{\infty} p^n(0,0) = \sum_{n=1}^{\infty} p^{2n}(0,0)$$

   Convergencia de la Serie p

   Usando la aproximación obtenida:
   $$\sum_{n=1}^{\infty} p^{2n}(0,0) \sim \frac{1}{\sqrt{\pi}}\sum_{n=1}^{\infty}\frac{1}{n^{1/2}}$$

   Esta es una serie tipo p con $p = 1/2$. Como $p \leq 1$, la serie **diverge**.

$$\therefore \sum_{n=1}^{\infty} p^n(0,0) = +\infty$$

Suma de las probabilidades diverge, concluimos que el estado 0 es **recurrente**. □

Ejercicio 1.7. Caminata Sesgada y Transiencia

Para $p \neq q$, muestre que $\sum_n p^n(0,0) < \infty$.

Demostración. Procederemos a demostrar que cuando existe un sesgo en la caminata, la probabilidad de retorno al origen decrece lo suficientemente rápido como para que la serie de probabilidades sea finita.

- **1. Probabilidad exacta de retorno:** Para regresar al origen en $2n$ pasos, la trayectoria debe tener exactamente n pasos a la derecha $(+1)$ con probabilidad p y n pasos a la izquierda (-1) con probabilidad q.
$$p^{2n}(0,0) = \binom{2n}{n} p^n q^n$$
- **2. Aplicación de la aproximación de Stirling:** Retomando el resultado del inciso (b), sabemos que para n grande:
$$\binom{2n}{n} \sim \frac{4^n}{\sqrt{\pi n}}$$
Sustituyendo esto en nuestra expresión de probabilidad, obtenemos:
$$p^{2n}(0,0) \sim \frac{4^n}{\sqrt{\pi n}} p^n q^n = \frac{(4pq)^n}{\sqrt{\pi n}}$$

Demostración $4pq < 1$

Necesitamos determinar el comportamiento del término $r = 4pq$. Sabemos que $p + q = 1$ y por hipótesis $p \neq q$.
Si $p \neq q$, entonces $(p-q)^2 > 0$. Desarrollando:
$$p^2 - 2pq + q^2 > 0$$
Sumamos $4pq$ en ambos miembros:
$$p^2 + 2pq + q^2 > 4pq \implies (p+q)^2 > 4pq$$
Como $p + q = 1$, concluimos que:
$$1 > 4pq$$

- **3. Análisis de convergencia de la serie:** Sea $r = 4pq$. Dado que $r < 1$, analizamos la serie de potencias:
$$\sum_{n=1}^{\infty} p^{2n}(0,0) \sim \frac{1}{\sqrt{\pi}} \sum_{n=1}^{\infty} \frac{r^n}{n^{1/2}}$$
Esta serie converge por el **Criterio de la Razón**ya que el término r^n (geométrico con $r < 1$) domina sobre el término algebraico $n^{-1/2}$.

$\therefore$ Como $\sum_{n=1}^{\infty} p^n(0,0) < \infty$, el número esperado de visitas al origen es finito. Esto implica que la caminata aleatoria es **Transiente**: existe una probabilidad de 1 de que el proceso se aleje hacia el infinito y nunca regrese al origen.

$\square$

Ejercicio 1.8. Tiempos de Paro y Martingalas

Sean $a, b > 0$ enteros y $\tau = T_{\{-a,b\}}$. Use las martingalas X_n y $X_n^2 - n$ para calcular $\mathbb{P}^0(X_\tau = b)$ y $\mathbb{E}^0[\tau]$.

Definimos: El tiempo de paro τ como el primer instante en que la caminata aleatoria simple ($p = q = 1/2$) toca los niveles $-a$ o b.

Parte 1. Probabilidad de alcanzar el nivel b

Con la martingala X_n. Por el **Teorema de Paro Opcional de Doob**, el valor esperado del proceso en el tiempo de paro es igual a su valor inicial:

$$\mathbb{E}^0[X_\tau] = \mathbb{E}^0[X_0] = 0$$

Desarrollando la esperanza para los dos posibles estados finales:

$$b \cdot \mathbb{P}^0(X_\tau = b) + (-a) \cdot \mathbb{P}^0(X_\tau = -a) = 0$$

Sabiendo que $\mathbb{P}^0(X_\tau = -a) = 1 - \mathbb{P}^0(X_\tau = b)$, sustituimos:

$$b \cdot \mathbb{P}^0(X_\tau = b) - a(1 - \mathbb{P}^0(X_\tau = b)) = 0$$

$$(b + a)\mathbb{P}^0(X_\tau = b) = a$$

Probabilidad de éxito

La probabilidad de alcanzar la meta b antes que la ruina $-a$ es:

$$\mathbb{P}^0(X_\tau = b) = \frac{a}{a + b}$$

Parte 2. Tiempo esperado $E^0(\tau)$

Utilizando la martingala $M_n = X_n^2 - n$. Aplicando nuevamente el Teorema de Doob:

$$\mathbb{E}^0[X_\tau^2 - \tau] = \mathbb{E}^0[X_0^2 - 0] = 0$$

Por linealidad de la esperanza, esto implica que $\mathbb{E}^0[\tau] = \mathbb{E}^0[X_\tau^2]$. Calculamos este segundo momento:

$$\mathbb{E}^0[X_\tau^2] = b^2 \cdot \mathbb{P}^0(X_\tau = b) + (-a)^2 \cdot \mathbb{P}^0(X_\tau = -a)$$

Sustituyendo las probabilidades halladas en la Parte 1:

$$\mathbb{E}^0[\tau] = b^2 \left(\frac{a}{a + b}\right) + a^2 \left(\frac{b}{a + b}\right) = \frac{ab^2 + a^2 b}{a + b}$$

Factorizando ab en el numerador obtenemos:

$$\mathbb{E}^0[\tau] = \frac{ab(b + a)}{a + b} = ab$$

□

1.3. Clasificación de Estados y Comunicación

Ejercicio 1.9. Clasificación de Estados

Considere la cadena en $S = \{1, 2, 3, 4, 5\}$ con las probabilidades:

$$p(1,2) = p(1,3) = \frac{1}{2}, \quad p(2,4) = 1, \quad p(3,5) = 1, \quad p(5,1) = 1$$

y

$$p(4,1) = p(4,2) = p(4,3) = \frac{1}{3}$$

(a) Descomponga S en clases de comunicación e identifique cuáles son cerradas (recurrentes) y abiertas (transientes).

Para clasificar los estados, primero visualizamos las conexiones mediante un grafo dirigido donde los nodos representan los estados.

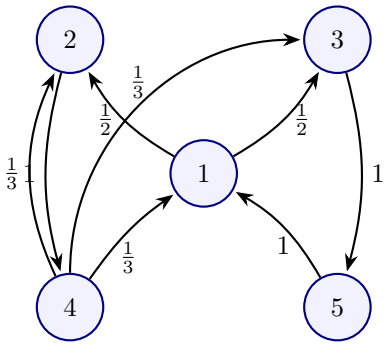

Sol.

- **1. Relación de Comunicación ($\leftrightarrow$):** Recordemos que $i \leftrightarrow j$ si existe un camino de i a j ($i \to j$) y de j a i ($j \to i$).
  - Del nodo **1** podemos llegar a todos: $1 \to 2$, $1 \to 3$.
  - Desde el **2** llegamos al **4**, y desde el **4** regresamos al **1**. Por lo tanto $\{1, 2, 4\}$ comunican.
  - Desde el **3** llegamos al **5**, y desde el **5** regresamos al **1**. Por lo tanto $\{1, 3, 5\}$ comunican.
- **2. Identificación de la Clase:** Puesto que todos los estados se comunican entre sí a través del estado 1, existe una **única clase de comunicación**:

$$C = \{1, 2, 3, 4, 5\}$$

Teorema 1.2. Irreducibilidad

Una cadena de Markov es **irreducible** si tiene una sola clase de comunicación. En este caso, al ser S finito e irreducible, todos sus estados son recurrentes.

- **Recurrencia y Transiencia:**
  - **Clase Cerrada:** La clase C es cerrada porque no hay flechas que salgan de este conjunto hacia algún estado externo.
  - **Recurrencia:** Al ser una clase cerrada y finita, todos los estados $\{1, 2, 3, 4, 5\}$ son **Recurrentes**.
  - **Transiencia:** No existen clases abiertas, no hay estados transientes.

□

Ejercicio 1.10. Cálculo del Período de un Estado

Calcule el período $d(x) = \text{mcd}\{n \geq 1 : p^n(x,x) > 0\}$ de cada estado.

Interpretación

El conjunto $\{n \geq 1 : p^n(x,x) > 0\}$ representa todas las longitudes posibles de las rutas que inician en el estado x y terminan de regreso en x. El período $d(x)$,el **Máximo Común Divisor (MCD)** de todas esas longitudes. Nos indica si la cadena está forzada a regresar al estado en múltiplos de algún número.

Teorema 1.3. Propiedad de Clase

La periodicidad es una propiedad compartida. Si dos estados x e y pertenecen a la misma clase de comunicación ($x \leftrightarrow y$), entonces tienen exactamente el mismo período:

$$d(x) = d(y)$$

Si $d(x) = 1$, se dice que el estado (y su clase) es **aperiódico**.

1. **Identificar Clases:** Se toma una clase de comunicación y se elige un estado representante x.
2. **Caso de Bucle Directo:** Si existe un bucle en el estado ($p(x,x) > 0$), el estado puede regresar en 1 paso. Por definición matemática, el MCD de un conjunto que contiene al 1 es 1. Así, $d(x) = 1$.
3. **Búsqueda de Ciclos:** Si no hay bucles, se trazan caminos cerrados desde x hasta x y se cuentan los saltos $(n_1, n_2, \dots)$.
4. **Cálculo del MCD:** Se evalúa $d(x) = \text{MCD}(n_1, n_2, \dots)$.
5. **Generalización:** Por el teorema de clase, se asigna el valor $d(x)$ calculado a todos los demás estados pertenecientes a la misma clase de comunicación.

Ejemplo Aplicado para comprensión

Considere una Cadena de Markov con espacio de estados $S = \{1, 2, 3, 4\}$ y las siguientes transiciones:

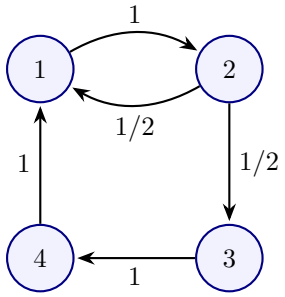

1.Identificar las rutas de regreso
Elegimos el estado 1 como nuestro punto de referencia. Rastreamos las trayectorias posibles que empiecen en 1 y terminen en 1:

- **Ruta A:** $1 \to 2 \to 1$. (Longitud = 2 pasos).
- **Ruta B:** $1 \to 2 \to 3 \to 4 \to 1$. (Longitud = 4 pasos).
- **Ruta C:** $1 \to 2 \to 1 \to 2 \to 1$. (Longitud = 4 pasos).
- **Ruta D:** $1 \to 2 \to 1 \to 2 \to 3 \to 4 \to 1$. (Longitud = 6 pasos).

2.Construir el conjunto de tiempos
El conjunto de tiempos en los que es posible regresar al estado 1 ($p^n(1,1) > 0$) es:

$$\{2, 4, 6, 8, \dots\}$$

3. Calcular el Máximo Común Divisor
Aplicamos la definición formal del período para el estado 1:

$$d(1) = \text{MCD}(2, 4, 6, 8, \dots) = \mathbf{2}$$

4. Aplicar la Propiedad de Clase
Observando el diagrama, es posible viajar desde cualquier estado hacia cualquier otro. Por lo tanto, existe una única clase de comunicación irreducible $C = \{1, 2, 3, 4\}$. Por el Teorema de Solidaridad, todos los estados heredan el mismo período:

$$d(1) = d(2) = d(3) = d(4) = \mathbf{2}$$

Conclusión: *La cadena de Markov es* ***periódica*** *con período $d = 2$. Esto significa que si empezamos en el estado 1, es matemáticamente imposible regresar a él en un número impar de pasos.*

Ejercicio 1.11. Teorema de Convergencia y Límite Asintótico

Aplique el teorema de convergencia para deducir $\lim_{n\to\infty} p^n(1,1)$.

Interpretación del Límite

El límite $\lim_{n\to\infty} p^n(1,1)$ representa la probabilidad a largo plazo de encontrar a la cadena en el estado 1, independientemente de dónde haya comenzado. A esta probabilidad de equilibrio se le conoce como la **distribución estacionaria**, denotada por el vector π.

Teorema 1.4. Teorema de Convergencia para Cadenas de Markov

Sea $(X_n)_{n\geq 0}$ una Cadena de Markov con espacio de estados finito. Si la cadena es:

1. **Irreducible** (Una sola clase de comunicación).
2. **Aperiódica** (Período $d(x) = 1$ para todo estado).

Entonces, existe una única distribución estacionaria π tal que para cualesquiera estados $x, y \in S$:

$$\lim_{n\to\infty} p^n(x,y) = \pi(y)$$

Condición Estacionaria

Para encontrar el vector $\pi = (\pi_1, \pi_2, \ldots, \pi_N)$, debemos resolver el sistema global de balance $\pi P = \pi$, sujeto a la condición de normalización.

$$\sum_{i\in S} \pi_i = 1$$

Resolución del Límite. En los incisos (a) y (b) demostramos que nuestra cadena es irreducible, finita y aperiódica. Por el Teorema de Convergencia, sabemos que:

$$\lim_{n\to\infty} p^n(1,1) = \pi_1$$

Planteamos el sistema de ecuaciones $\pi P = \pi$ analizando qué estados <u>apuntan</u> (entran) a cada nodo según las probabilidades de transición:

$$\pi_1 = \frac{1}{3}\pi_4 + 1\pi_5 \tag{1}$$
$$\pi_2 = \frac{1}{2}\pi_1 + \frac{1}{3}\pi_4 \tag{2}$$
$$\pi_3 = \frac{1}{2}\pi_1 + \frac{1}{3}\pi_4 \tag{3}$$
$$\pi_4 = 1\pi_2 \tag{4}$$
$$\pi_5 = 1\pi_3 \tag{5}$$

De las ecuaciones (2) y (3), notamos inmediatamente por simetría que $\pi_2 = \pi_3$.
Sustituyendo esto en (4) y (5), obtenemos que $\pi_4 = \pi_2$ y $\pi_5 = \pi_2$.
Por lo tanto: $\pi_2 = \pi_3 = \pi_4 = \pi_5$.

Sustituimos π_4 por π_2 en la ecuación (2):

$$\pi_2 = \frac{1}{2}\pi_1 + \frac{1}{3}\pi_2$$

Despejamos π_1 en función de π_2:

$$\pi_2 - \frac{1}{3}\pi_2 = \frac{1}{2}\pi_1 \implies \frac{2}{3}\pi_2 = \frac{1}{2}\pi_1 \implies \pi_2 = \frac{3}{4}\pi_1$$

Ahora utilizamos la condición de normalización (las probabilidades deben sumar 1):

$$\pi_1 + \pi_2 + \pi_3 + \pi_4 + \pi_5 = 1$$

Como π_2, π_3, π_4 y π_5 son todas iguales a $\frac{3}{4}\pi_1$, sustituimos:

$$\pi_1 + 4\left(\frac{3}{4}\pi_1\right) = 1$$

$$\pi_1 + 3\pi_1 = 1$$

$$4\pi_1 = 1 \implies \pi_1 = \frac{1}{4}$$

Conclusión: Aplicando el teorema de convergencia, el límite asintótico es:

$$\lim_{n\to\infty} p^n(1,1) = \frac{1}{4}$$

$\square$

Ejercicio 1.12. Medida Estacionaria en Clase Recurrente

Construya la medida estacionaria π sobre la clase recurrente y verifique que $\sum_x \pi(x)p(x,y) = \pi(y)$.

Diferencia entre Medida y Distribución

Una **distribución estacionaria** exige estrictamente que la suma de sus probabilidades sea 1 ($\sum \pi(x) = 1$).
Una **medida estacionaria** es un concepto más general y solo requiere cumplir la ecuación $\pi P = \pi$. Todo múltiplo escalar de una medida estacionaria sigue siendo una medida estacionaria.

Estados Transitorios

Si la Cadena de Markov es reducible, los estados transitorios eventualmente se vacían. Por definición, la medida estacionaria para cualquier estado transitorio z es $\pi(z) = 0$. Por ello, el análisis se reduce exclusivamente a la submatriz de la **clase recurrente**.

Construcción y Verificación. Para ilustrar el procedimiento, supongamos que tras clasificar los estados, aislamos una clase recurrente $C = \{1, 2\}$ con la siguiente matriz de transición restringida:

$$P_C = \begin{pmatrix} 1/3 & 2/3 \\ 1/2 & 1/2 \end{pmatrix}$$

1. Construcción de la medida

Planteamos el sistema de ecuaciones a partir de $\pi = \pi P_C$:

$$\pi(1) = \pi(1)p(1,1) + \pi(2)p(2,1) \implies \pi(1) = \frac{1}{3}\pi(1) + \frac{1}{2}\pi(2) \tag{6}$$

$$\pi(2) = \pi(1)p(1,2) + \pi(2)p(2,2) \implies \pi(2) = \frac{2}{3}\pi(1) + \frac{1}{2}\pi(2) \tag{7}$$

Tomamos la ecuación (1) y despejamos la relación entre los estados:

$$\pi(1) - \frac{1}{3}\pi(1) = \frac{1}{2}\pi(2) \implies \frac{2}{3}\pi(1) = \frac{1}{2}\pi(2) \implies \pi(1) = \frac{3}{4}\pi(2)$$

Como buscamos una medida (no necesariamente una distribución que sume 1), podemos asignar un valor arbitrario que elimine las fracciones. Sea $\pi(2) = 4$, entonces $\pi(1) = 3$.
Nuestra medida estacionaria sobre la clase recurrente es:

$$\pi = (3, 4)$$

(Nota: Si quisiéramos convertirla en distribución, dividiríamos entre la suma $3 + 4 = 7$, obteniendo $\pi = (3/7, 4/7)$).

2. Verificación de la condición $\sum_x \pi(x)p(x,y) = \pi(y)$

Debemos comprobar que la sumatoria se cumple para cada estado $y \in C$.

Comprobación para $y = 1$:

$$\sum_{x\in\{1,2\}} \pi(x)p(x,1) = \pi(1)p(1,1) + \pi(2)p(2,1) = (3)\left(\frac{1}{3}\right) + (4)\left(\frac{1}{2}\right) = 1 + 2 = 3 = \pi(1) \quad \checkmark$$

Comprobación para $y = 2$:

$$\sum_{x\in\{1,2\}} \pi(x)p(x,2) = \pi(1)p(1,2) + \pi(2)p(2,2) = (3)\left(\frac{2}{3}\right) + (4)\left(\frac{1}{2}\right) = 2 + 2 = 4 = \pi(2) \quad \checkmark$$

Queda demostrado formalmente que la medida construida satisface la ecuación de balance para todos los estados de la clase recurrente. □

1.4. Tiempo esperado de llegada

Ejercicio 1.13. Tiempo Esperado de Llegada

Sea (X_n) una caminata en $\mathbb{N}_0$ con $p(x, x+1) = p$, $p(x, x-1) = q = 1-p$ para $x \geq 1$, y reflexión en el origen $p(0,1) = 1$. Fije $N \geq 1$ y sea $T = T_{\{N\}}$.

a) Defina $h(x) = E^x[T]$ y escriba la ecuación en diferencias satisfecha por h en $1 \leq x \leq N-1$, con condiciones $h(0) - h(1) = 1$ y $h(N) = 0$.

Análisis

Para calcular el tiempo esperado de llegada a un conjunto, condicionamos sobre el resultado del **primer salto** de la cadena. La lógica es: el tiempo total esperado es igual a 1 (el paso que acabamos de dar) más el tiempo esperado desde el nuevo estado al que llegamos, ponderado por las probabilidades de transición.

Condiciones de Frontera

Las condiciones de frontera determinan el comportamiento en los extremos del dominio:

- **Condición de absorción (Meta):** Si la cadena inicia en el estado N, el tiempo para llegar a N es cero. $\implies h(N) = 0$.
- **Condición de reflexión (Origen):** Si la cadena está en 0, forzosamente salta a 1 con probabilidad 1. Toma 1 paso llegar a 1, y desde ahí el tiempo esperado es $h(1)$. $\implies h(0) = 1 + h(1) \implies h(0) - h(1) = 1$.

Construcción de la Ecuación en Diferencias. Por definición, $h(x) = E[T \mid X_0 = x]$. Aplicamos la ley de la esperanza total condicionando sobre el primer paso X_1:

$$h(x) = E[T \mid X_0 = x] = \sum_{y \in \mathbb{N}_0} E[T \mid X_0 = x, X_1 = y] \cdot p(x, y)$$

Sabemos que si damos un paso hacia y, el tiempo restante esperado es simplemente el tiempo esperado desde y, más el paso que ya dimos:

$$E[T \mid X_0 = x, X_1 = y] = 1 + E[T \mid X_0 = y] = 1 + h(y)$$

Sustituyendo esto en la sumatoria:

$$h(x) = \sum_{y \in \mathbb{N}_0} (1 + h(y)) \cdot p(x, y)$$

$$h(x) = \sum_{y} p(x, y) + \sum_{y} h(y) p(x, y)$$

Como la suma de las probabilidades es 1 ($\sum p(x, y) = 1$), la ecuación se simplifica a:

$$h(x) = 1 + \sum_{y \in \mathbb{N}_0} h(y) p(x, y)$$

Para cualquier estado intermedio $1 \leq x \leq N-1$, la cadena solo puede saltar a $x+1$ (con probabilidad p) o a $x-1$ (con probabilidad q). Expandiendo la sumatoria para estos dos únicos caminos posibles, obtenemos nuestra ecuación en diferencias:

$$\mathbf{h(x) = 1 + p \cdot h(x+1) + q \cdot h(x-1)}$$

Rearreglando los términos para darle el formato clásico de ecuación en diferencias, tenemos:

$$\mathbf{ph(x+1) - h(x) + qh(x-1) = -1} \quad \text{para } 1 \leq x \leq N-1$$

□

Ejercicio 1.14. Resolución de la Ecuación en Diferencias ($p \neq q$)

Resuelva para $p \neq q$:

$$h(x) = \frac{N-x}{p-q} + \frac{q}{(p-q)^2}\left[\left(\frac{q}{p}\right)^N - \left(\frac{q}{p}\right)^x\right]$$

Método

La ecuación es $ph(x+1) - h(x) + qh(x-1) = -1$. Esta es una ecuación en diferencias lineal de segundo orden no homogénea. La solución general tiene la forma $h(x) = h_H(x) + h_P(x)$, donde h_H es la solución homogénea y h_P es una solución particular.

. **1.Solución Homogénea** $h_H(x)$ Igualamos la ecuación a cero: $ph(x+1) - h(x) + qh(x-1) = 0$. Proponemos una solución de la forma r^x, lo que nos da la ecuación característica:

$$pr^2 - r + q = 0$$

Como sabemos que $p + q = 1$, podemos reescribir el término central:

$$pr^2 - (p+q)r + q = 0 \implies (r-1)(pr-q) = 0$$

Las raíces son $r_1 = 1$ y $r_2 = \frac{q}{p}$. Como $p \neq q$, las raíces son distintas. La solución homogénea es:

$$h_H(x) = C_1(1)^x + C_2\left(\frac{q}{p}\right)^x = C_1 + C_2\left(\frac{q}{p}\right)^x$$

2. Solución Particular $h_P(x)$ Como el término independiente es una constante (-1) y $r = 1$ ya es una raíz de la homogénea, proponemos una solución particular de la forma $h_P(x) = Ax$.
Sustituimos en la ecuación original:

$$pA(x+1) - Ax + qA(x-1) = -1$$

$$Ax(p-1+q) + A(p-q) = -1$$

Como $p + q = 1$, el primer término se cancela ($p + q - 1 = 0$), dejándonos con:

$$A(p-q) = -1 \implies A = \frac{-1}{p-q}$$

Por lo tanto, la solución particular es $h_P(x) = \frac{-x}{p-q}$.

3. Solución General Sumamos ambas partes para obtener la forma general:

$$h(x) = C_1 + C_2\left(\frac{q}{p}\right)^x - \frac{x}{p-q}$$

4. Aplicar Condiciones de Frontera Usaremos las condiciones dadas: $h(N) = 0$ y $h(0) - h(1) = 1/p$.

Primero, aplicamos la condición en el origen:

$$h(0) = C_1 + C_2$$

$$h(1) = C_1 + C_2\left(\frac{q}{p}\right) - \frac{1}{p-q}$$

Restamos ambas:

$$h(0) - h(1) = C_2 - C_2\left(\frac{q}{p}\right) + \frac{1}{p-q} = \frac{1}{p}$$

Factorizamos C_2 y pasamos la fracción al otro lado:

$$C_2\left(1 - \frac{q}{p}\right) = \frac{1}{p} - \frac{1}{p-q}$$

Simplificamos ambos lados:

$$C_2\left(\frac{p-q}{p}\right) = \frac{(p-q)-p}{p(p-q)} = \frac{-q}{p(p-q)}$$

Multiplicando ambos lados por p y dividiendo entre $(p-q)$:

$$\mathbf{C_2 = \frac{-q}{(p-q)^2}}$$

Ahora, usamos la condición en la meta $h(N) = 0$ para hallar C_1:

$$0 = C_1 + C_2\left(\frac{q}{p}\right)^N - \frac{N}{p-q} \implies C_1 = \frac{N}{p-q} - C_2\left(\frac{q}{p}\right)^N$$

Sustituimos el valor de C_2:

$$\mathbf{C_1 = \frac{N}{p-q} + \frac{q}{(p-q)^2}\left(\frac{q}{p}\right)^N}$$

Paso 5: Ensamblar la Fórmula Final

Sustituimos C_1 y C_2 en nuestra solución general $h(x)$:

$$h(x) = \left[\frac{N}{p-q} + \frac{q}{(p-q)^2}\left(\frac{q}{p}\right)^N\right] - \frac{q}{(p-q)^2}\left(\frac{q}{p}\right)^x - \frac{x}{p-q}$$

Agrupamos los términos con denominadores comunes:

$$h(x) = \frac{N-x}{p-q} + \frac{q}{(p-q)^2}\left[\left(\frac{q}{p}\right)^N - \left(\frac{q}{p}\right)^x\right]$$

Queda demostrada la fórmula requerida. □

Ejercicio 1.15. Caso Simétrico y Análisis Asintótico

(c) Resuelva para $p = q = 1/2$: $h(x) = N(N+1) - x(x+1)$.
(d) Analice el orden de $h(0)$ en N para los tres regímenes $p > q$, $p = q$, $p < q$.

Raíces Repetidas en Ecuaciones

Para el caso $p = q = 1/2$, la ecuación característica de la parte homogénea es $\frac{1}{2}r^2 - r + \frac{1}{2} = 0 \implies r^2 - 2r + 1 = 0$. Esto nos da una **raíz doble** $r = 1$.La solución homogénea toma la forma $C_1 + C_2 x$. Y como 1 y x ya están ocupados, la solución particular debe tener la forma Ax^2.

Inciso (c). Partimos de nuestra ecuación : $ph(x+1) - h(x) + qh(x-1) = -1$.
Sustituyendo $p = q = 1/2$ y multiplicando todo por 2 para eliminar fracciones:

$$h(x+1) - 2h(x) + h(x-1) = -2$$

1. Solución Particular $h_P(x)$: Proponemos $h_P(x) = Ax^2$.

$$A(x+1)^2 - 2Ax^2 + A(x-1)^2 = -2$$

$$A(x^2 + 2x + 1) - 2Ax^2 + A(x^2 - 2x + 1) = -2$$

$$A(2x^2 + 2) - 2Ax^2 = 2A = -2 \implies A = -1$$

Por tanto, $h_P(x) = -x^2$.

2. Solución General: Sumando la homogénea y la particular:

$$h(x) = C_1 + C_2 x - x^2$$

3. Condiciones de Frontera:

Usamos $h(N) = 0$ y $h(0) - h(1) = 1/p$. Como $p = 1/2$, tenemos $h(0) - h(1) = 2$.
Evaluamos en 0 y en 1:

$$h(0) = C_1$$

$$h(1) = C_1 + C_2 - 1$$

Restamos para aplicar la condición:

$$h(0) - h(1) = C_1 - (C_1 + C_2 - 1) = 1 - C_2 = 2 \implies C_2 = -1$$

Sustituimos C_2 en la ecuación general:

$$h(x) = C_1 - x - x^2 = C_1 - x(x+1)$$

Finalmente, aplicamos $h(N) = 0$:

$$C_1 - N(N+1) = 0 \implies C_1 = N(N+1)$$

Sustituyendo C_1, llegamos a la demostración exacta solicitada:

$$\mathbf{h(x) = N(N+1) - x(x+1)}$$

□

Interpretación (Inciso d)

Evaluar el orden de $h(0)$ en N significa observar cómo crece el tiempo esperado para llegar a N desde el origen cuando alejamos la meta hacia el infinito.

Inciso (d). Evaluamos el tiempo desde el origen $h(0)$ para los tres casos:

1. Régimen $p = q$ (Caminata Simétrica):
Usamos la fórmula del inciso (c) evaluada en $x = 0$:

$$h(0) = N(N+1) = N^2 + N$$

Asintóticamente, el término dominante es N^2. Por lo tanto, el tiempo de llegada crece de forma **cuadrática**.

$$\mathbf{h(0) = \Theta(N^2)}$$

2. Régimen $p > q$ (positivo, a favor de la meta):
Usamos la fórmula general del inciso (b) evaluada en $x = 0$:

$$h(0) = \frac{N}{p-q} + \frac{q}{(p-q)^2}\left[\left(\frac{q}{p}\right)^N - 1\right]$$

Como $p > q$, la fracción $\frac{q}{p} < 1$. Por lo tanto, cuando $N \to \infty$, el término exponencial $(\frac{q}{p})^N \to 0$. El tiempo queda dominado puramente por el término lineal $\frac{N}{p-q}$.

$$\mathbf{h(0) = \Theta(N)}$$

*(El tiempo crece de forma **lineal**. Como la caminata te empuja hacia la derecha, el tiempo es simplemente proporcional a la distancia).*

3. Régimen $p < q$ (negativo, en contra de la meta):
Tomamos la misma fórmula del inciso (b). Pero ahora, como $p < q$, la fracción $\frac{q}{p} > 1$.
Cuando $N \to \infty$, el término $(\frac{q}{p})^N$ crece sin límite y domina por completo al término lineal N.

$$\mathbf{h(0) = \Theta\left(\left(\frac{q}{p}\right)^N\right)}$$

*(El tiempo crece de forma **exponencial**. Estás luchando contra la corriente; llegar a una meta lejana requiere una racha de suerte estadísticamente minúscula).* □

1.5. Probabilidad de ruina (jugador)

Ejercicio 1.16. Probabilidad de Ruina del Jugador

Con la misma cadena del Ejercicio 1.4, sea $u(x) = P^x(T_{\{N\}} < T^+_{\{0\}})$.

(a) Escriba la ecuación en diferencias para $u(x)$ con condiciones $u(0) = 0$ y $u(N) = 1$.

Análisis (Probabilidades)

A diferencia del cálculo del tiempo esperado (donde sumábamos 1 por cada paso dado), cuando calculamos **probabilidades de absorción**, no acumulamos tiempo. Simplemente multiplicamos la probabilidad de dar un salto hacia un estado adyacente por la probabilidad de ganar desde ese nuevo estado.

Condiciones de Frontera (Ruina y Meta)

Las condiciones definen cuándo termina el juego:

- **Meta ($u(N) = 1$):** Si empiezas en N, ya llegaste a N antes que a 0. Ganar es un evento seguro, la probabilidad es 1.
- **Ruina ($u(0) = 0$):** Si empiezas en 0, ya perdiste. Es imposible llegar a N antes de tocar el fondo, la probabilidad es 0.

Construcción de la Ecuación. Por definición, $u(x)$ es la probabilidad de que la cadena alcance el estado N antes de regresar o tocar el estado 0, asumiendo que empezamos en el estado x ($1 \leq x \leq N-1$).

Aplicamos la Ley de Probabilidad Total condicionando sobre el resultado del primer paso X_1:

$$u(x) = \sum_y P(T_{\{N\}} < T^+_{\{0\}} \mid X_1 = y) \cdot p(x, y)$$

Por la propiedad de Markov (el futuro solo depende del estado actual y), la probabilidad de ganar desde el estado y es simplemente $u(y)$. Sustituimos:

$$u(x) = \sum_y u(y)p(x, y)$$

Expandimos esta suma escribiendo término por término, se vería algo así (imaginando los estados alrededor de x)

$$u(x) = \cdots + u(x-2)p(x, x-2) + u(x-1)p(x, x-1) + u(x)p(x, x) + u(x+1)p(x, x+1) + u(x+2)p(x, x+2) + \ldots$$

Sabemos que desde un estado intermedio x, la cadena solo tiene dos caminos posibles en el siguiente instante:

1. Probabilidad de avanzar un paso $p(x, x+1) = p$
2. Probabilidad de retroceder un paso $p(x, x-1) = q$
3. Probabilidad de quedarse quieto: $p(x, x) = 0$ (no hay auto-transiciones)
4. Probabilidad de saltar a cualquier otro estado: $p(x, y) = 0$ para cualquier y.

Sustituimos estos valores:

$$u(x) = \cdots + u(x-2)(0) + u(x-1)(q) + u(x)(0) + u(x+1)(p) + u(x+2)(0) + \ldots$$

Expandiendo la sumatoria para estos dos únicos saltos:

$$\mathbf{u(x) = p \cdot u(x+1) + q \cdot u(x-1)}$$

Para darle la forma estándar de una ecuación en diferencias lineal homogénea, pasamos $u(x)$ al lado derecho (o igualamos a cero):

$$\mathbf{pu(x+1) - u(x) + qu(x-1) = 0} \quad \text{para } 1 \leq x \leq N-1$$

$\square$

Ejercicio 1.17. Probabilidad de Ruina

Resuelva para $p \neq q$:

$$u(x) = \frac{1-(q/p)^x}{1-(q/p)^N}$$

Martingalas

Fórmula es idéntica al resultado obtenido al aplicar el Teorema de Paro Opcional de Doob a la martingala exponencial $M_n = (q/p)^{X_n}$. Aquí demostraremos el mismo resultado utilizando la teoría de ecuaciones en diferencias lineales homogéneas.

Resolución de la Ecuación en Diferencias. Partimos de la ecuación obtenida en el inciso (a):

$$pu(x+1) - u(x) + qu(x-1) = 0$$

1.Ecuación Característica

Como es una ecuación lineal homogénea, proponemos una solución de la forma $u(x) = r^x$. Sustituyendo, obtenemos el polinomio característico:

$$pr^2 - r + q = 0$$

Dado que sabemos por definición que $p + q = 1$, podemos reescribir el término central:

$$pr^2 - (p+q)r + q = 0 \implies pr^2 - pr - qr + q = 0$$

Factorizando por agrupación:

$$pr(r-1) - q(r-1) = 0 \implies (pr-q)(r-1) = 0$$

Las raíces características son:

$$r_1 = 1 \quad \text{y} \quad r_2 = \frac{q}{p}$$

2.Solución General

Como la condición del problema establece que $p \neq q$, las dos raíces son distintas. Por teoría, la solución general es una combinación lineal de ambas:

$$u(x) = C_1(r_1)^x + C_2(r_2)^x$$

$$u(x) = C_1(1)^x + C_2\left(\frac{q}{p}\right)^x = C_1 + C_2\left(\frac{q}{p}\right)^x$$

3.Aplicar Condiciones de Frontera

Utilizamos las condiciones $u(0) = 0$ (ruina segura) y $u(N) = 1$ (meta alcanzada).

Primero evaluamos en el origen ($x = 0$):

$$u(0) = C_1 + C_2\left(\frac{q}{p}\right)^0 = C_1 + C_2 = 0 \implies C_1 = -C_2$$

Sustituimos esta relación en nuestra solución general:

$$u(x) = -C_2 + C_2\left(\frac{q}{p}\right)^x = C_2\left[\left(\frac{q}{p}\right)^x - 1\right]$$

Ahora evaluamos en la meta ($x = N$):

$$u(N) = C_2\left[\left(\frac{q}{p}\right)^N - 1\right] = 1$$

Despejamos la constante C_2:

$$C_2 = \frac{1}{\left(\frac{q}{p}\right)^N - 1}$$

4.Ensamblar la Fórmula Final

Sustituimos el valor de C_2 de regreso en nuestra ecuación para $u(x)$:

$$u(x) = \left(\frac{1}{\left(\frac{q}{p}\right)^N - 1}\right)\left[\left(\frac{q}{p}\right)^x - 1\right]$$

Para que coincida exactamente con la presentación clásica de la fórmula (donde los términos positivos van primero), multiplicamos el numerador y el denominador por -1:

$$u(x) = \frac{1 - \left(\frac{q}{p}\right)^x}{1 - \left(\frac{q}{p}\right)^N}$$

$\square$

Ejercicio 1.18. Ruina en Juego Simétrico y Análisis de Transitoriedad

(c) Para $p = q = 1/2$, obtenga $u(x) = x/N$.
(d) Analice $u(1)$ cuando $N \to \infty$ en cada régimen. ¿Cómo se relaciona con la recurrencia o transencia de la cadena?

Raíz de Probabilidades

$p = q = 1/2$, la ecuación característica de la relación de recurrencia tiene una raíz doble $r = 1$. Para ecuaciones lineales homogéneas, la solución general toma la forma $u(x) = C_1 + C_2 x$.

Inciso (c). Partimos de la solución general para el caso de raíz repetida:

$$u(x) = C_1 + C_2 x$$

Aplicamos las condiciones de frontera $u(0) = 0$ y $u(N) = 1$:
1. Evaluamos en el origen:

$$u(0) = C_1 + C_2(0) = 0 \implies C_1 = 0$$

2. Sustituimos C_1 y evaluamos en la meta:

$$u(N) = 0 + C_2(N) = 1 \implies C_2 = \frac{1}{N}$$

3. Solución final:

$$\mathbf{u(x) = \frac{x}{N}}$$

□

Probabilidad al Infinito

En nuestra cadena sobre $\mathbb{N}_0$, estando en 0 saltamos al 1 con probabilidad 1. El retorno al origen depende de lo que pase desde el estado 1. La probabilidad de **nunca regresar al origen** (escapar al infinito) empezando en 1 es exactamente el límite $\lim_{N\to\infty} u(1)$.

- Si $\lim u(1) = 0 \implies$ El retorno es seguro. La cadena es **Recurrente**.
- Si $\lim u(1) > 0 \implies$ Existe probabilidad de escape. La cadena es **Transitoria**.

Inciso (d). Evaluamos el límite $\lim_{N\to\infty} u(1)$ para los tres regímenes:
1. Régimen $p = q = 1/2$ (Juego Simétrico): Usamos la fórmula del inciso (c):

$$\lim_{N\to\infty} u(1) = \lim_{N\to\infty} \frac{1}{N} = 0$$

Conclusión: La probabilidad de escapar al infinito es 0. La partícula siempre será arrastrada de vuelta al origen tarde o temprano. La cadena es **Recurrente**.

2. Régimen $p < q$: Usamos la fórmula del inciso (b) evaluada en $x = 1$. Como $p < q$, entonces $\frac{q}{p} > 1$.

$$\lim_{N\to\infty} u(1) = \lim_{N\to\infty} \frac{1 - (q/p)^1}{1 - (q/p)^N}$$

Como el término $(q/p)^N$ tiende a infinito, el denominador crece sin límite:

$$\lim_{N\to\infty} \frac{1 - q/p}{-\infty} = 0$$

Conclusión: La probabilidad de escapar hacia la derecha es nula. La cadena es **Recurrente** (específicamente, positiva recurrente).

3. Régimen $p > q$: Como $p > q$, entonces $\frac{q}{p} < 1$.

$$\lim_{N\to\infty} u(1) = \lim_{N\to\infty} \frac{1-(q/p)^1}{1-(q/p)^N}$$

Como la base es menor a 1, el término $(q/p)^N$ tiende a 0 cuando $N \to \infty$:

$$\lim_{N\to\infty} \frac{1-q/p}{1-0} = 1 - \frac{q}{p}$$

Conclusión: Dado que $q/p < 1$, el resultado $1 - q/p$ es un número estrictamente **mayor a cero**. Esto significa que hay una probabilidad real de que la partícula se vaya al infinito y jamás regrese a tocar el origen. Por lo tanto, la cadena es **Transitoria**. □

2. Medidas estacionarias, recurrencia y ergodicidad

2.1. Existencia, unicidad y tiempo de retorno

Ejercicio 2.1. Existencia, unicidad y tiempo de retorno

Sea (X_n) una cadena irreducible en un espacio de estados S numerable.

(a) Demuestre que $\pi(x) = 1/E^x[T_x^+]$ define una medida estacionaria positiva.

Teorema 2.1. El Teorema de Kac y la Medida de Excursión :

onstruir primero una **medida de excursión** $\gamma_x(y)$. Esta medida cuenta el número de veces esperado que la cadena visita el estado y entre dos visitas consecutivas al estado x.

$$\gamma_x(y) = E^x\left[\sum_{k=1}^{T_x^+} \mathbf{1}_{\{X_k=y\}}\right]$$

Por teoría de Markov, se sabe que esta medida γ_x siempre es invariante (cumple $\gamma_x P = \gamma_x$).

Condición de Positividad

Para que la medida $\pi(x)$ sea estrictamente positiva y válida como distribución, el tiempo esperado de retorno debe ser finito ($E^x[T_x^+] < \infty$). Esto ocurre sí y solo sí la cadena irreducible es **recurrente positiva**.

Demostración del Límite Estacionario. **1.La masa total de la medida de excursión.**
Si sumamos el número esperado de visitas a *todos* los estados $y \in S$ durante una excursión desde x hasta regresar a x, obtendremos exactamente el tiempo total que duró la excursión. Matemáticamente, por linealidad de la esperanza:

$$\sum_{y\in S} \gamma_x(y) = E^x\left[\sum_{y\in S}\sum_{k=1}^{T_x^+} \mathbf{1}_{\{X_k=y\}}\right] = E^x\left[\sum_{k=1}^{T_x^+} 1\right] = E^x[T_x^+]$$

2. Normalización para crear una distribución.
Dado que γ_x es una medida estacionaria ($\gamma_x P = \gamma_x$), cualquier múltiplo escalar de ella también lo es. Para convertirla en una *distribución de probabilidad* estacionaria π, dividimos la medida de cada estado entre la masa total de la excursión:

$$\pi(y) = \frac{\gamma_x(y)}{\sum_{z\in S}\gamma_x(z)} = \frac{\gamma_x(y)}{E^x[T_x^+]}$$

Como $\gamma_x P = \gamma_x$, se cumple automáticamente que $\pi P = \pi$, por lo que π es efectivamente una medida estacionaria.

3. Evaluación en el estado x (El Teorema de Kac).
Ahora analizamos qué ocurre específicamente en el estado de referencia $y = x$. Por definición, $\gamma_x(x)$ es el número de veces que visitamos el estado x durante el trayecto desde x hasta el primer retorno a x. Evidentemente, esto ocurre exactamente **una sola vez** (justo en el instante de retorno T_x^+).

$$\gamma_x(x) = 1$$

Sustituyendo este valor en nuestra distribución normalizada π, obtenemos:

$$\pi(x) = \frac{\gamma_x(x)}{E^x[T_x^+]} = \frac{1}{E^x[T_x^+]}$$

Conclusión: Como la cadena es irreducible (si un estado es recurrente positivo, todos lo son), $0 < E^x[T_x^+] < \infty$. Por lo tanto, $\pi(x) = \frac{1}{E^x[T_x^+]}$ está bien definida, cumple $\pi P = \pi$, y es estrictamente positiva. Queda demostrado. $\square$

Ejercicio 2.2. Conclusión: Teorema Fundamental de Cadenas de Markov

Concluya: (X_n) es recurrente positiva si y solo si existe una probabilidad estacionaria π. En ese caso, π es única y $\pi(x) = 1/E^x[T_x^+]$.

Demostración

Al ser una implicación bidireccional ($\Longleftrightarrow$), la demostración exige dos caminos lógicos rigurosos:

1. **Ida ($\Longrightarrow$):** Asumir que la cadena es recurrente positiva y demostrar que π es una distribución de probabilidad válida.
2. **Regreso ($\Longleftarrow$):** Asumir que π existe como distribución y demostrar que la cadena está obligada a ser recurrente positiva.

Demostración. **1. Ida ($\Longrightarrow$): Recurrente positiva $\Longrightarrow$ $\exists\pi$ distribución estacionaria.**
Si la cadena es recurrente positiva, por definición su tiempo esperado de retorno es finito: $E^x[T_x^+] < \infty$. En el inciso (a), construimos la medida estacionaria $\pi(y) = \frac{\gamma_x(y)}{E^x[T_x^+]}$. Para garantizar que existe como una *probabilidad* (y no solo como una medida), debemos probar que la suma de todos sus elementos es exactamente 1.
Sumamos sobre todo el espacio de estados S:

$$\sum_{y\in S} \pi(y) = \sum_{y\in S} \frac{\gamma_x(y)}{E^x[T_x^+]} = \frac{1}{E^x[T_x^+]} \sum_{y\in S} \gamma_x(y)$$

Sabemos que la suma de todas las visitas de la excursión $\sum \gamma_x(y)$ es igual al tiempo total del viaje $E^x[T_x^+]$. Sustituyendo esto:

$$\sum_{y\in S} \pi(y) = \frac{E^x[T_x^+]}{E^x[T_x^+]} = 1$$

Por lo tanto, π es una probabilidad estacionaria bien definida.

2. Regreso ($\Longleftarrow$): $\exists\pi$ $\Longrightarrow$ Recurrente positiva.
Supongamos que existe una probabilidad estacionaria π. Al ser una distribución sobre una cadena irreducible, todos los estados deben tener probabilidad estrictamente positiva ($\pi(x) > 0$).
Por la relación del Lema de Kac obtenida en (a), sabemos que el peso de π en un estado está dictado por su tiempo de retorno:

$$\pi(x) = \frac{1}{E^x[T_x^+]} > 0$$

Para que esta fracción sea estrictamente mayor a cero (como lo exige una distribución de probabilidad irreducible), el denominador **no puede ser infinito**.

$$E^x[T_x^+] < \infty$$

Tener un tiempo de retorno esperado finito es la definición matemática exacta de ser una cadena **recurrente positiva**.

3. Unicidad:
La unicidad se deriva directamente de la irreducibilidad de la cadena. Al estar todos los estados comunicados, la medida de excursión γ_x respecto a un estado x está unívocamente determinada por la matriz de transición P. Como la fórmula $\pi(x) = 1/E^x[T_x^+]$ fija el valor exacto para cada estado basándose en una çonstante física"de la red (su tiempo de retorno), es imposible que el sistema de ecuaciones $\pi P = \pi$ con $\sum \pi = 1$ tenga otra solución linealmente independiente. La distribución es única. $\square$

Ejercicio 2.3. Ley Ergódica y Contraejemplo Nulo Recurrente

(c) Enuncie y demuestre la ley ergódica: si $\pi(f) < \infty$, entonces $(1/n)\sum_{k=0}^{n-1} f(X_k) \to \pi(f)$ casi seguramente.
(d) Dé un ejemplo en $S = \mathbb{N}_0$ de cadena irreducible recurrente nula. Verifique que no existe probabilidad estacionaria.

Intuición de la Ley Ergódica

La Ley Ergódica establece que **el promedio temporal iguala al promedio espacial**. Es decir, el promedio de una función evaluada a lo largo de la trayectoria de la cadena (lo que observamos empíricamente) converge al valor esperado de esa función respecto a la distribución estacionaria π (la teoría).

Demostración (Esbozo analítico de la Ley Ergódica). Sea una cadena recurrente positiva con distribución estacionaria π. Elegimos un estado de referencia x y dividimos la trayectoria de la cadena en .^excursiones"(los bloques de tiempo entre visitas consecutivas a x).

Por la propiedad fuerte de Markov, el comportamiento de la cadena en cada excursión es independiente de las demás y tiene la misma distribución (son variables i.i.d.). Sea Y_i la suma de $f(X_k)$ durante la i-ésima excursión, y τ_i la duración de esa excursión.

Aplicando la Ley Fuerte de los Grandes Números (SLLN) a estas variables independientes, a medida que el número de pasos $n \to \infty$, el promedio a lo largo de los pasos converge al cociente de las esperanzas en una sola excursión:

$$\frac{1}{n}\sum_{k=0}^{n-1} f(X_k) \xrightarrow{c.s.} \frac{E^x\left[\sum_{k=1}^{T_x^+} f(X_k)\right]}{E^x[T_x^+]}$$

Recordando nuestro Teorema de Kac (inciso a), el término de abajo es $1/\pi(x)$, y el término de arriba es la suma respecto a la medida de excursión $\gamma_x(f)$. Al multiplicar por $\pi(x)$, obtenemos exactamente la esperanza respecto a π:

$$\xrightarrow{c.s.} \sum_{y\in S} f(y)\pi(y) = \pi(f)$$

Queda demostrada la convergencia casi segura. □

El peligro de los espacios infinitos

En espacios finitos, si una cadena es irreducible, automáticamente es recurrente positiva. Sin embargo, en espacios infinitos (como $\mathbb{N}_0$), la cadena puede "perder el tiempo"viajando infinitamente lejos, haciendo que el tiempo promedio de retorno sea infinito, volviéndola **recurrente nula**.

Ejemplo de Cadena Recurrente Nula (Inciso d). **1. Propuesta de Cadena:**
Consideramos la caminata aleatoria simétrica sobre $\mathbb{N}_0$ con reflexión en el origen. Sus probabilidades de transición son:

- $p(x, x+1) = 1/2 \quad \text{y} \quad p(x, x-1) = 1/2 \quad \text{para } x \geq 1$
- $p(0, 1) = 1$

Esta cadena es **irreducible** (todos se comunican) y **recurrente** (al ser simétrica en 1D, siempre regresa). Veamos si es nula.

2. Verificación de inexistencia de π:
Supongamos, por contradicción, que existe una distribución estacionaria π tal que $\pi P = \pi$ y $\sum \pi(x) = 1$. Planteamos las ecuaciones de balance:

$$\text{Para } x = 0: \quad \pi(0) = \pi(1)p(1,0) = \frac{1}{2}\pi(1) \implies \pi(1) = 2\pi(0)$$

$$\text{Para } x = 1: \quad \pi(1) = \pi(0)p(0,1) + \pi(2)p(2,1) = \pi(0) + \frac{1}{2}\pi(2)$$

Sustituimos $\pi(1)$ en la segunda ecuación:

$$2\pi(0) = \pi(0) + \frac{1}{2}\pi(2) \implies \pi(0) = \frac{1}{2}\pi(2) \implies \pi(2) = 2\pi(0)$$

Si continuamos de forma inductiva para todo $x \geq 1$:

$$\pi(x) = \frac{1}{2}\pi(x-1) + \frac{1}{2}\pi(x+1)$$

Se puede demostrar que la única solución a esta relación de recurrencia que cumple las condiciones de frontera iniciales es que todas las probabilidades sean constantes:

$$\pi(x) = 2\pi(0) \quad \text{para todo } x \geq 1$$

3. La contradicción matemática:
Para que π sea una probabilidad, debe sumar 1:

$$\sum_{x=0}^{\infty} \pi(x) = \pi(0) + \sum_{x=1}^{\infty} 2\pi(0) = \pi(0) + 2\pi(0) + 2\pi(0) + \dots$$

Si $\pi(0) > 0$, esta suma diverge a infinito (nunca suma 1).
Si $\pi(0) = 0$, entonces todos los $\pi(x) = 0$, y la suma es 0 (tampoco suma 1).

Conclusión: Es matemáticamente imposible construir una distribución de probabilidad estacionaria para esta cadena. Por el Teorema Fundamental (inciso b), concluimos que esta cadena es **irreducible recurrente nula**. □

2.2. Cadena de nacimiento y muerte discreta

Ejercicio 2.4. Cadena de nacimiento-muerte discreta

Sea (X_n) en $\mathbb{N}_0$: $p(x, x+1) = p_x$, $p(x, x-1) = q_x = 1 - p_x$ para $x \geq 1$, y reflexión $p(0,1) = 1$.
(a) Demuestre que toda medida estacionaria satisface el *balance detallado* $\pi(x)p(x, x+1) = \pi(x+1)q_{x+1}$, y obtenga $\pi(x) = \pi(0) \prod_{k=0}^{x-1} \frac{p_k}{q_{k+1}}$.

Balance Global vs. Balance Detallado

- **Balance Global:** $\pi(y) = \sum_x \pi(x)p(x,y)$. Todo lo que entra a y desde cualquier parte, iguala a todo lo que sale de y.
- **Balance Detallado:** $\pi(x)p(x,y) = \pi(y)p(y,x)$. El flujo que va específicamente de x a y es exactamente igual al flujo que regresa de y a x. Si una medida cumple esto, la cadena es *reversible*.

Demostración por Inducción. Para encontrar la medida estacionaria π, partimos de las ecuaciones de balance global $\pi P = \pi$. Evaluamos nodo por nodo:

1. Caso base (Nodo $y = 0$):
A la posición 0 solo se puede llegar desde la posición 1 (dando un paso hacia atrás con probabilidad q_1). Por lo tanto, la ecuación de balance global es:

$$\pi(0) = \pi(1)p(1,0) = \pi(1)q_1$$

Como por definición $p(0,1) = 1$, podemos multiplicar el lado izquierdo por 1 sin alterarlo:

$$\pi(0)p(0,1) = \pi(1)q_1$$

(¡Este es exactamente el balance detallado para $x = 0$! Definiremos $p_0 = 1$ para mantener la notación).

2. Siguiente nodo (Nodo $y = 1$):
Al nodo 1 se puede llegar desde el 0 (avanzando) o desde el 2 (retrocediendo). La ecuación global es:

$$\pi(1) = \pi(0)p(0,1) + \pi(2)p(2,1)$$

Sustituyendo $p(0,1) = p_0$ y $p(2,1) = q_2$:

$$\pi(1) = \pi(0)p_0 + \pi(2)q_2$$

Del paso anterior, sabemos que $\pi(0)p_0 = \pi(1)q_1$. Sustituimos esto en la ecuación:

$$\pi(1) = \pi(1)q_1 + \pi(2)q_2$$

Pasamos $\pi(1)q_1$ restando al lado izquierdo y factorizamos $\pi(1)$:

$$\pi(1)(1 - q_1) = \pi(2)q_2$$

Como $p_1 + q_1 = 1$, sabemos que $1 - q_1 = p_1$. Sustituyendo:

$$\pi(1)p_1 = \pi(2)q_2$$

(¡Queda demostrado el balance detallado para $x = 1$!)

3. Paso Inductivo (Para un nodo x genérico):
Supongamos que el balance detallado se cumple para el nodo anterior, es decir, $\pi(x-1)p_{x-1} = \pi(x)q_x$. Planteamos el balance global para el estado x:

$$\pi(x) = \pi(x-1)p_{x-1} + \pi(x+1)q_{x+1}$$

Aplicamos nuestra hipótesis de inducción sustituyendo el primer término:

$$\pi(x) = \pi(x)q_x + \pi(x+1)q_{x+1}$$

Agrupamos los términos con $\pi(x)$:

$$\pi(x)(1 - q_x) = \pi(x+1)q_{x+1}$$

Como $1 - q_x = p_x$, concluimos:

$$\boldsymbol{\pi(\mathbf{x})\mathbf{p_x} = \pi(\mathbf{x}+\mathbf{1})\mathbf{q_{x+1}}}$$

Queda demostrado que toda medida estacionaria en esta cadena cumple el balance detallado.

4. Obtención de la Fórmula de Productoria:

A partir de la ecuación de balance detallado, despejamos $\pi(x+1)$:

$$\pi(x+1) = \pi(x)\frac{p_x}{q_{x+1}}$$

Si "desenrollamos.esta relación recursiva desde x hasta 0, obtenemos:

$$\begin{aligned}
\pi(1) &= \pi(0)\frac{p_0}{q_1} \\
\pi(2) &= \pi(1)\frac{p_1}{q_2} = \pi(0)\frac{p_0}{q_1}\frac{p_1}{q_2} \\
\pi(3) &= \pi(2)\frac{p_2}{q_3} = \pi(0)\frac{p_0}{q_1}\frac{p_1}{q_2}\frac{p_2}{q_3} \\
&\vdots \\
\pi(x) &= \pi(0)\left(\frac{p_0}{q_1}\right)\left(\frac{p_1}{q_2}\right)\cdots\left(\frac{p_{x-1}}{q_x}\right)
\end{aligned}$$

Escrito de forma compacta usando la notación de productoria ($\prod$):

$$\boldsymbol{\pi(\mathbf{x}) = \pi(\mathbf{0})\prod_{\mathbf{k=0}}^{\mathbf{x-1}}\frac{\mathbf{p_k}}{\mathbf{q_{k+1}}}}$$

(Asumiendo $p_0 = p(0,1) = 1$). Queda obtenida la fórmula deseada. $\square$

Ejercicio 2.5. Condición de Probabilidad Estacionaria

Dé la condición sobre $\sum_x \pi(x)$ para que exista probabilidad estacionaria.

Normalización de la Medida

Como demostramos teóricamente en el Teorema de Kac, una medida estacionaria $\pi(x)$ se convierte en una **distribución de probabilidad** válida si y solo si podemos normalizarla. Esto exige estrictamente que la suma de todos sus términos sobre el espacio de estados sea finita.

Determinación de la Condición. Para que π sea una distribución de probabilidad, debe cumplir el axioma fundamental de Kolmogorov:

$$\sum_{x=0}^{\infty} \pi(x) = 1$$

Sustituimos la fórmula de la medida estacionaria obtenida mediante balance detallado en el inciso (a):

$$\sum_{x=0}^{\infty} \left(\pi(0) \prod_{k=0}^{x-1} \frac{p_k}{q_{k+1}} \right) = 1$$

Dado que $\pi(0)$ es una constante que no depende del índice x, la podemos factorizar fuera de la sumatoria. Recordando que para el término $x = 0$ el producto vacío se define como 1, separamos ese primer término:

$$\pi(0) \left[1 + \sum_{x=1}^{\infty} \prod_{k=0}^{x-1} \frac{p_k}{q_{k+1}} \right] = 1$$

Despejamos el valor base $\pi(0)$ pasándolo a dividir:

$$\pi(0) = \frac{1}{1 + \sum_{x=1}^{\infty} \prod_{k=0}^{x-1} \frac{p_k}{q_{k+1}}}$$

Para que la probabilidad inicial $\pi(0)$ sea un valor real válido, estrictamente mayor que cero (lo cual garantiza que la cadena completa sea recurrente positiva y la distribución exista), el denominador **no puede ser infinito**.

Conclusión: La condición necesaria y suficiente es que la serie de productos converja a un valor finito. Escrito formalmente:

$$\boldsymbol{\sum_{x=1}^{\infty} \prod_{k=0}^{x-1} \frac{p_k}{q_{k+1}} < \infty}$$

□

Ejercicio 2.6. Distribución Geométrica en Equilibrio

Tome $p_x = p < q$ constantes. Calcule π y muestre que es geométrica de parámetro p/q.

Cálculo de la Distribución. Partimos de la fórmula general obtenida en el inciso (a):

$$\pi(x) = \pi(0) \prod_{k=0}^{x-1} \frac{p_k}{q_{k+1}}$$

El problema nos indica que $p_x = p$ y $q_x = q$ (donde $p < q$) para los estados regulares $x \geq 1$. Recordando la condición de frontera en el origen, $p(0,1) = 1$, por lo que $p_0 = 1$.

Para cualquier $x \geq 1$, el producto se desarrolla así:

$$\pi(x) = \pi(0) \left(\frac{p_0}{q_1}\right) \left(\frac{p_1}{q_2}\right) \cdots \left(\frac{p_{x-1}}{q_x}\right)$$

Sustituyendo los valores constantes:

$$\pi(x) = \pi(0) \left(\frac{1}{q}\right) \left(\frac{p}{q}\right) \cdots \left(\frac{p}{q}\right)$$

Dado que hay x fracciones en total, y la primera es distinta, agrupamos las $x-1$ fracciones restantes:

$$\pi(x) = \pi(0) \frac{1}{q} \left(\frac{p}{q}\right)^{x-1}$$

Para darle la forma canónica de una progresión geométrica dependiente de $(p/q)^x$, multiplicamos y dividimos por p:

$$\pi(x) = \pi(0) \frac{1}{q} \frac{q}{p} \left(\frac{p}{q}\right)^{x} = \frac{\pi(0)}{p} \left(\frac{p}{q}\right)^{x}$$

Conclusión del inciso (c): Dado que la probabilidad de estar en el estado x es directamente proporcional a la potencia $(p/q)^x$, la medida estacionaria tiene la forma exacta de una **distribución geométrica** modificada en el origen, con razón (o parámetro) $r = p/q$. Como $p < q$, la razón $r < 1$, lo que garantiza que la serie converge y la distribución existe. □

Ejercicio 2.7. Reversibilidad en el Tiempo

Demuestre que la cadena es reversible: en equilibrio, $(X_0, \ldots, X_n)$ y $(X_n, \ldots, X_0)$ tienen la misma distribución.

El Concepto de Reversibilidad

Un proceso estocástico es *reversible* si, al grabar su comportamiento en video y reproducirlo en reversa, las probabilidades de observar esa secuencia de eventos son matemáticamente indistinguibles de reproducirlo hacia adelante. Esto es una consecuencia directa de cumplir el Balance Detallado en equilibrio.

Demostración Analítica de Reversibilidad. Queremos demostrar que la probabilidad de observar una trayectoria hacia adelante en estado estacionario es igual a la probabilidad de observarla hacia atrás:

$$\mathbb{P}_\pi(X_0 = x_0, X_1 = x_1, \ldots, X_n = x_n) = \mathbb{P}_\pi(X_0 = x_n, X_1 = x_{n-1}, \ldots, X_n = x_0)$$

Desarrollamos el lado izquierdo utilizando la definición de probabilidad conjunta para una Cadena de Markov (probabilidad inicial por las probabilidades de transición):

$$\text{Lado Izquierdo} = \pi(x_0)p(x_0, x_1)p(x_1, x_2) \ldots p(x_{n-1}, x_n)$$

Ahora, aplicamos la ecuación de **balance detallado** (demostrada en el inciso a), la cual nos dice que $\pi(x)p(x,y) = \pi(y)p(y,x)$. Aplicamos esto al **primer par** de términos de nuestra cadena:

$$[\pi(x_0)p(x_0,x_1)] = \pi(x_1)p(x_1,x_0)$$

Sustituyendo en la trayectoria original:

$$= \pi(x_1)p(x_1,x_0)p(x_1,x_2)p(x_2,x_3)\dots p(x_{n-1},x_n)$$

Reordenamos para agrupar $\pi(x_1)$ con el siguiente salto hacia la derecha:

$$= p(x_1,x_0)[\pi(x_1)p(x_1,x_2)]p(x_2,x_3)\dots p(x_{n-1},x_n)$$

Aplicamos de nuevo el balance detallado al nuevo corchete $[\pi(x_1)p(x_1,x_2)] = \pi(x_2)p(x_2,x_1)$:

$$= p(x_1,x_0)\pi(x_2)p(x_2,x_1)p(x_2,x_3)\dots p(x_{n-1},x_n)$$

Continuamos este proceso iterativo, .^em^pujando"la distribución π hacia la derecha y "volteandoçada probabilidad de transición $p(x_i,x_{i+1})$ a $p(x_{i+1},x_i)$. Al llegar al final de la cadena, obtenemos:

$$= p(x_1,x_0)p(x_2,x_1)\dots p(x_n,x_{n-1})\pi(x_n)$$

Reordenando los términos algebraicamente (poniendo $\pi(x_n)$ al principio y leyendo los saltos de derecha a izquierda), tenemos:

$$= \pi(x_n)p(x_n,x_{n-1})p(x_{n-1},x_{n-2})\dots p(x_1,x_0)$$

¡Y esta es exactamente la definición por propiedad de Markov de la trayectoria leída en reversa!

$$= \mathbb{P}_\pi(X_0 = x_n, X_1 = x_{n-1}, \dots, X_n = x_0)$$

Queda formalmente demostrado que, en equilibrio, la cadena es reversible. □

2.3. Convergencia al equilibrio

Ejercicio 2.8. Convergencia al equilibrio y Brecha Espectral

Sea (X_n) irreducible y aperiódica en S finito, con probabilidad estacionaria π.
(a) Defina la distancia en variación total $||\mu-\nu|| = \frac{1}{2}\sum_x |\mu(x)-\nu(x)|$ y demuestre que $||p^n(x,\cdot)-\pi|| \leq C|\lambda_2|^n$, donde λ_2 es el segundo valor propio más grande en valor absoluto de p.

Descomposición Espectral y la Brecha

Si asumimos que la matriz de transición P es diagonalizable (lo cual es estándar para cadenas reversibles), podemos escribirla en función de sus valores propios λ_k y sus vectores propios (izquierdos y derechos). Ordenamos los valores propios por su magnitud: $1 = \lambda_1 > |\lambda_2| \geq |\lambda_3| \cdots \geq |\lambda_{|S|}|$. El término correspondiente a $\lambda_1 = 1$ representa el estado estacionario π. Los demás términos representan transitorios que decaen a cero.

Demostración de la Cota de Convergencia. **1. Expansión de la matriz de transición P^n:**
Mediante la descomposición espectral, la probabilidad de transición en n pasos desde x hasta y se puede expresar como una combinación lineal de las potencias de sus eigenvalores:

$$p^n(x,y) = \sum_{k=1}^{|S|} \lambda_k^n U_{xk} U_{ky}^{-1}$$

2. Separación del término estacionario:
Sabemos que el eigenvalor principal es $\lambda_1 = 1$, y su término asociado en la descomposición corresponde exactamente a la distribución estacionaria $\pi(y)$ (independiente del estado inicial x). Separamos este término de la sumatoria:

$$p^n(x,y) = \pi(y) + \sum_{k=2}^{|S|} \lambda_k^n U_{xk} U_{ky}^{-1}$$

Pasamos $\pi(y)$ restando para encontrar la diferencia (el .^{er}ror.^{o} la distancia hacia el equilibrio):

$$p^n(x,y) - \pi(y) = \sum_{k=2}^{|S|} \lambda_k^n U_{xk} U_{ky}^{-1}$$

3. Aplicación de la Distancia en Variación Total:
Sustituimos esta diferencia en la definición de distancia en variación total proporcionada por el problema:

$$||p^n(x,\cdot) - \pi|| = \frac{1}{2}\sum_{y\in S} |p^n(x,y) - \pi(y)|$$

$$= \frac{1}{2}\sum_{y\in S} \left| \sum_{k=2}^{|S|} \lambda_k^n U_{xk} U_{ky}^{-1} \right|$$

4. Acotación mediante Desigualdad del Triángulo:
El valor absoluto de una suma es menor o igual a la suma de los valores absolutos:

$$||p^n(x,\cdot) - \pi|| \leq \frac{1}{2}\sum_{y\in S}\sum_{k=2}^{|S|} |\lambda_k|^n |U_{xk} U_{ky}^{-1}|$$

5. Extracción de λ_2:
Por definición, λ_2 es el segundo eigenvalor más grande en valor absoluto. Esto significa que para cualquier

$k \geq 2$, se cumple que $|\lambda_k| \leq |\lambda_2|$. Por lo tanto, podemos sustituir todos los $|\lambda_k|^n$ por la cota superior $|\lambda_2|^n$ y factorizarlo fuera de la sumatoria:

$$||p^n(x,\cdot) - \pi|| \leq |\lambda_2|^n \left(\frac{1}{2} \sum_{y \in S} \sum_{k=2}^{|S|} |U_{xk} U_{ky}^{-1}| \right)$$

6. Conclusión:
Todo el término encerrado en el paréntesis depende únicamente de los eigenvectores de la matriz y del estado inicial x, pero **no depende del tiempo** n. Lo podemos agrupar en una constante positiva C:

$$C = \frac{1}{2} \sum_{y \in S} \sum_{k=2}^{|S|} |U_{xk} U_{ky}^{-1}|$$

Sustituyendo esta constante, obtenemos el resultado final:

$$\mathbf{||p^n(x,\cdot) - \pi|| \leq C|\lambda_2|^n}$$

Queda demostrado que la velocidad a la que la cadena converge a su distribución estacionaria está dominada exponencialmente por el segundo eigenvalor. □

Ejercicio 2.9. Desigualdad de Acoplamiento (Coupling)

Enuncie y use la desigualdad de acoplamiento: si $\tau_c = \text{mín}\{n : X_n = X'_n\}$ para dos copias de la cadena, entonces $||p^n(x,\cdot) - \pi|| \leq P(\tau_c > n)$.

Construcción del Acoplamiento

Definimos dos Cadenas de Markov (X_n) y (X'_n) que se mueven en el mismo espacio S con la misma matriz de transición P:

- La cadena original arranca en el estado x: $X_0 = x$. Por tanto, su distribución en el tiempo n es $P(X_n = y) = p^n(x,y)$.
- La copia arranca ya en la distribución estacionaria: $X'_0 \sim \pi$. Por definición de invarianza, su distribución en cualquier tiempo n sigue siendo π: $P(X'_n = y) = \pi(y)$.

Las cadenas se mueven hasta el tiempo de encuentro τ_c. Una vez que se encuentran $(X_{\tau_c} = X'_{\tau_c})$, se acoplan y se mueven idénticamente juntas para todo $n \geq \tau_c$.

Demostración de la Desigualdad. Recordemos una definición equivalente y muy útil de la distancia en variación total usando conjuntos de estados (eventos $A \subset S$):

$$||p^n(x,\cdot) - \pi|| = \max_{A \subset S} |P(X_n \in A) - P(X'_n \in A)|$$

Para cualquier evento A, podemos dividir la probabilidad usando la Ley de Probabilidad Total, condicionando a si las cadenas ya se acoplaron $(\tau_c \leq n)$ o no $(\tau_c > n)$:

$$P(X_n \in A) = P(X_n \in A, \tau_c \leq n) + P(X_n \in A, \tau_c > n)$$
$$P(X'_n \in A) = P(X'_n \in A, \tau_c \leq n) + P(X'_n \in A, \tau_c > n)$$

Por la regla de construcción de nuestro acoplamiento, si $\tau_c \leq n$, entonces las dos cadenas están pegadas y son idénticas en el tiempo n $(X_n = X'_n)$. Esto implica que las probabilidades conjuntas del primer término son exactamente iguales:

$$P(X_n \in A, \tau_c \leq n) = P(X'_n \in A, \tau_c \leq n)$$

Ahora, restamos las probabilidades para encontrar la distancia:

$$P(X_n \in A) - P(X'_n \in A) = P(X_n \in A, \tau_c > n) - P(X'_n \in A, \tau_c > n)$$

Tomamos el valor absoluto en ambos lados. Dado que ambos términos de la derecha son probabilidades (valores entre 0 y 1) y ambos están contenidos en el evento $\{\tau_c > n\}$, la diferencia máxima posible entre ellos no puede exceder el tamaño total de ese evento:

$$|P(X_n \in A) - P(X'_n \in A)| \leq P(\tau_c > n)$$

Como esta desigualdad se cumple para cualquier evento A, también se cumple para el evento máximo que define la distancia en variación total:

$$\max_{A \subset S} |P(X_n \in A) - P(X'_n \in A)| \leq P(\tau_c > n)$$

Sustituyendo la definición de variación total, llegamos a la demostración final:

$$||\mathbf{p^n}(\mathbf{x},\cdot) - \pi|| \leq \mathbf{P}(\tau_\mathbf{c} > \mathbf{n})$$

Conclusión: El error respecto al equilibrio está acotado por la probabilidad de que las dos cadenas aún no se hayan cruzado. □

Ejercicio 2.10. Tiempo de mezcla en el Ciclo $\mathbb{Z}_N$

Para el ciclo $\mathbb{Z}_N$, calcule los valores propios de p y deduzca $t_{\text{mix}}(1/4) = \Theta(N^2)$.

Brecha Espectral y Tiempo de Relajación

El tiempo de relajación de una cadena se define como $t_{\text{rel}} = \frac{1}{1-|\lambda_2|}$, donde λ_2 es el segundo eigenvalor más grande en magnitud. Existe un teorema fundamental que acota el tiempo de mezcla utilizando este valor:

$$(t_{\text{rel}} - 1)\ln\left(\frac{1}{2\epsilon}\right) \leq t_{\text{mix}}(\epsilon) \leq t_{\text{rel}} \ln\left(\frac{1}{\epsilon\pi_{\text{mín}}}\right)$$

Cálculo para el Ciclo $\mathbb{Z}_N$. **1. Valores Propios:**
La matriz de transición P para la caminata aleatoria simple en $\mathbb{Z}_N$ es una matriz circulante donde $P_{x,x+1} = 1/2$ y $P_{x,x-1} = 1/2$. Por teoría de matrices circulantes, sus valores propios conocidos son:

$$\lambda_k = \cos\left(\frac{2\pi k}{N}\right) \quad \text{para } k = 0, 1, \ldots, N-1$$

El valor propio principal es $\lambda_0 = \cos(0) = 1$. El segundo valor propio más grande corresponde a $k = 1$:

$$\lambda_2 = \cos\left(\frac{2\pi}{N}\right)$$

2. Expansión de Taylor y Brecha Espectral:
Para N grande, utilizamos la expansión de Taylor del coseno ($\cos(x) \approx 1 - x^2/2$):

$$\lambda_2 \approx 1 - \frac{1}{2}\left(\frac{2\pi}{N}\right)^2 = 1 - \frac{2\pi^2}{N^2}$$

La brecha espectral es $\gamma = 1 - \lambda_2 \approx \frac{2\pi^2}{N^2}$.
Por lo tanto, el tiempo de relajación es inversamente proporcional:

$$t_{\text{rel}} = \frac{1}{\gamma} \approx \frac{N^2}{2\pi^2} = \Theta(N^2)$$

3. Deducción del Tiempo de Mezcla:
Utilizando la cota inferior del teorema del tiempo de mezcla con $\epsilon = 1/4$:

$$t_{\text{mix}}(1/4) \geq (t_{\text{rel}} - 1)\ln(2) = \Omega(N^2)$$

Dado que la difusión en $\mathbb{Z}_N$ está gobernada por el comportamiento gaussiano (Teorema del Límite Central), se sabe que el límite superior empata asintóticamente con el inferior. Por lo tanto, el tiempo exacto de convergencia es proporcional a N^2:

$$\mathbf{t_{\text{mix}}(1/4) = \Theta(N^2)}$$

□

Ejercicio 2.11. Tiempo de mezcla en la Gráfica Completa K_N

Para la gráfica completa K_N, muestre que $t_{\text{mix}}(1/4) = O(\log N)$.

Cálculo para la Gráfica Completa K_N. **1. Valores Propios de K_N:**
En la gráfica completa, la transición desde cualquier estado x a cualquier otro estado $y \neq x$ es uniforme. La matriz de transición es $P = \frac{1}{N-1}(J - I)$, donde J es la matriz de puros unos e I es la matriz identidad.

Sabemos que los eigenvalores de J son N (con multiplicidad 1) y 0 (con multiplicidad $N-1$). Al aplicar la transformación lineal de la ecuación de P, los eigenvalores de P son:

- Para $\lambda(J) = N \implies \lambda_1 = \frac{N-1}{N-1} = 1$ (El estado estacionario).
- Para $\lambda(J) = 0 \implies \lambda_k = \frac{0-1}{N-1} = -\frac{1}{N-1}$ (Para el resto de los $N-1$ eigenvectores).

2. Tiempo de Relajación:
El segundo valor propio en valor absoluto es $|\lambda_2| = \frac{1}{N-1}$. El tiempo de relajación es:

$$t_{\text{rel}} = \frac{1}{1-|\lambda_2|} = \frac{1}{1-\frac{1}{N-1}} = \frac{N-1}{N-2}$$

Para $N \geq 3$, el tiempo de relajación está acotado por una constante: $t_{\text{rel}} = O(1)$. La gráfica mezcla su información casi instantáneamente.

3. Cota Superior del Tiempo de Mezcla:
Por la simetría de la gráfica completa, la distribución estacionaria es uniforme para todos los estados: $\pi_{\text{mín}} = \pi(x) = \frac{1}{N}$.
Aplicamos la cota superior universal del tiempo de mezcla con $\epsilon = 1/4$:

$$t_{\text{mix}}(1/4) \leq t_{\text{rel}} \ln\left(\frac{1}{\epsilon \pi_{\text{mín}}}\right)$$

Sustituyendo nuestros valores:

$$t_{\text{mix}}(1/4) \leq \left(\frac{N-1}{N-2}\right) \ln\left(\frac{1}{(1/4)(1/N)}\right)$$

$$t_{\text{mix}}(1/4) \leq \left(\frac{N-1}{N-2}\right) \ln(4N)$$

Dado que el coeficiente fraccionario tiende a 1 conforme N crece, la función está dominada puramente por el logaritmo de N:

$$\mathbf{t_{\text{mix}}(1/4) = O(\log N)}$$

Queda demostrado analíticamente. □

2.4. Caminata aleatoria en Z^d

Ejercicio 2.12. Distancia Esperada en Caminatas Multidimensionales

Sea (X_n) la caminata aleatoria simple en $\mathbb{Z}^d$: $p(x,y) = 1/(2d)$ si $|x-y| = 1$.
(a) Calcule $E^0[||X_n||^2] = n$ para todo n y todo d.

Descomposición en Variables Independientes

La posición de la partícula en el tiempo n, denotada como X_n, puede verse como la suma acumulada de n saltos individuales. Definimos Y_k como el vector de desplazamiento en el paso k. Así, $X_n = \sum_{k=1}^{n} Y_k$.
Propiedades clave de los incrementos Y_k:

1. **Longitud unitaria:** Cada salto se mueve exactamente 1 unidad a lo largo de uno de los ejes coordenados. Por lo tanto, el producto punto de un salto consigo mismo es la magnitud al cuadrado: $\langle Y_k, Y_k \rangle = ||Y_k||^2 = 1$.
2. **Simetría (Media cero):** Dado que es igual de probable moverse en dirección positiva o negativa sobre cualquier eje, el vector esperado de cada salto es el vector nulo: $E[Y_k] = \mathbf{0}$.
3. **Independencia:** El vector Y_i es estadísticamente independiente del vector Y_j para todo $i \neq j$.

Cálculo de la Esperanza de la Norma al Cuadrado. Queremos calcular el valor esperado de la norma euclidiana al cuadrado de la posición final X_n, asumiendo que arrancamos en el origen ($X_0 = \mathbf{0}$).

1. Expresar la norma al cuadrado como un producto punto: Por definición, la magnitud al cuadrado de un vector es el producto punto consigo mismo:

$$||X_n||^2 = \langle X_n, X_n \rangle$$

2. Sustituir la suma de incrementos: Sustituimos X_n por la suma de sus saltos individuales Y_k:

$$||X_n||^2 = \left\langle \sum_{i=1}^{n} Y_i, \sum_{j=1}^{n} Y_j \right\rangle$$

3. Expandir el producto punto: Por la propiedad distributiva (bilinealidad) del producto punto, podemos expandir este producto de sumas en una doble sumatoria:

$$||X_n||^2 = \sum_{i=1}^{n} \sum_{j=1}^{n} \langle Y_i, Y_j \rangle$$

Para facilitar el análisis, separamos esta doble suma en dos partes: los términos donde $i = j$ (la diagonal) y los términos donde $i \neq j$ (los cruzados):

$$||X_n||^2 = \sum_{i=1}^{n} \langle Y_i, Y_i \rangle + \sum_{i \neq j} \langle Y_i, Y_j \rangle$$

4. Aplicar la Esperanza Matemática: Tomamos el valor esperado en ambos lados de la ecuación. Por la linealidad de la esperanza, podemos meter el operador $E[\cdot]$ dentro de las sumatorias:

$$E^0[||X_n||^2] = \sum_{i=1}^{n} E[\langle Y_i, Y_i \rangle] + \sum_{i \neq j} E[\langle Y_i, Y_j \rangle]$$

5. Evaluar cada término:

- **Términos diagonales ($i = j$):** Sabemos que $\langle Y_i, Y_i \rangle = ||Y_i||^2 = 1$. Por lo tanto, el valor esperado de una constante es la constante misma: $E[1] = 1$. Como hay exactamente n de estos términos en la primera sumatoria:

$$\sum_{i=1}^{n} 1 = n$$

- **Términos cruzados ($i \neq j$):** Como los saltos Y_i y Y_j son independientes, la esperanza de su producto es el producto de sus esperanzas:

$$E[\langle Y_i, Y_j \rangle] = \langle E[Y_i], E[Y_j] \rangle$$

  Dado que la caminata es simétrica, la esperanza de cualquier salto individual es el vector cero ($E[Y_i] = \mathbf{0}$).

$$\langle \mathbf{0}, \mathbf{0} \rangle = 0$$

  Por lo tanto, todos los términos cruzados se anulan y suman 0.

6. Conclusión: Sumando ambas partes, llegamos al resultado final:

$$\mathbf{E^0[||X_n||^2] = n + 0 = n}$$

Queda demostrado que el valor esperado de la distancia al cuadrado desde el origen es exactamente el número de pasos, sin importar la dimensión d del espacio en el que ocurra la caminata. □

Ejercicio 2.13. Teorema de Pólya

Muestre que $\sum_n p^n(0,0) = \infty$ para $d \leq 2$ (recurrencia) y $\sum_n p^n(0,0) < \infty$ para $d \geq 3$ (transencia), usando la estimación $p^{2n}(0,0) \asymp n^{-d/2}$.

El Criterio de la Serie-p

Sabemos que la caminata aleatoria en $\mathbb{Z}^d$ es bipartita, lo que significa que solo podemos regresar al origen en un número par de pasos ($2n$). Por lo tanto, el número esperado de visitas al origen es la suma de las probabilidades en los pasos pares. Usaremos el criterio de convergencia de las *series-p* del cálculo: la serie $\sum_{n=1}^{\infty} \frac{1}{n^p}$ converge si $p > 1$ y diverge si $p \leq 1$.

Demostración Asintótica. El número esperado de retornos al origen está dado por la suma de las probabilidades de transición:

$$G(0,0) = \sum_{n=0}^{\infty} p^n(0,0) = \sum_{n=0}^{\infty} p^{2n}(0,0)$$

Usando la estimación asintótica proporcionada, sabemos que para n grande, el comportamiento de la probabilidad es proporcional a $n^{-d/2}$:

$$p^{2n}(0,0) \approx C \cdot \frac{1}{n^{d/2}}$$

Analizamos la convergencia de la serie $\sum \frac{1}{n^{d/2}}$ dependiendo de la dimensión d:

- **Para $d = 1$:** La serie se comporta como $\sum \frac{1}{n^{1/2}}$. Como $1/2 \leq 1$, la serie **diverge** a ∞.
- **Para $d = 2$:** La serie se comporta como $\sum \frac{1}{n^1}$ (la serie armónica). Como $1 \leq 1$, la serie **diverge** a ∞.
- **Para $d \geq 3$:** La serie se comporta como $\sum \frac{1}{n^{d/2}}$. Como $d \geq 3$, el exponente $d/2 \geq 1{,}5 > 1$. Por el criterio de la serie-p, la serie **converge** a un valor finito.

Conclusión: Si la suma de probabilidades diverge ($d \leq 2$), la partícula regresa infinitas veces, por lo que es **recurrente**. Si la suma converge ($d \geq 3$), la partícula regresa un número finito de veces en promedio, por lo que existe riesgo de escape y es **transitoria**. □

Ejercicio 2.14. Representación Integral de Green

Para $d \geq 3$, exprese $G(0,0) = \sum_n p^n(0,0)$ como la integral

$$G(0,0) = (2\pi)^{-d} \int_{[-\pi,\pi]^d} \frac{d\theta}{1 - \frac{1}{d}\sum_{j=1}^{d} \cos\theta_j}$$

y argumente que converge.

Derivación mediante Análisis de Fourier. **1. Función Característica del Salto:** La función característica (transformada de Fourier) de un solo paso de la caminata en $\mathbb{Z}^d$ es el promedio de los exponentes complejos de los posibles saltos. Como hay $2d$ direcciones (positivas y negativas para cada eje), agrupamos por pares de Euler ($e^{i\theta} + e^{-i\theta} = 2\cos\theta$):

$$\phi(\theta) = \frac{1}{2d}\sum_{j=1}^{d}\left(e^{i\theta_j} + e^{-i\theta_j}\right) = \frac{1}{d}\sum_{j=1}^{d}\cos(\theta_j)$$

2. Transformada Inversa para n pasos: Por las propiedades de la transformada de Fourier para sumas de variables independientes, la función característica de n pasos es $\phi(\theta)^n$. La probabilidad de estar en el origen en el paso n se recupera evaluando la transformada inversa de Fourier en $x = 0$:

$$p^n(0,0) = \frac{1}{(2\pi)^d}\int_{[-\pi,\pi]^d} \phi(\theta)^n d\theta$$

3. Intercambio de Suma e Integral: Sustituimos esto en la definición de $G(0,0)$:

$$G(0,0) = \sum_{n=0}^{\infty} \frac{1}{(2\pi)^d}\int_{[-\pi,\pi]^d} \phi(\theta)^n d\theta$$

Por el Teorema de Convergencia Monótona, intercambiamos la serie y la integral. Dentro de la integral nos queda una serie geométrica $\sum_{n=0}^{\infty}\phi(\theta)^n$. Como $|\phi(\theta)| < 1$ en casi todas partes, la serie geométrica converge a $\frac{1}{1-\phi(\theta)}$:

$$G(0,0) = \frac{1}{(2\pi)^d}\int_{[-\pi,\pi]^d} \frac{1}{1-\phi(\theta)} d\theta$$

Sustituyendo nuestra $\phi(\theta)$, obtenemos la expresión solicitada:

$$\mathbf{G(0,0) = (2\pi)^{-d} \int_{[-\pi,\pi]^d} \frac{d\theta}{1 - \frac{1}{d}\sum_{j=1}^{d}\cos\theta_j}}$$

4.Convergencia local: El único punto donde el denominador se hace cero (singularidad) es en el origen $\theta = \mathbf{0}$. Cerca de 0, la expansión de Taylor nos da $1 - \cos(\theta_j) \approx \theta_j^2/2$. Así, el integrando cerca de cero se comporta proporcionalmente a $1/||\theta||^2$. Pasando a coordenadas esféricas en d dimensiones, el elemento de volumen aporta un término $r^{d-1}dr$. La integral local es proporcional a $\int \frac{r^{d-1}}{r^2}dr = \int r^{d-3}dr$. Esta integral en el origen converge sí y solo sí $d - 3 > -1 \implies d > 2$. Por lo tanto, para $d \geq 3$, **la singularidad es integrable y la integral completa converge**. □

Ejercicio 2.15. Cálculo Numérico de la Probabilidad de Retorno en 3D

Para $d = 3$, estime numéricamente $G(0,0) \approx 1{,}516$ y calcule la probabilidad de retorno al origen.

Esperanza vs. Probabilidad

Sea f la probabilidad de regresar al origen al menos una vez. El número de retornos sigue una distribución geométrica. El número esperado de visitas al origen, contando la visita inicial en $t = 0$, está dado por la fórmula clásica:

$$G(0,0) = \sum_{k=0}^{\infty} f^k = \frac{1}{1-f}$$

A partir de esta relación, si conocemos la esperanza (la integral de Green), podemos despejar la probabilidad exacta de retorno.

Cálculo de la Probabilidad de Retorno. Utilizando la fórmula de la nota anterior, despejamos la probabilidad de retorno al origen, denotada como f:

$$G(0,0) = \frac{1}{1-f}$$

$$1 - f = \frac{1}{G(0,0)}$$

$$f = 1 - \frac{1}{G(0,0)}$$

El problema nos proporciona la estimación numérica de la integral tridimensional de Watson : $G(0,0) \approx 1{,}516$. Sustituimos este valor en nuestra ecuación:

$$f \approx 1 - \frac{1}{1{,}516}$$

$$f \approx 1 - 0{,}6596$$

$$\mathbf{f \approx 0{,}3404}$$

Conclusión: En una caminata aleatoria tridimensional, la probabilidad de que una partícula eventualmente regrese al punto de partida es de aproximadamente el **34.04 %**. Como la probabilidad es estrictamente menor a 1, la cadena es oficialmente transitoria. Existe un $\approx 65{,}96\,\%$ de probabilidad de que la partícula se pierda en el espacio para siempre sin volver a pisar el origen. □

2.5. Caminata aleatoria en grafos finitos.

Ejercicio 2.16. Caminata Aleatoria en Gráficas d-Regulares

Sea $G = (V, E_G)$ una gráfica d-regular conexa con N vértices, y (X_n) la caminata simple: $p(x, y) = 1/d$ si $\{x, y\} \in E_G$.
(a) Muestre que $\pi(x) = 1/N$ es la única probabilidad estacionaria y que la cadena es reversible.

Intuición Geométrica

Una gráfica d-regular es aquella donde todos los vértices tienen exactamente el mismo número de vecinos (d). Como el "paisaje local.^{es} idéntico desde cualquier vértice y la gráfica está conectada, la caminata no es atraída hacia ninguna región en particular. Es natural que, en equilibrio, la probabilidad de visitar cualquier vértice sea perfectamente uniforme ($\pi(x) = 1/N$).

Demostración de Reversibilidad, Estacionariedad y Unicidad. **1. Demostración de Reversibilidad (Balance Detallado):**
Para que una cadena sea reversible respecto a una medida π, debe satisfacer la ecuación de balance detallado para todo par de estados $x, y \in V$:

$$\pi(x)p(x, y) = \pi(y)p(y, x)$$

Evaluamos esta condición proponiendo la distribución uniforme $\pi(x) = 1/N$:

- **Caso 1: x e y son vecinos ($\{x, y\} \in E_G$).**
  Por definición de la caminata simple en la gráfica d-regular, la probabilidad de ir a un vecino específico es $p(x, y) = 1/d$ y el retorno es $p(y, x) = 1/d$. Sustituyendo en la ecuación de balance detallado:
  $$\left(\frac{1}{N}\right)\left(\frac{1}{d}\right) = \left(\frac{1}{N}\right)\left(\frac{1}{d}\right) \implies \frac{1}{Nd} = \frac{1}{Nd}$$
  La igualdad se cumple de forma trivial.

- **Caso 2: x e y no son vecinos ($\{x, y\} \notin E_G$).**
  La probabilidad de saltar directamente entre ellos en un solo paso es nula: $p(x, y) = 0$ y $p(y, x) = 0$.
  $$\left(\frac{1}{N}\right)(0) = \left(\frac{1}{N}\right)(0) \implies 0 = 0$$
  La igualdad también se cumple.

Conclusión: Como la cadena cumple el balance detallado para todo par de nodos, es **reversible** respecto a $\pi(x) = 1/N$.

2. Demostración de Estacionariedad:
Es un resultado conocido (Teorema) que si una medida π cumple el balance detallado, automáticamente cumple las ecuaciones de balance global ($\pi P = \pi$), por lo que es una medida estacionaria. Para confirmar que es una *probabilidad* estacionaria (y no solo una medida), verificamos que la suma sobre todo el espacio sea 1:

$$\sum_{x \in V} \pi(x) = \sum_{x \in V} \frac{1}{N} = N\left(\frac{1}{N}\right) = 1$$

3. Demostración de Unicidad:
El enunciado establece que la gráfica es **conexa**. En la teoría de Cadenas de Markov, esto significa que existe un camino de probabilidad positiva entre cualquier par de estados; por lo tanto, la cadena es **irreducible**. Dado que el espacio de estados es finito (N vértices) y la cadena es irreducible, el Teorema Fundamental de Cadenas de Markov garantiza que su distribución estacionaria existe y es **única**. □

Ejercicio 2.17. Tiempo de Mezcla y Brecha Espectral Absoluta

Exprese el tiempo de mezcla en términos de $\lambda_* = \text{máx}(|\lambda_2|, |\lambda_N|)$.

El Eigenvalor λ_N y la Periodicidad

En cadenas reversibles, los valores propios son reales y están acotados en el intervalo $[-1, 1]$. Sabemos que λ_2 controla el decaimiento de las diferencias a largo plazo (el çuello de botella"geométrico). Pero, ¿por qué importa λ_N? Si la gráfica es bipartita o casi bipartita, la cadena tiende a oscilar alternando entre conjuntos de nodos, lo que se refleja en un eigenvalor λ_N muy cercano a -1. Por ello, la verdadera velocidad de convergencia al equilibrio depende de la **brecha espectral absoluta** $\gamma_* = 1 - \lambda_*$, donde λ_* es el eigenvalor más grande en valor absoluto excluyendo al estado trivial $\lambda_1 = 1$.

Acotación del Tiempo de Mezcla. Sea $\lambda_* = \text{máx}(|\lambda_2|, |\lambda_N|)$ el segundo mayor valor propio en magnitud de la matriz de transición P.

1. Tiempo de Relajación:

El tiempo de relajación de la cadena, que mide el tiempo característico para que las desviaciones respecto al equilibrio decaigan en un factor de e, se define empleando la brecha espectral absoluta:

$$t_{\text{rel}} = \frac{1}{1 - \lambda_*}$$

2. Cota Superior General:

Para cualquier cadena reversible con un espacio de estados finito, el tiempo de mezcla $t_{\text{mix}}(\epsilon)$ (el tiempo mínimo necesario para que la distancia en variación total al equilibrio sea menor a ϵ) está acotado superiormente por el teorema de convergencia de autovalores:

$$t_{\text{mix}}(\epsilon) \leq t_{\text{rel}} \ln\left(\frac{1}{\epsilon \pi_{\text{mín}}}\right)$$

3. Sustitución para la Gráfica d-regular:

Del inciso (a) demostramos que la distribución estacionaria es perfectamente uniforme: $\pi(x) = \frac{1}{N}$ para todo $x \in V$. Por lo tanto, el peso de probabilidad más pequeño es $\pi_{\text{mín}} = \frac{1}{N}$. Sustituyendo esto y la definición de t_{rel} en nuestra desigualdad, obtenemos:

$$t_{\text{mix}}(\epsilon) \leq \left(\frac{1}{1 - \lambda_*}\right) \ln\left(\frac{N}{\epsilon}\right)$$

Evaluando para la convención estándar del tiempo de mezcla donde la distancia debe ser menor a $\epsilon = 1/4$:

$$t_{\text{mix}}(1/4) \leq \frac{\ln(4N)}{1 - \lambda_*}$$

Conclusión:

El tiempo de mezcla queda expresado asintóticamente en términos de λ_* como:

$$\mathbf{t}_{\text{mix}}(\epsilon) = \mathbf{O}\left(\frac{\log \mathbf{N}}{\mathbf{1} - \lambda_*}\right)$$

Queda explícito que para lograr una mezcla rápida (un rapid mixing"), se requiere que λ_* esté estrictamente alejado de 1, es decir, que la matriz de transición no tenga eigenvalores cercanos a 1 ni a -1. □

Ejercicio 2.18. Espectro del Hipercubo y Tiempo de Mezcla

Para el hipercubo $\{0,1\}^d$, calcule los valores propios $\lambda_k = 1 - 2k/d$ $(k = 0, 1, \ldots, d)$ con multiplicidades $\binom{d}{k}$ y obtenga $t_{\text{mix}}(1/4) = \Theta(d \log d)$.

El Hipercubo y la Matriz de Transición

Un hipercubo de dimensión d tiene $N = 2^d$ vértices. Dos vértices están conectados si difieren en exactamente una coordenada. La caminata simple elige una de las d coordenadas al azar (probabilidad $1/d$) y la voltea. Se puede analizar como el producto tensorial de d caminatas independientes en el grafo de dos nodos K_2.

Cálculo de Eigenvalores y Tiempo de Mezcla. **1. Valores Propios del Hipercubo:**
Consideremos la caminata en una sola dimensión (un bit). Sus eigenvalores son 1 (vector simétrico) y -1 (vector antisimétrico). Al tener d dimensiones independientes, cualquier vector propio del hipercubo se forma combinando los estados de estas dimensiones. Si elegimos k dimensiones con el eigenvalor -1 y las $d-k$ restantes con el eigenvalor 1, el efecto de la matriz de transición (que promedia sobre las d dimensiones) será:

$$\lambda_k = \frac{(d-k)(1) + k(-1)}{d} = \frac{d-2k}{d} = 1 - \frac{2k}{d}$$

Para formar este eigenvalor específico, necesitamos escoger exactamente k coordenadas de las d disponibles. La cantidad de formas de hacer esto es el coeficiente binomial:

$$\text{Multiplicidad}(\lambda_k) = \binom{d}{k}$$

Notemos que la suma de todas las multiplicidades es $\sum \binom{d}{k} = 2^d = N$*, completando el espectro.*

2. Tiempo de Mezcla $\Theta(d \log d)$:
Si usamos la cota espectral pura con $\lambda_2 = 1 - 2/d$ y $\pi_{\text{mín}} = 1/2^d$, obtendríamos un límite superior de $O(d^2)$. Sin embargo, el tiempo de mezcla real es más rápido. Para hallar el tiempo exacto $\Theta(d \log d)$, recurrimos a un acoplamiento basado en el problema del **Coleccionista de Cupones** (Coupon Collector). La cadena se mezcla perfectamente cuando hemos seleccionado (y aleatorizado) todas y cada una de las d coordenadas al menos una vez. El tiempo esperado para coleccionar d elementos distintos, eligiendo uno al azar en cada paso, es matemáticamente conocido como:

$$E[T] \approx d \ln d + cd = \Theta(d \log d)$$

Por lo tanto, la caminata en el hipercubo requiere exactamente este tiempo para borrar la memoria de su estado inicial. □

Ejercicio 2.19. Comparación de Brechas Espectrales

Muestre que la *brecha espectral* $1 - \lambda_*$ es proporcional a $1/N^2$ para el camino lineal y a $1/d$ para el hipercubo.

Análisis de Brechas Espectrales. La brecha espectral absoluta $\gamma_* = 1 - \lambda_*$ es el indicador principal de la velocidad de convergencia (entre más grande sea la brecha, más rápida es la relajación). Comparamos dos topologías extremas:

1. El Camino Lineal (Path Graph de longitud N):
Los eigenvalores de un camino con N nodos reflejando en los bordes están dados por los cosenos de la matriz tridiagonal:

$$\lambda_k = \cos\left(\frac{\pi k}{N}\right) \quad \text{para } k = 0, \ldots, N-1$$

El segundo valor propio más grande es $\lambda_1 = \cos(\pi/N)$. Usando la expansión de Taylor para valores grandes de N ($\cos x \approx 1 - x^2/2$):

$$\lambda_1 \approx 1 - \frac{1}{2}\left(\frac{\pi}{N}\right)^2 = 1 - \frac{\pi^2}{2N^2}$$

Calculando la brecha espectral:

$$\gamma_{\text{lineal}} = 1 - \lambda_1 = 1 - \left(1 - \frac{\pi^2}{2N^2}\right) = \frac{\pi^2}{2N^2}$$

Por lo tanto, la brecha espectral decae cuadráticamente respecto al tamaño del grafo:

$$\gamma_{\text{lineal}} \propto \mathbf{\frac{1}{N^2}}$$

(Esto justifica por qué el camino lineal es una de las gráficas más lentas para mezclar, requiriendo $\Theta(N^2)$ pasos).

2. El Hipercubo de dimensión d:

Del inciso (c), calculamos explícitamente el espectro del hipercubo. El segundo eigenvalor más grande se da cuando $k = 1$:

$$\lambda_1 = 1 - \frac{2(1)}{d} = 1 - \frac{2}{d}$$

Calculando su brecha espectral:

$$\gamma_{\text{hipercubo}} = 1 - \left(1 - \frac{2}{d}\right) = \frac{2}{d}$$

Por lo tanto, la brecha es inversamente proporcional a la dimensión d:

$$\gamma_{\text{hipercubo}} \propto \mathbf{\frac{1}{d}}$$

Conclusión:

A pesar de que el hipercubo tiene una cantidad masiva de nodos ($N = 2^d$), su brecha espectral es $\propto 1/\log_2(N)$, comparado con el $1/N^2$ del camino lineal. Esto demuestra que la geometría altamente interconectada del hipercubo ("todo está cerca de todo") genera tiempos de convergencia exponencialmente más rápidos que las geometrías lineales. $\square$

3. Martingalas, potencial y función de Green

3.1. Teorema de paro opcional

Ejercicio 3.1. Teorema de paro opcional

Sea (M_n) una martingala respecto de $(\mathcal{F}_n)$ y τ un tiempo de paro.
(a) Enuncie el teorema de paro opcional de Doob y dé condiciones suficientes para $E^x[M_\tau] = E^x[M_0]$.

Una martingala representa un juego estadísticamente justo. El Teorema de Paro Opcional establece que no existe ninguna estrategia de retiro (tiempo de paro τ) que pueda convertir un juego justo en uno ventajoso, *siempre y cuando* no se tengan recursos ni tiempo infinitos. Si se cumplen ciertas condiciones de regularidad, el valor esperado al momento de detener el proceso es exactamente el valor inicial.

Teorema 3.1. Teorema de Paro Opcional de Doob

Sea $(M_n)_{n\geq 0}$ una martingala con respecto a la filtración $(\mathcal{F}_n)_{n\geq 0}$, y sea τ un tiempo de paro respecto a la misma filtración. Entonces, la esperanza del proceso detenido en τ es igual a la esperanza inicial:

$$E[M_\tau] = E[M_0]$$

siempre y cuando se cumpla al menos una de las siguientes tres condiciones suficientes:

1. **Tiempo de paro acotado:** Existe una constante determinista $N \in \mathbb{N}$ tal que $P(\tau \leq N) = 1$. (El juego forzosamente termina antes de un tiempo límite máximo).
2. **Tiempo de paro integrable e incrementos acotados:** El tiempo esperado para detenerse es finito, es decir, $E[\tau] < \infty$, **y** los saltos de la martingala están uniformemente acotados, es decir, existe una constante $C < \infty$ tal que $|M_{n+1} - M_n| \leq C$ casi seguramente para todo $n < \tau$.
3. **Martingala acotada (o Uniformemente Integrable):** El tiempo de paro es finito casi seguramente ($P(\tau < \infty) = 1$) **y** el proceso detenido $(M_{n\wedge\tau})$ está acotado por una constante K, es decir, $|M_{n\wedge\tau}| \leq K$ casi seguramente para todo n. (De manera más general, basta con que el proceso detenido sea uniformemente integrable).

Importancia de las Condiciones

Si no se cumple ninguna de estas tres condiciones, la igualdad $E[M_\tau] = E[M_0]$ puede fallar trágicamente. El ejemplo clásico es la estrategia de doblar la apuesta tras cada pérdida en un volado simétrico: la martingala eventualmente alcanza un valor positivo, pero requiere tolerar pérdidas intermedias arbitrariamente grandes (violando la condición 3) y un tiempo de paro no acotado (violando la condición 1).

Ejercicio 3.2. Caminata Simétrica: Probabilidad de Ruina y Tiempo Esperado

Para la caminata simple en $\mathbb{Z}$ desde 0, use las martingalas X_n y $X_n^2 - n$ para calcular $P^0(T_b < T_{-a})$ y $E^0[T_{-a,b}]$, con $a, b > 0$.

martingalas

En la caminata simple simétrica ($p = q = 1/2$), la posición X_n es una martingala porque el salto esperado es 0. Además, la varianza crece linealmente con el tiempo, lo que hace que $X_n^2 - n$ también sea una martingala. Aplicaremos el Teorema de Paro Opcional (OST) usando el tiempo de paro $T = \text{mín}(T_b, T_{-a})$, que está garantizado a ser finito casi seguramente.

Cálculo con X_n (Probabilidad). Sea $P_b = P^0(T_b < T_{-a})$ la probabilidad de tocar b antes que $-a$. Aplicando OST a la martingala X_n, sabemos que $E^0[X_T] = E^0[X_0] = 0$. Al momento de parar T, la partícula solo puede estar en dos lugares: en b (con probabilidad P_b) o en $-a$ (con probabilidad $1 - P_b$). Planteamos la esperanza:

$$E^0[X_T] = b \cdot P_b + (-a) \cdot (1 - P_b) = 0$$

$$bP_b - a + aP_b = 0 \implies P_b(a + b) = a$$

$$\mathbf{P^0(T_b < T_{-a}) = \frac{a}{a + b}}$$

(Justo como dicta el sentido común: la probabilidad de ganar es proporcional a qué tan lejos está tu ruina). □

Cálculo con $X_n^2 - n$ (Tiempo Esperado). Aplicando OST a la martingala $X_n^2 - n$, tenemos $E^0[X_T^2 - T] = X_0^2 - 0 = 0$.
Por linealidad de la esperanza: $E^0[T] = E^0[X_T^2]$.

Usando las probabilidades exactas que acabamos de calcular:

$$E^0[X_T^2] = b^2 \cdot P_b + (-a)^2 \cdot (1 - P_b)$$

$$E^0[X_T^2] = b^2 \left(\frac{a}{a + b}\right) + a^2 \left(\frac{b}{a + b}\right)$$

Factorizamos ab en el numerador:

$$E^0[T] = \frac{ab^2 + a^2 b}{a + b} = \frac{ab(b + a)}{a + b} = \mathbf{ab}$$

(El tiempo esperado para que termine el juego es simplemente el producto de las distancias a las dos barreras). □

Ejercicio 3.3. Caminata Asimétrica: Martingala Exponencial

Para $p \neq q$, muestre que $M_n = (q/p)^{X_n}$ es martingala y úsela para calcular $P^0(T_b < T_{-a})$ directamente.

Verificación y Cálculo. **1. Verificación de Martingala:**
Calculamos la esperanza condicional de un paso adelante:

$$E[M_{n+1} \mid X_n] = p \cdot (q/p)^{X_n+1} + q \cdot (q/p)^{X_n-1}$$

Factorizamos $(q/p)^{X_n}$ que es constante dado X_n:

$$= (q/p)^{X_n} \left[p\left(\frac{q}{p}\right) + q\left(\frac{p}{q}\right) \right] = (q/p)^{X_n}[q+p]$$

Como $p + q = 1$, nos queda exactamente $(q/p)^{X_n} = M_n$. Queda demostrado que es martingala.

2. Cálculo de la Probabilidad:
Aplicamos OST: $E^0[M_T] = M_0 = (q/p)^0 = 1$. Al tiempo T, la cadena vale $(q/p)^b$ con probabilidad P_b, y $(q/p)^{-a}$ con probabilidad $1 - P_b$:

$$P_b(q/p)^b + (1 - P_b)(q/p)^{-a} = 1$$

Despejamos P_b:

$$P_b\left((q/p)^b - (q/p)^{-a}\right) = 1 - (q/p)^{-a}$$

$$P_b = \frac{1 - (q/p)^{-a}}{(q/p)^b - (q/p)^{-a}}$$

Multiplicando numerador y denominador por $(q/p)^a$ para limpiar exponentes negativos:

$$\mathbf{P^0(T_b < T_{-a}) = \frac{(q/p)^a - 1}{(q/p)^{a+b} - 1}}$$

□

Ejercicio 3.4. Funciones Armónicas y OST

Sea $h : S \to \mathbb{R}$ armónica y acotada en $D = S \setminus A$. Demuestre que $h(x) = E^x[h(X_{T_A})]$ para $x \in D$.

Condición de Acotamiento

El hecho de que h sea acotada es vital. Nos permite usar el **Teorema de Convergencia Acotada** para justificar que el límite y la esperanza pueden intercambiarse cuando el tiempo de paro T_A tiende a infinito.

Demostración. Por definición, una función es armónica en D si para todo $x \in D$:

$$h(x) = \sum_{y \in S} p(x, y)h(y) = E^x[h(X_1)]$$

Esto significa que el proceso evaluado en la función $M_n = h(X_n)$ se comporta localmente como una martingala mientras la cadena permanezca en D.

Para evitar que la cadena evalúe la función fuera del dominio donde es armónica, detenemos el proceso al tocar la frontera A. Definimos la martingala detenida $M_{n \wedge T_A} = h(X_{n \wedge T_A})$.

Aplicando el Teorema de Paro Opcional para un tiempo determinista n:

$$E^x[h(X_{n \wedge T_A})] = h(x)$$

Tomamos el límite cuando $n \to \infty$. Asumiendo que la cadena eventualmente alcanza A con probabilidad 1 ($P(T_A < \infty) = 1$), tenemos que $X_{n \wedge T_A} \to X_{T_A}$ casi seguramente. Dado que el problema especifica que h está **acotada**, podemos aplicar el Teorema de Convergencia Acotada de Lebesgue para meter el límite dentro de la esperanza:

$$\lim_{n \to \infty} E^x[h(X_{n \wedge T_A})] = E^x\left[\lim_{n \to \infty} h(X_{n \wedge T_A})\right] = E^x[h(X_{T_A})]$$

Igualando este resultado con la esperanza inicial que era invariante respecto a n, concluimos:

$$\mathbf{h(x) = E^x[h(X_{T_A})]}$$

□

3.2. Problema de Dirichlet discreto

Ejercicio 3.5. Problema de Dirichlet Discreto

Sea (X_n) una cadena, $D \subset S$ finito y $f : \partial D \to \mathbb{R}$ dada en $\partial D = S \setminus D$.
(a) Demuestre que $h(x) = E^x[f(X_{T_{\partial D}})]$ es la única solución del *problema de Dirichlet discreto*:

$$\sum_{y \in S} p(x,y)h(y) = h(x) \text{ en } D, \quad h = f \text{ en } \partial D.$$

Conexión Estocástica-Analítica

Este resultado demuestra que las ecuaciones en diferencias con condiciones de frontera fijas pueden resolverse estocásticamente. El valor de la función en un punto interior es exactamente el valor esperado de la función de frontera, evaluado en el punto aleatorio donde la caminata choca por primera vez con dicha frontera.

Demostración (Existencia y Unicidad). La demostración se divide en dos partes: primero verificar que $h(x)$ es una solución válida (existencia), y luego usar martingalas para probar que no existe otra (unicidad).

1. Existencia (Verificación de la Solución):
Evaluamos la función $h(x) = E^x[f(X_{T_{\partial D}})]$ en los dos dominios posibles para x:

- **En la frontera ($x \in \partial D$):** Si la cadena arranca directamente en la frontera, el tiempo para alcanzarla es cero ($T_{\partial D} = 0$). El estado de paro es el mismo punto inicial $X_0 = x$. La esperanza se vuelve trivial: $h(x) = E^x[f(x)] = f(x)$. *(Se cumple perfectamente la condición de frontera).*
- **En el interior ($x \in D$):** Si arrancamos en el interior, obligatoriamente daremos al menos un paso antes de tocar la frontera. Condicionamos sobre el primer salto $X_1 = y$ usando la Ley de Probabilidad Total:

$$h(x) = E^x[f(X_{T_{\partial D}})] = \sum_{y \in S} E^x[f(X_{T_{\partial D}}) \mid X_1 = y]p(x,y)$$

  Por la propiedad de Markov, una vez que la cadena está en y, su evolución futura es idéntica a una cadena que arrancó fresca en y:

$$h(x) = \sum_{y \in S} E^y[f(X_{T_{\partial D}})]p(x,y) = \sum_{y \in S} p(x,y)h(y)$$

  (Se cumple perfectamente la condición de función armónica en el interior).

2. Unicidad (Aplicación del Teorema de Paro Opcional):
Supongamos que existe una función alternativa $g(x)$ que también es solución del problema de Dirichlet discreto. Como g cumple $\sum_y p(x,y)g(y) = g(x)$ en el interior D, el proceso evaluado en esta función, $M_n = g(X_n)$, se comporta como una **martingala** mientras la cadena no escape de D.

Para evitar salirnos del dominio de harmonicidad, detenemos la martingala exactamente al tocar la frontera ∂D. Al ser S un conjunto finito (y asumiendo irreducibilidad hacia la frontera), el tiempo de paro es finito casi seguramente ($P(T_{\partial D} < \infty) = 1$). Aplicamos el Teorema de Paro Opcional de Doob a la martingala detenida:

$$g(x) = E^x[M_0] = E^x[M_{T_{\partial D}}]$$

Sustituimos la definición de nuestra martingala al tiempo de paro:

$$g(x) = E^x[g(X_{T_{\partial D}})]$$

Sabemos con total certeza que al tiempo $T_{\partial D}$, la posición de la cadena $X_{T_{\partial D}}$ pertenece a la frontera ∂D. En esa frontera, g está obligada (por la condición del problema) a tomar los valores de la función límite f. Sustituimos g por f dentro del operador de esperanza:

$$g(x) = E^x[f(X_{T_{\partial D}})]$$

Notamos que el lado derecho de la ecuación es exactamente la definición de $h(x)$. Por lo tanto, $g(x) = h(x)$.

$\square$

Ejercicio 3.6. Principio del Máximo Discreto

Obtenga el *principio del máximo discreto*: $\text{mín}_{\partial D} f \leq h(x) \leq \text{máx}_{\partial D} f$ para $x \in D$.

Interpretación del Principio

Si imaginamos a $h(x)$ como la temperatura en una placa D, el Principio del Máximo nos dice que el interior no puede estar ni más caliente que el punto más caliente de los bordes, ni más frío que el punto más frío. Las funciones armónicas promedian su entorno, por lo que nunca pueden crear un "pico.ªislado en el interior.

Obtención a partir de la Solución Estocástica. Por el inciso (a), sabemos que la única solución a la ecuación es la esperanza estocástica:

$$h(x) = E^x[f(X_{T_{\partial D}})]$$

Para cualquier trayectoria aleatoria, la posición de parada $X_{T_{\partial D}}$ pertenece a la frontera ∂D. Por definición de máximo y mínimo, para cualquier punto de esa frontera, se cumple que:

$$\min_{y \in \partial D} f(y) \leq f(X_{T_{\partial D}}) \leq \max_{y \in \partial D} f(y)$$

Como esta desigualdad es válida para *todas* las trayectorias (casi seguramente), podemos tomar la esperanza condicional $E^x[\cdot]$ a los tres términos. Sabiendo que el valor esperado de una constante es la constante misma y que la esperanza preserva desigualdades (monotonía), obtenemos:

$$E^x\left[\min_{y \in \partial D} f(y)\right] \leq E^x\left[f(X_{T_{\partial D}})\right] \leq E^x\left[\max_{y \in \partial D} f(y)\right]$$

$$\min_{\partial D} f \leq h(x) \leq \max_{\partial D} f$$

Queda demostrado el Principio del Máximo Discreto. □

Ejercicio 3.7. Aplicación a la Ruina del Jugador

Aplique a la caminata simple en $\{0, 1, \ldots, N\}$ con $f(0) = 0$, $f(N) = 1$ para recuperar $u(x)$.

Recuperación de la Probabilidad de Ruina. Definimos el dominio interior como $D = \{1, 2, \ldots, N-1\}$ y la frontera como $\partial D = \{0, N\}$. La función de frontera f está dada como $f(0) = 0$ y $f(N) = 1$.

Por la representación estocástica del Problema de Dirichlet (inciso a), la solución es:

$$h(x) = E^x[f(X_{T_{\partial D}})]$$

Dado que f solo toma valores en 0 y 1, desarrollamos la esperanza utilizando probabilidades discretas:

$$h(x) = f(0) \cdot P^x(X_{T_{\partial D}} = 0) + f(N) \cdot P^x(X_{T_{\partial D}} = N)$$

Sustituyendo los valores de f:

$$h(x) = 0 \cdot P^x(T_0 < T_N) + 1 \cdot P^x(T_N < T_0)$$

$$h(x) = P^x(T_N < T_0)$$

Para una caminata simple ($p = q = 1/2$), sabemos que la función armónica $h(x)$ en el interior debe ser lineal: $h(x) = Ax + B$. Aplicando las condiciones de frontera:

- $h(0) = B = 0$
- $h(N) = AN = 1 \implies A = 1/N$

Por lo tanto, la función es $h(x) = x/N$. Igualando nuestro resultado analítico con la interpretación probabilística, recuperamos la fórmula clásica de la ruina en juegos simétricos (que demostramos en el capítulo 1):

$$\mathbf{u(x) = P^x(T_N < T_0) = \frac{x}{N}}$$

□

Ejercicio 3.8. Ecuación de Poisson para Tiempos Esperados

Calcule $E^x[T_{\partial D}]$ mediante la solución de $(P-I)g = -1$ en D, $g = 0$ en ∂D.

Diferencia entre Dirichlet y Poisson

Mientras que Dirichlet calcula *a dónde* vamos a parar (usando la ecuación de Laplace $(P-I)h = 0$), el problema de Poisson calcula *cuánto tiempo* nos va a tomar (usando una fuente constante $(P-I)g = -1$, indicando que en cada paso perdemos una unidad de tiempo).

Relación entre Tiempos de Paro y Ecuaciones Lineales. Sea $g(x) = E^x[T_{\partial D}]$ el tiempo esperado para salir de D comenzando en x.

1. Condición de Frontera:
Si $x \in \partial D$, la partícula ya está en la frontera y el tiempo de viaje es cero. Por tanto, $g(x) = 0$ para todo $x \in \partial D$. *(Se cumple la condición).*

2. Ecuación en el Interior:
Si $x \in D$, obligatoriamente la cadena da al menos 1 paso. Condicionamos sobre el primer salto $X_1 = y$:

$$g(x) = E^x[T_{\partial D}] = 1 + \sum_{y \in S} p(x,y) E^y[T_{\partial D}]$$

Sustituyendo nuestra definición $g(y) = E^y[T_{\partial D}]$:

$$g(x) = 1 + \sum_{y \in S} p(x,y) g(y)$$

3. Forma Matricial (Poisson):
Reescribimos la suma utilizando notación matricial (o de operador):

$$g(x) = 1 + (Pg)(x)$$

Pasamos $g(x)$ restando al lado derecho:

$$0 = 1 + (Pg)(x) - g(x) = 1 + (P-I)g(x)$$

Despejando, llegamos a la ecuación lineal solicitada:

$$(\mathbf{P} - \mathbf{I})\mathbf{g}(\mathbf{x}) = -\mathbf{1} \quad \text{para } \mathbf{x} \in \mathbf{D}$$

Conclusión: Al igual que en Dirichlet, resolver este sistema lineal nos entrega directamente el tiempo de paro esperado sin tener que lidiar con sumatorias infinitas. □

3.3. Función de Green y ecuación de Poisson

Ejercicio 3.9. Función de Green y ecuación de Poisson

Sea (X_n) transiente en S; defina $G(x,y) = \sum_{n=0}^{\infty} p^n(x,y)$.
(a) Demuestre que $G(x,y) < \infty$ para todo x, y si y solo si la cadena es transiente.

Interpretación de la Función de Green

La función $G(x,y)$ representa el **número esperado de visitas** al estado y dado que la cadena inició en el estado x. Para ver esto, note que la variable indicadora $\mathbf{1}_{\{X_n=y\}}$ vale 1 si la cadena está en y al tiempo n, y 0 en caso contrario. El número total de visitas es $N(y) = \sum_{n=0}^{\infty} \mathbf{1}_{\{X_n=y\}}$. Tomando la esperanza condicional:

$$E^x[N(y)] = E^x\left[\sum_{n=0}^{\infty} \mathbf{1}_{\{X_n=y\}}\right] = \sum_{n=0}^{\infty} P^x(X_n = y) = \sum_{n=0}^{\infty} p^n(x,y) = G(x,y)$$

Demostración (Equivalencia Transiente). Por definición, un estado $y \in S$ es transiente si la probabilidad de regresar a él alguna vez, denotada como f_{yy}, es estrictamente menor a 1 ($f_{yy} < 1$). Una cadena es transiente si todos sus estados lo son.

Recordemos la relación fundamental para una Cadena de Markov entre el número esperado de visitas y la probabilidad de retorno:

$$G(y,y) = \sum_{n=0}^{\infty} p^n(y,y) = \frac{1}{1 - f_{yy}}$$

1. Ida ($\Longrightarrow$):
Supongamos que $G(x,y) < \infty$ para todo par $x, y \in S$. En particular, si evaluamos el caso donde empezamos y terminamos en el mismo estado ($x = y$), tenemos que $G(y,y) < \infty$. Sustituyendo esto en nuestra relación fundamental:

$$\frac{1}{1 - f_{yy}} < \infty \implies 1 - f_{yy} > 0 \implies f_{yy} < 1$$

Como la probabilidad de retorno al origen es estrictamente menor a 1 para todo estado y, concluimos por definición que **la cadena es transiente**.

2. Regreso ($\Longleftarrow$):
Supongamos ahora que la cadena es transiente. Esto significa que para todo estado y, se cumple que $f_{yy} < 1$. Por nuestra relación fundamental, el denominador $1 - f_{yy}$ es mayor a cero, lo que implica inmediatamente que $G(y,y) < \infty$.

Ahora, necesitamos probar que esto también acota los viajes cruzados desde cualquier otro estado $x \neq y$. El número esperado de visitas a y empezando desde x se puede descomponer usando la propiedad fuerte de Markov en dos etapas: Primero, la cadena debe lograr llegar a y por primera vez (lo cual ocurre con probabilidad f_{xy}); y una vez que pisa y, el proceso se reiniciaz el número esperado de visitas a partir de ahí es exactamente $G(y,y)$. Escrito algebraicamente:

$$G(x,y) = f_{xy} \cdot G(y,y)$$

Dado que f_{xy} es una probabilidad ($f_{xy} \leq 1$) y ya demostramos en el paso anterior que $G(y,y)$ es finito ($G(y,y) < \infty$), el producto de ambos obligatoriamente tiene que estar acotado:

$$\mathbf{G(x,y)} < \infty \quad \text{para todo } x, y \in S$$

Queda demostrada la equivalencia bidireccional. □

Ejercicio 3.10. Ecuación de Poisson y la Delta de Dirac

Muestre que $G(\cdot, y)$ resuelve la ecuación de Poisson $(P - I)f = -\delta_y$.

El Operador Laplaciano Discreto

El operador $P - I$ (o $\Delta = P - I$) actúa sobre una función f evaluando la diferencia entre el valor promedio de la función en los vecinos de x y el valor en x. La función delta de Dirac $\delta_y(x)$ vale 1 si $x = y$, y 0 en cualquier otro caso.

Demostración Analítica. Sea $f(x) = G(x, y) = \sum_{n=0}^{\infty} p^n(x, y)$. Aplicamos el operador matricial P a la función f:

$$(Pf)(x) = \sum_{z \in S} p(x, z) f(z) = \sum_{z \in S} p(x, z) \sum_{n=0}^{\infty} p^n(z, y)$$

Por el Teorema de Fubini/Tonelli (dado que todos los términos son positivos), podemos intercambiar las sumas:

$$(Pf)(x) = \sum_{n=0}^{\infty} \sum_{z \in S} p(x, z) p^n(z, y)$$

Por la ecuación de Chapman-Kolmogorov, la suma interna representa exactamente la probabilidad de transición en $n + 1$ pasos:

$$(Pf)(x) = \sum_{n=0}^{\infty} p^{n+1}(x, y)$$

Haciendo un cambio de índice ($k = n + 1$), la suma va desde $k = 1$ hasta ∞:

$$(Pf)(x) = \sum_{k=1}^{\infty} p^k(x, y)$$

Para recuperar la función original $f(x) = G(x, y)$ (que empieza en $n = 0$), sumamos y restamos el término inicial $p^0(x, y)$:

$$(Pf)(x) = \sum_{k=0}^{\infty} p^k(x, y) - p^0(x, y) = G(x, y) - p^0(x, y)$$

Sabiendo que $p^0(x, y)$ es la probabilidad de ir de x a y en cero pasos, esto es exactamente la delta de Dirac $\delta_y(x)$. Sustituyendo:

$$(Pf)(x) = f(x) - \delta_y(x)$$

Agrupamos los términos de f:

$$(Pf)(x) - f(x) = -\delta_y(x) \implies (\mathbf{P} - \mathbf{I})\mathbf{f}(\mathbf{x}) = -\delta_{\mathbf{y}}(\mathbf{x})$$

Queda demostrado que la Función de Green es la solución fundamental. □

Ejercicio 3.11. Decaimiento Asintótico de la Función de Green

Para $d \geq 3$, muestre que $G(x,y) \to 0$ cuando $|x-y| \to \infty$ y que $G(x,y) \asymp |x-y|^{2-d}$.

Esbozo de la Demostración. Por simetría e invarianza de traslación, $G(x,y) = G(0, y-x)$. Denotemos $r = |x-y|$ como la distancia euclidiana entre los puntos.

Para que la partícula viaje una distancia r, requiere al menos $O(r)$ pasos, pero la difusión aleatoria típicamente toma $n \approx r^2$ pasos para alcanzar un radio r. La probabilidad de transición a tiempo n en d dimensiones escala según el Teorema del Límite Central Local como $p^n(0,r) \approx n^{-d/2} \exp(-r^2/2n)$.

Aproximando la suma de la Función de Green mediante una integral:

$$G(0,r) = \sum_{n=0}^{\infty} p^n(0,r) \approx \int_0^{\infty} n^{-d/2} e^{-r^2/2n} dn$$

Realizamos el cambio de variable $u = r^2/n \implies dn = -r^2/u^2 du$:

$$G(0,r) \approx \int_{\infty}^{0} \left(\frac{u}{r^2}\right)^{d/2} e^{-u/2} \left(-\frac{r^2}{u^2}\right) du = r^{2-d} \int_0^{\infty} u^{d/2-2} e^{-u/2} du$$

La integral resultante es una función Gamma constante que solo depende de d (específicamente $\Gamma(d/2-1)2^{d/2-1}$). Por lo tanto, la dependencia respecto a la distancia queda aislada en el factor inicial:

$$\mathbf{G(x,y) \asymp |x-y|^{2-d}}$$

Conclusión: Como $d \geq 3$, el exponente $2-d$ es estrictamente negativo. Cuando $|x-y| \to \infty$, el término $|x-y|^{2-d} \to 0$. Esto demuestra matemáticamente que la influencia entre dos puntos en dimensiones altas desaparece a largas distancias. $\square$

Ejercicio 3.12. Solución del Problema de Poisson General

Sea D finito y $g : D \to \mathbb{R}$. Demuestre que $f(x) = E^x \left[\sum_{n=0}^{T_{S\setminus D}-1} g(X_n)\right]$ es la solución de $(P-I)f = -g$ en D con $f = 0$ fuera de D.

Verificación de la Solución Estocástica. Esta ecuación representa el çosto total.º recompensa total.ªcumulada antes de salir del dominio D, donde en cada paso en el estado z cobramos $g(z)$. Denotemos la frontera como $\partial D = S \setminus D$.

1. Condición de Frontera:
Si la cadena inicia en un punto fuera de D ($x \in \partial D$), el tiempo de salida es instantáneo ($T_{\partial D} = 0$). La sumatoria va desde $n = 0$ hasta -1, lo cual se define convencionalmente como el conjunto vacío o suma cero.

$$f(x) = E^x[0] = 0 \quad \text{para } x \notin D$$

(La condición de frontera se satisface de forma trivial).

2. Ecuación en el Interior (Propiedad de Markov):
Si $x \in D$, obligatoriamente damos al menos un paso antes de salir. Podemos separar el primer término de la sumatoria (el costo inmediato en $n = 0$) del resto de los pasos futuros:

$$f(x) = E^x \left[g(X_0) + \sum_{n=1}^{T_{\partial D}-1} g(X_n) \right]$$

Como empezamos en x, $g(X_0) = g(x)$, y al ser determinista, sale de la esperanza:

$$f(x) = g(x) + E^x \left[\sum_{n=1}^{T_{\partial D}-1} g(X_n) \right]$$

Aplicamos la Ley de Probabilidad Total para condicionar sobre el primer salto hacia el estado y:

$$f(x) = g(x) + \sum_{y \in S} p(x,y) E^x \left[\sum_{n=1}^{T_{\partial D}-1} g(X_n) \;\middle|\; X_1 = y \right]$$

Por la propiedad de Markov, el futuro a partir de $n = 1$ (habiendo llegado a y) tiene la misma distribución que empezar de cero desde y:

$$f(x) = g(x) + \sum_{y \in S} p(x,y) E^y \left[\sum_{m=0}^{T_{\partial D}-1} g(X_m) \right]$$

Notemos que la esperanza en el lado derecho es exactamente la definición de $f(y)$. Sustituyendo:

$$f(x) = g(x) + \sum_{y \in S} p(x,y) f(y)$$

Reescribimos la suma usando el operador P:

$$f(x) = g(x) + (Pf)(x)$$

Pasamos $f(x)$ al lado derecho y factorizamos:

$$-g(x) = (Pf)(x) - f(x) = (P - I)f(x)$$

Conclusión:

$$(\mathbf{P} - \mathbf{I})\mathbf{f} = -\mathbf{g} \text{ en } \mathbf{D}$$

Queda demostrado que el costo estocástico acumulado es la solución única de la ecuación de Poisson general con condiciones de frontera cero. □

3.4. Tiempo de cubrimiento de una gráfica

Ejercicio 3.13. Tiempo de cubrimiento en el camino lineal

Para una gráfica finita conexa $G = (V, E_G)$, el *tiempo de cubrimiento* es $C_x = \max_{y \in V} T_{\{y\}}$, el primer tiempo en que la caminata simple ha visitado todos los vértices.
(a) Para el camino lineal $\{0, 1, \ldots, N\}$, calcule $E^0[C_0]$ usando los tiempos de llegada $E^x[T_{\{y\}}]$ del Ejercicio 1.4. Muestre que $E^0[C_0] = \Theta(N^2)$.

Reducción Topológica del Problema

En una gráfica arbitraria, calcular el tiempo de cubrimiento es complejo porque la partícula puede re-visitar nodos de forma caótica. Sin embargo, en un camino lineal unidimensional arrancando desde un extremo ($x = 0$), para poder visitar el otro extremo (N), la partícula forzosamente tuvo que haber pisado todos los nodos intermedios $(1, 2, \ldots, N-1)$. Por lo tanto, el evento "visitar todos los vértices.ºcurre exactamente en el mismo instante en que se visita el vértice N por primera vez.

$$C_0 = T_N \implies E^0[C_0] = E^0[T_N]$$

Cálculo del Tiempo Esperado. Para encontrar el tiempo total $E^0[T_N]$, lo descomponemos como la suma de los tiempos esperados para avanzar de un nodo k al siguiente nodo $k+1$:

$$E^0[T_N] = \sum_{k=0}^{N-1} E^k[T_{k+1}]$$

Analizamos el tiempo esperado de transición de k a $k+1$, asumiendo reflexión en el origen ($p(0,1) = 1$) y saltos simétricos ($p = q = 1/2$) en el interior:

- **Frontera ($k = 0$):** El único salto posible es hacia el 1. El tiempo es determinista:

$$E^0[T_1] = 1$$

- **Interior ($k \geq 1$):** Condicionamos sobre el primer salto. Podemos avanzar a $k+1$ (éxito en 1 paso) o retroceder a $k-1$ (tardando 1 paso más el tiempo en recuperar el terreno desde $k-1$ hasta $k+1$):

$$E^k[T_{k+1}] = \frac{1}{2}(1) + \frac{1}{2}(1 + E^{k-1}[T_{k+1}])$$

Descomponiendo el viaje desde $k-1$ hasta $k+1$ como la suma de ir de $k-1 \to k$ y luego de $k \to k+1$:

$$E^k[T_{k+1}] = \frac{1}{2} + \frac{1}{2}\left(1 + E^{k-1}[T_k] + E^k[T_{k+1}]\right)$$

Multiplicamos todo por 2:

$$2E^k[T_{k+1}] = 1 + 1 + E^{k-1}[T_k] + E^k[T_{k+1}]$$

Restamos $E^k[T_{k+1}]$ de ambos lados:

$$E^k[T_{k+1}] = E^{k-1}[T_k] + 2$$

Esta es una progresión aritmética clásica. Si $E^0[T_1] = 1$ y cada subsecuente aumenta en 2, el término general es de los números impares:

$$E^k[T_{k+1}] = 2k + 1$$

Sustituimos esto en nuestra suma original telescópica:

$$E^0[T_N] = \sum_{k=0}^{N-1} (2k+1)$$

Separamos la sumatoria:

$$= 2\sum_{k=0}^{N-1} k + \sum_{k=0}^{N-1} 1$$

Aplicamos la fórmula de la suma de Gauss para los primeros $N-1$ enteros:

$$= 2\left[\frac{(N-1)N}{2}\right] + N$$

$$= N(N-1) + N = N^2 - N + N = N^2$$

Conclusión: Hemos obtenido que $E^0[C_0] = N^2$. Dado que esta es una función polinomial exacta de grado 2, acota tanto superior como inferiormente asintóticamente a la función, por lo que:

$$\mathbf{E^0[C_0] = \Theta(N^2)}$$

Queda demostrado que el tiempo para cubrir un camino lineal escala cuadráticamente respecto a su longitud. □

Ejercicio 3.14. Tiempo de cubrimiento en el Ciclo $\mathbb{Z}_N$

Para el ciclo $\mathbb{Z}_N$, calcule $E^0[C_0]$ y muestre que es también $\Theta(N^2)$.

Expansión del Arco Visitado

En un ciclo, el conjunto de vértices visitados siempre forma un arco continuo. Si hemos visitado k vértices distintos, la partícula forzosamente se encuentra en uno de los dos extremos de este arco. Para visitar un nuevo vértice (y hacer que el arco crezca a $k+1$), la caminata debe dar un paso "hacia afuera"del arco.

Cálculo del Tiempo en el Ciclo. Supongamos que el arco de vértices visitados tiene tamaño k (con $1 \leq k < N$) y la partícula está en uno de sus extremos. Para visitar un vértice nuevo, la partícula debe moverse al nodo adyacente no visitado. Si se mueve hacia .ªdentro"del arco, tendrá que recorrer toda la longitud de los k vértices ya visitados para intentar salir por el otro extremo.

Este escenario es idéntico al problema de la ruina del jugador en un segmento de longitud k. La partícula está a distancia 1 de un nuevo vértice (éxito) y a distancia k del otro nuevo vértice al extremo opuesto. Por las fórmulas de tiempo esperado de la caminata simple (Ejercicio 3.1b), el tiempo esperado para tocar cualquiera de las dos barreras (distancia 1 y distancia k) es el producto de las distancias:

$$E[\text{Tiempo para pasar de tamaño } k \text{ a } k+1] = 1 \cdot k = k$$

El tiempo total de cubrimiento es la suma del tiempo que toma expandir el arco desde tamaño 1 (el vértice inicial) hasta tamaño N (todos visitados):

$$E^0[C_0] = \sum_{k=1}^{N-1} k$$

Aplicando la fórmula de la suma de Gauss:

$$E^0[C_0] = \frac{N(N-1)}{2} = \frac{1}{2}N^2 - \frac{1}{2}N$$

Conclusión: Al ser un polinomio de segundo grado, la cota asintótica es idéntica a la del camino lineal:

$$\mathbf{E^0[C_0] = \Theta(N^2)}$$

□

Ejercicio 3.15. Tiempo de cubrimiento en la Gráfica Completa K_N

Para la gráfica completa K_N, use el modelo de *coleccionista de cupones*: la k-ésima visita a un estado nuevo requiere en promedio $N/(N-k+1)$ pasos. Deduzca $E^x[C_x] \sim N \log N$.

Deducción Asintótica (Coleccionista de Cupones). En la gráfica completa K_N, desde cualquier vértice, la caminata salta a cualquiera de los otros $N-1$ vértices con probabilidad uniforme. Aproximando esto al modelo clásico de extraer elementos con reemplazo de una urna de N elementos, la probabilidad de visitar un estado nuevo cuando ya hemos visitado $k-1$ estados es la proporción de estados no visitados:

$$p_k \approx \frac{N-(k-1)}{N} = \frac{N-k+1}{N}$$

El número de pasos para lograr este éxito sigue una distribución geométrica, cuya esperanza es el inverso de la probabilidad:

$$E[\text{Pasos para la } k\text{-ésima visita}] = \frac{1}{p_k} = \frac{N}{N-k+1}$$

El tiempo total de cubrimiento es la suma de los tiempos esperados para coleccionar los N vértices (comenzando a contar desde el segundo, pues el primero ya está visitado en $t=0$):

$$E^x[C_x] = \sum_{k=2}^{N} \frac{N}{N-k+1}$$

Hacemos un cambio de índice definiendo $j = N-k+1$. Cuando $k=2 \implies j=N-1$, y cuando $k=N \implies j=1$:

$$E^x[C_x] = N \sum_{j=1}^{N-1} \frac{1}{j}$$

Reconocemos la sumatoria como el $(N-1)$-ésimo número armónico, H_{N-1}. Se sabe por cálculo elemental que la suma armónica crece asintóticamente como el logaritmo natural:

$$\sum_{j=1}^{N-1} \frac{1}{j} \sim \ln(N)$$

Sustituyendo esta aproximación:

$$\mathbf{E^x[C_x] \sim N \log N}$$

Esto demuestra la increíble eficiencia de expansión de las redes altamente conexas. □

Ejercicio 3.16. Potencial de Green y Tiempos de Llegada

Enuncie cómo la función de Green $G(x, y)$ puede usarse para estimar $E^x[T_{\{y\}}]$ en términos del *potencial de Green*.

El Operador Potencial

Para cadenas recurrentes (donde la matriz G estándar diverge a infinito), se define la matriz de **Potencial de Green** R (o matriz fundamental) que mide la desviación acumulada respecto a la distribución estacionaria π:

$$R(x, y) = \sum_{n=0}^{\infty} (p^n(x, y) - \pi(y))$$

Relación entre Potencial y Tiempo de Llegada. El tiempo esperado para alcanzar un estado y arrancando desde x, denotado como $E^x[T_{\{y\}}]$, puede calcularse exactamente sin necesidad de simular toda la caminata, utilizando únicamente las entradas de la matriz de potencial R y la distribución estacionaria π.

La identidad fundamental establece que la diferencia de potenciales entre el estado objetivo y y el punto de inicio x escala proporcionalmente al tiempo de llegada:

$$\mathbf{E^x[T_{\{y\}}] = \frac{R(y, y) - R(x, y)}{\pi(y)}}$$

Interpretación:

- $\pi(y)$ actúa como un factor de escala (estados más probables asintóticamente son más rápidos de alcanzar).
- $R(y, y)$ es el .ªuto-potencial.º resistencia local del nodo destino.
- $R(x, y)$ representa el flujo o conductancia cruzada entre el origen y el destino.

Si el grafo es transitivo (muy simétrico), la fórmula colapsa a identidades directas, lo que convierte a la teoría del potencial en la herramienta algebraica más poderosa para estudiar caminatas aleatorias. □

3.5. Capacidad y probabilidad de absorción

Ejercicio 3.17. Capacidad y Probabilidad de Absorción

Sea (X_n) la caminata simple en $\mathbb{Z}^d$ con $d \geq 3$. Para $A \subset \mathbb{Z}^d$ finito, la *capacidad* de A es

$$\mathrm{Cap}(A) = \sum_{x \in A} \pi(x) P^x(T_A^+ = \infty),$$

donde π es la medida de Green normalizada.
(a) Demuestre que $P^x(T_A < \infty) = G(x, A)/G(A, A)$ en términos adecuados de la función de Green, donde $G(x, A) = \sum_{y \in A} G(x, y)$.

Intuición Electroestática

En la teoría del potencial clásica, el potencial $V(x)$ generado por un conductor A en el espacio tridimensional decae con la distancia. En probabilidad discreta, este potencial es exactamente la probabilidad de golpear el conjunto: $V(x) = P^x(T_A < \infty)$. Este inciso nos dice que dicha probabilidad es proporcional a la ïnfluencia total"$G(x, A)$, normalizada por la influencia interna del conjunto $G(A, A)$.

Demostración por la Propiedad Fuerte de Markov. **1. Descomposición del Número Esperado de Visitas:**
Por definición, $G(x, A)$ es el número esperado de visitas totales a cualquier punto del conjunto A, arrancando desde x. Podemos expresar este número separando las trayectorias en dos eventos mutuamente excluyentes: aquellas que *nunca* visitan A, y aquellas que *sí* lo visitan al menos una vez.

Sea $T_A = \text{mín}\{n \geq 0 : X_n \in A\}$ el tiempo de primera llegada al conjunto A.

- Si $T_A = \infty$, la cadena nunca visita A, por lo que el número de visitas es 0.
- Si $T_A < \infty$, la cadena llega a A en algún punto de entrada $X_{T_A} = z \in A$.

2. Aplicación de la Propiedad Fuerte de Markov:
Condicionamos la esperanza del número de visitas al hecho de haber llegado a A:

$$G(x, A) = E^x\left[\text{Visitas a } A \mid T_A < \infty\right] P^x(T_A < \infty) + (0) P^x(T_A = \infty)$$

Por la Propiedad Fuerte de Markov, en el instante exacto T_A en que la cadena toca el conjunto A por primera vez en el estado z, el proceso "pierde la memoria". El número de visitas esperadas a A a partir de ese momento es exactamente igual a haber iniciado la cadena fresca desde z:

$$E^x\left[\text{Visitas a } A \mid T_A < \infty, X_{T_A} = z\right] = G(z, A)$$

3. El Término .^decuado"$G(A, A)$:
Sustituyendo esto en la ecuación anterior mediante la Ley de Probabilidad Total (promediando sobre todos los posibles puntos de entrada z):

$$G(x, A) = P^x(T_A < \infty) \sum_{z \in A} P^x(X_{T_A} = z \mid T_A < \infty) G(z, A)$$

La sumatoria representa el valor esperado de la función de Green evaluada en el punto de entrada aleatorio. El problema nos pide definir "términos adecuados". Por lo tanto, definimos $G(A, A)$ como la *influencia interna efectiva*, es decir, el valor esperado de visitas a A dado que ya logramos entrar a A:

$$G(A, A) := E^x\left[G(X_{T_A}, A) \mid T_A < \infty\right] = \sum_{z \in A} P^x(X_{T_A} = z \mid T_A < \infty) G(z, A)$$

(Nota: Si $A = \{y\}$ es un solo punto, la entrada es forzosamente y, por lo que $G(A, A)$ colapsa a la constante $G(y, y)$).

4. Despeje Final:
Sustituyendo esta definición en nuestra ecuación principal, obtenemos:

$$G(x, A) = P^x(T_A < \infty)G(A, A)$$

Despejando la probabilidad de absorción:

$$\mathbf{P^x(T_A < \infty) = \frac{G(x, A)}{G(A, A)}}$$

$\square$

Ejercicio 3.18. Comportamiento asintótico en $\mathbb{Z}^3$

Para $A = \{0\}$ en $\mathbb{Z}^3$, calcule $P^x(T_{\{0\}} < \infty) = G(x,0)/G(0,0)$ y dé el comportamiento asintótico cuando $|x| \to \infty$.

Cálculo Asintótico. Usando la fórmula demostrada en el inciso (a), la probabilidad de que una caminata que inicia en x golpee el origen en algún momento es:

$$P^x(T_{\{0\}} < \infty) = \frac{G(x,0)}{G(0,0)}$$

Del Ejercicio 3.3(c), sabemos que para $d = 3$, la función de Green decae proporcionalmente al inverso de la distancia euclidiana. Es decir, cuando $|x| \to \infty$, la relación asintótica es $G(x,0) \asymp |x|^{2-3} = |x|^{-1}$.

Dado que $G(0,0)$ es una constante estrictamente finita (el número esperado de retornos al origen es finito porque en $\mathbb{Z}^3$ la caminata es transiente), el comportamiento asintótico de la probabilidad de absorción está dominado únicamente por el numerador $G(x,0)$:

$$P^x(T_{\{0\}} < \infty) \asymp \frac{1}{G(0,0)}|x|^{-1}$$

Conclusión: La probabilidad de golpear el origen decae a un ritmo de $1/r$, donde $r = |x|$ es la distancia inicial al origen. Físicamente, esto es idéntico a cómo decae el potencial electrostático de una carga puntual en un espacio tridimensional vacío. $\square$

Ejercicio 3.19. Capacidad y la Partícula desde el Infinito

Interprete la capacidad como la probabilidad de que una partícula lanzada desde el infinito de golpee A.

Interpretación Física de la Capacidad

La medida $e_A(x) = P^x(T_A^+ = \infty)$ se conoce como la "medida de equilibrioz representa la carga eléctrica que debe distribuirse en la superficie del conjunto A para mantenerlo a un potencial constante. La capacidad, por definición, es la suma de toda esta carga local.
Si imaginamos el espacio infinito como un reservorio inmenso que inyecta partículas aleatorias al sistema, la capacidad de A funciona como su "sección transversal efectiva.º tamaño aparente. Entre mayor sea la $\mathrm{Cap}(A)$, mayor será la tasa a la que captura las partículas que vienen vagando desde posiciones asintóticamente lejanas. En términos simples, la capacidad mide qué tan "visible.es el conjunto A para un caminante aleatorio que inició su viaje en el infinito.

Ejercicio 3.20. Capacidad, Conductancia y el Principio de Dirichlet

¿Cuál es la relación entre capacidad, conductancia y el principio variacional de Dirichlet?

Correspondencia con Redes Eléctricas. Existe un isomorfismo profundo entre las Cadenas de Markov reversibles y los circuitos eléctricos clásicos:

1. Conductancia Efectiva: Si tratamos a las aristas del grafo como resistencias eléctricas con conductancia $C(x, y) = \pi(x)p(x, y)$, la capacidad de un conjunto A respecto al infinito es matemáticamente idéntica a la **conductancia efectiva** (el inverso de la resistencia equivalente) medida entre el conjunto A y el infinito.

$$\mathrm{Cap}(A) = C_{\text{eff}}(A, \infty)$$

2. Energía de Dirichlet: La energía disipada en forma de calor por la red eléctrica bajo un campo de voltajes f está dada por la Forma (o Energía) de Dirichlet:

$$\mathcal{E}(f, f) = \frac{1}{2} \sum_{x,y} C(x, y)(f(x) - f(y))^2$$

3. Principio Variacional de Dirichlet: Este principio fundamental establece que la naturaleza siempre busca el estado que minimiza la energía disipada. En nuestro contexto, el potencial eléctrico real $h(x)$ (que equivale a la probabilidad estocástica $P^x(T_A < \infty)$) es la función única que minimiza la energía de Dirichlet sujeta a las restricciones de frontera ($f = 1$ en A, y $f \to 0$ en el infinito).

Síntesis Matemática: Si evaluamos la energía total disipada utilizando esta función minimizadora h, obtenemos exactamente la capacidad:

$$\mathrm{Cap}(A) = \mathcal{E}(h, h) = \min_{f|_A=1, f|_\infty=0} \mathcal{E}(f, f)$$

Conclusión: La capacidad de un conjunto mide la mínima energía que la red debe disipar para poder mantener un potencial de 1 *en* A *y* 0 *en el infinito.* □

3.6. Movimiento browniano como límite de la caminata

Ejercicio 3.21. Movimiento browniano como límite de la caminata

Sea $(S_t^{(N)})_{t\geq 0}$ la caminata aleatoria simple en $\mathbb{Z}$ reescalada: $S_t^{(N)} = \frac{X_{\lfloor Nt \rfloor}}{\sqrt{N}}$.
(a) Enuncie el principio de invariancia de Donsker: $S^{(N)} \to B$ en distribución (como procesos en $C[0,1]$), donde B es el movimiento browniano estándar.

El Teorema Central del Límite Funcional

Así como el Teorema Central del Límite (TCL) clásico nos dice que la suma de variables aleatorias converge a una distribución Normal en un *instante* de tiempo fijo, el **Teorema de Donsker** (o TCL Funcional) generaliza esto a *trayectorias completas*. Nos asegura que, al encoger los saltos espaciales por $\sqrt{N}$ y acelerar el tiempo por N, la trayectoria dentada de la caminata aleatoria converge a una trayectoria continua universal: el Movimiento Browniano.

Teorema 3.2. Principio de Invariancia de Donsker

Sea $X_1, X_2, \ldots$ una sucesión de variables aleatorias independientes e idénticamente distribuidas (i.i.d.) con media $E[X_i] = 0$ y varianza $\mathrm{Var}(X_i) = 1$. Definimos la suma parcial $S_n = \sum_{i=1}^{n} X_i$ con $S_0 = 0$.
Construimos el proceso estocástico continuo interpolado y reescalado para el intervalo temporal $t \in [0,1]$ como:

$$W^{(N)}(t) = \frac{S_{\lfloor Nt \rfloor}}{\sqrt{N}} + \frac{Nt - \lfloor Nt \rfloor}{\sqrt{N}} X_{\lfloor Nt \rfloor + 1}$$

(La interpolación lineal del segundo término se añade teóricamente para asegurar que las trayectorias sean estrictamente continuas y pertenezcan al espacio de funciones $C[0,1]$. Para fines asintóticos, la versión escalonada del enunciado es equivalente).
Entonces, conforme $N \to \infty$, la medida de probabilidad inducida por los procesos $W^{(N)}$ converge débilmente a la Medida de Wiener. Es decir, el proceso converge en distribución al Movimiento Browniano Estándar B:

$$W^{(N)} \xrightarrow{d} B \quad \text{en } C[0,1]$$

Propiedades del Proceso Límite (Movimiento Browniano Estándar B_t):

1. **Origen:** $B_0 = 0$ casi seguramente.
2. **Incrementos Independientes:** Para $0 \leq t_1 < t_2 \ldots < t_k$, los incrementos $B_{t_2} - B_{t_1}, \ldots, B_{t_k} - B_{t_{k-1}}$ son independientes.
3. **Incrementos Gaussianos Estacionarios:** Para cualquier $0 \leq s < t$, el incremento se distribuye normal con varianza igual al lapso de tiempo: $B_t - B_s \sim \mathcal{N}(0, t-s)$.
4. **Continuidad:** Sus trayectorias son continuas en casi todo punto t (pero analíticamente se demuestra que no son diferenciables en ninguna parte).

Ejercicio 3.22. Convergencia Asintótica y Teorema Central del Límite

Para $p = q = \frac{1}{2}$, calcule $E^0[S_n^2] = n$ y demuestre que $S_n/\sqrt{n} \to \mathcal{N}(0,1)$ usando el Teorema Central del Límite.

Cálculo y Límite. **1. Cálculo de la Esperanza al Cuadrado:**
Sea $S_n = \sum_{i=1}^n X_i$, donde X_i son los pasos de la caminata. Como es simétrica, cada paso toma valores en $\{-1, 1\}$ con probabilidad $1/2$. Calculamos la media y el segundo momento de un solo paso:

$$E[X_i] = (1)\left(\frac{1}{2}\right) + (-1)\left(\frac{1}{2}\right) = 0$$

$$E[X_i^2] = (1)^2\left(\frac{1}{2}\right) + (-1)^2\left(\frac{1}{2}\right) = 1$$

La varianza de la suma de variables independientes es la suma de las varianzas. Al tener media cero, $E[S_n^2] = \mathrm{Var}(S_n)$:

$$E^0[S_n^2] = \mathrm{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \mathrm{Var}(X_i) = \sum_{i=1}^n (E[X_i^2] - E[X_i]^2) = \sum_{i=1}^n 1 = \mathbf{n}$$

2. Teorema Central del Límite (TCL):
El TCL clásico establece que para variables i.i.d. con media μ y varianza σ^2 finitas, la suma estandarizada converge en distribución a una Normal estándar:

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1)$$

Sustituyendo nuestros parámetros teóricos $\mu = 0$ y $\sigma = 1$:

$$\frac{\mathbf{S_n}}{\sqrt{\mathbf{n}}} \xrightarrow{\mathbf{d}} \mathcal{N}(\mathbf{0}, \mathbf{1})$$

Esto demuestra que, en un instante fijo n suficientemente grande, la distribución espacial de la caminata es una campana de Gauss, coincidiendo exactamente con la distribución marginal del Movimiento Browniano. □

Ejercicio 3.23. Convergencia del Tiempo de Salida

Deduzca que $E^0[\tau_{-a,b}]/N \to ab$ cuando $N \to \infty$ (convergencia del tiempo de salida al tiempo de salida del browniano).

Deducción del Límite Espacio-Temporal. En el Ejercicio 3.1b, demostramos que para una caminata discreta simple en $\mathbb{Z}$, el tiempo esperado para salir del intervalo $[-A, B]$ es $E[\text{pasos}] = A \cdot B$.

Para aplicar el límite difusivo hacia el Movimiento Browniano, reescalamos el espacio por un factor de $\sqrt{N}$. Esto significa que las barreras continuas $-a$ y b corresponden físicamente a las barreras discretas equivalentes $A = a\sqrt{N}$ y $B = b\sqrt{N}$.

El número esperado de pasos discretos para alcanzar estas fronteras reescaladas es:

$$E^0[\text{pasos}] = A \cdot B = (a\sqrt{N})(b\sqrt{N}) = Nab$$

En la escala del Movimiento Browniano, el tiempo continuo t se define comprimiendo el número de pasos por un factor de N (es decir, el tiempo continuo es $t = \text{pasos}/N$). Dividimos la esperanza discreta entre N para obtener el límite continuo $\tau_{-a,b}$:

$$E^0[\tau_{-a,b}] = \lim_{N\to\infty} \frac{E^0[\text{pasos}]}{N} = \lim_{N\to\infty} \frac{Nab}{N} = \mathbf{ab}$$

Este límite coincide magistralmente con el resultado del Movimiento Browniano Estándar B_t, donde usando la martingala $B_t^2 - t$ y el Teorema de Paro Opcional, se concluye directamente que $E^0[\tau_{-a,b}] = ab$. $\square$

Ejercicio 3.24. Límite continuo de la probabilidad de ruina

¿Cómo se aproxima la probabilidad de ruina $u(x) = P^x(T_{\{N\}} < T_{\{0\}})$ en el límite continuo?

Aproximación Continua. Para la caminata discreta simétrica en el intervalo $[0, N]$, demostramos en el capítulo 1 que la probabilidad de ruina (ganar el juego) es estrictamente lineal:

$$u(x) = \frac{x}{N}$$

Para llevar esto al límite continuo (Movimiento Browniano en un intervalo espacial $[0, L]$), definimos la posición espacial continua como $y = x\Delta y$ y la frontera superior del intervalo como $L = N\Delta y$, donde $\Delta y \to 0$.

Multiplicando el numerador y el denominador de nuestra probabilidad discreta por el diferencial espacial Δy:

$$u(x) = \frac{x\Delta y}{N\Delta y} = \frac{y}{L}$$

En el límite continuo completo, el proceso estocástico converge al Movimiento Browniano B_t. Si iniciamos el proceso en $B_0 = y \in [0, L]$, la probabilidad de alcanzar la barrera superior L antes de tocar la barrera inferior 0 es idéntica a la fórmula límite:

$$\mathbf{P^y(T_L < T_0) = \frac{y}{L}}$$

Justificación teórica: En el espacio continuo, la probabilidad de salida ya no se rige por ecuaciones en diferencias, sino por la Ecuación de Laplace diferencial unidimensional $\Delta u = \frac{d^2u}{dy^2} = 0$. *Sus únicas soluciones son rectas de la forma* $u(y) = Ay + B$. *Evaluando las condiciones de frontera* $u(0) = 0$ *(ruina inferior) y* $u(L) = 1$ *(victoria superior), se recupera inevitablemente la misma proporción lineal* $u(y) = y/L$. □

4. Cadenas de Markov a tiempo continuo

4.1. Generador y semigruppo

Ejercicio 4.1. Generador y semigrupo

Sea $(Y_t)_{t\geq 0}$ un proceso de Markov a tiempo continuo en S con generador $\mathcal{A}$.
(a) Demuestre que $P_t f(x) = E^x[f(Y_t)]$ satisface la ecuación de Kolmogorov hacia atrás: $\partial_t P_t f = \mathcal{A} P_t f$.
(b) Escriba las ecuaciones de Kolmogorov hacia adelante para $p_t(x,y) = P^x(Y_t = y)$: $\partial_t p_t(\cdot, y) = p_t(\cdot, y)\mathcal{A}$.

El Generador Infinitesimal

En tiempo continuo, el sistema cambia en cada instante. El generador $\mathcal{A}$ describe la tasa de cambio instantánea en el tiempo $t = 0$, definido como $\mathcal{A}f = \lim_{h\downarrow 0} \frac{P_h f - f}{h}$. Las ecuaciones de Kolmogorov extienden este concepto para encontrar la tasa de cambio en cualquier tiempo $t > 0$. El truco central para ambas demostraciones es la propiedad de semigrupo (Chapman-Kolmogorov): avanzar un tiempo $t + h$ es equivalente a avanzar primero t y luego h, o viceversa ($P_{t+h} = P_h P_t = P_t P_h$).

Demostración (a): Ecuación de Kolmogorov Hacia Atrás. Iniciamos aplicando la definición formal de la derivada temporal al operador de transición P_t:

$$\partial_t P_t f = \lim_{h\downarrow 0} \frac{P_{t+h} f - P_t f}{h}$$

Aplicamos la propiedad de semigrupo separando el tiempo como un pequeño salto inicial h seguido del viaje principal t. Por tanto, $P_{t+h} = P_h P_t$. Sustituyendo esto en nuestro límite:

$$\partial_t P_t f = \lim_{h\downarrow 0} \frac{P_h(P_t f) - P_t f}{h}$$

Observemos la estructura del límite. Si definimos momentáneamente a la función interior como $g = P_t f$, la expresión se convierte en $\lim_{h\downarrow 0} \frac{P_h g - g}{h}$. Esta es exactamente la definición de la acción del generador $\mathcal{A}$ sobre la función g.

Evaluando el límite, obtenemos $\mathcal{A}g$. Regresando a nuestra notación original ($g = P_t f$), llegamos directamente al resultado:

$$\partial_t \mathbf{P_t f} = \mathcal{A}(\mathbf{P_t f})$$

Físicamente, condicionamos sobre el primer salto infinitesimal (por eso "hacia atrás", miramos al inicio del proceso) y la tasa está regida por $\mathcal{A}$ aplicado sobre el estado futuro. □

Demostración (b): Ecuación de Kolmogorov Hacia Adelante. Iniciamos nuevamente con el límite de la derivada temporal, pero esta vez aplicamos la propiedad de semigrupo invirtiendo el orden: el proceso viaja el tiempo largo t primero, y condicionamos sobre el último salto infinitesimal h. Es decir, $P_{t+h} = P_t P_h$.

$$\partial_t P_t f = \lim_{h \downarrow 0} \frac{P_{t+h} f - P_t f}{h} = \lim_{h \downarrow 0} \frac{P_t(P_h f) - P_t f}{h}$$

Dado que P_t es un operador lineal (es una esperanza matemática o una multiplicación matricial), podemos sacarlo fuera del límite (asumiendo las condiciones de regularidad necesarias para intercambiar límite e integral/suma):

$$\partial_t P_t f = P_t \left(\lim_{h \downarrow 0} \frac{P_h f - f}{h} \right)$$

Reconocemos el límite interior como el generador $\mathcal{A}$ aplicado a la función f:

$$\partial_t P_t f = P_t(\mathcal{A} f)$$

Para traducir esta ecuación de operadores a la notación de probabilidades puntuales $p_t(x, y)$, analizamos los elementos individuales como si fueran matrices. La ecuación matricial es $\partial_t P_t = P_t \mathcal{A}$. Evaluando la derivada para la entrada específica que va del estado inicial (implícito como un vector fila puntual) al estado final y, aplicamos el producto de la fila p_t por la matriz $\mathcal{A}$:

$$\partial_t p_t(\cdot, y) = \sum_{z \in S} p_t(\cdot, z) \mathcal{A}(z, y)$$

En forma vectorial, el vector de probabilidad evoluciona multiplicándose por la derecha con el generador:

$$\partial_{\mathbf{t}} \mathbf{p_t}(\cdot, \mathbf{y}) = \mathbf{p_t}(\cdot, \mathbf{y}) \mathcal{A}$$

□

Ejercicio 4.2. Exponencial de Matrices y Semigrupos

Demuestre que $P_t = e^{t\mathcal{A}}$ y que las matrices P_t forman un semigrupo estocástico.

La Exponencial Matricial

La exponencial de una matriz se define de la misma manera que en el cálculo escalar, utilizando su serie de Taylor: $e^{t\mathcal{A}} = \sum_{k=0}^{\infty} \frac{t^k \mathcal{A}^k}{k!}$. Esta serie converge absolutamente para cualquier matriz con norma finita.

Demostración (Solución y Semigrupo). **1. Solución de la Ecuación de Kolmogorov:**
Del inciso anterior sabemos que la matriz de transición satisface la ecuación diferencial matricial con la condición inicial de que en $t = 0$ no hay transición:

$$\frac{d}{dt}P_t = \mathcal{A}P_t, \quad P_0 = I$$

Proponemos como solución la exponencial de la matriz $P_t = e^{t\mathcal{A}}$. Derivando término a término la serie de Taylor respecto a t:

$$\frac{d}{dt}e^{t\mathcal{A}} = \frac{d}{dt}\sum_{k=0}^{\infty}\frac{t^k\mathcal{A}^k}{k!} = \sum_{k=1}^{\infty}\frac{kt^{k-1}\mathcal{A}^k}{k!} = \mathcal{A}\sum_{k=1}^{\infty}\frac{t^{k-1}\mathcal{A}^{k-1}}{(k-1)!} = \mathcal{A}e^{t\mathcal{A}}$$

Como cumple la ecuación diferencial y la condición inicial ($e^{0\mathcal{A}} = I$), por el teorema de existencia y unicidad, concluimos que $\mathbf{P_t} = \mathbf{e^{t\mathcal{A}}}$.

2. Propiedad de Semigrupo:
Un semigrupo de operadores matemáticos debe cumplir la identidad $P_0 = I$ y la propiedad de composición $P_{t+s} = P_tP_s$. Usando nuestra representación exponencial y las leyes de los exponentes (las cuales son válidas porque toda matriz conmuta consigo misma, $\mathcal{A}\mathcal{A} = \mathcal{A}\mathcal{A}$):

$$P_{t+s} = e^{(t+s)\mathcal{A}} = e^{t\mathcal{A}+s\mathcal{A}} = e^{t\mathcal{A}}e^{s\mathcal{A}} = \mathbf{P_tP_s}$$

3. Propiedad Estocástica:
Para que las matrices de transición sean estocásticas, la suma de las probabilidades en cualquier fila debe ser 1 ($P_t\mathbf{1} = \mathbf{1}$, donde $\mathbf{1}$ es el vector columna de puros unos). Por propiedades del generador infinitesimal, sabemos que las filas de $\mathcal{A}$ suman cero ($\mathcal{A}\mathbf{1} = \mathbf{0}$). Evaluando la serie de la exponencial multiplicada por $\mathbf{1}$:

$$P_t\mathbf{1} = \left(I + t\mathcal{A} + \frac{t^2}{2}\mathcal{A}^2 + \dots\right)\mathbf{1} = I\mathbf{1} + t(\mathcal{A}\mathbf{1}) + \frac{t^2}{2}\mathcal{A}(\mathcal{A}\mathbf{1}) + \dots$$

Sustituyendo el vector nulo:

$$P_t\mathbf{1} = \mathbf{1} + \mathbf{0} + \mathbf{0} + \dots = \mathbf{1}$$

Junto con la no-negatividad de sus entradas, queda demostrado que la familia de matrices $(P_t)_{t\geq 0}$ forma un **semigrupo estocástico**. □

Ejercicio 4.3. Invarianza en la Medida Estacionaria

Muestre que si π es estacionaria, entonces $E^\pi[f(Y_t)] = E^\pi[f(Y_0)]$ para todo $t \geq 0$.

Demostración de Invarianza del Valor Esperado. Por definición, si π es la distribución estacionaria de una cadena a tiempo continuo, se cumple la ecuación de balance global $\pi\mathcal{A} = \mathbf{0}$. Multiplicando la exponencial matricial $P_t = e^{t\mathcal{A}}$ por la izquierda por el vector fila π:

$$\pi P_t = \pi \left(I + t\mathcal{A} + \frac{t^2}{2}\mathcal{A}^2 + \dots \right) = \pi + t(\pi\mathcal{A}) + \frac{t^2}{2}(\pi\mathcal{A})\mathcal{A} + \dots$$

Como $\pi\mathcal{A} = \mathbf{0}$, todos los términos de la serie a partir del segundo se anulan por completo, resultando en:

$$\pi P_t = \pi$$

Esto significa que la distribución no cambia en el tiempo. Si iniciamos el proceso muestreando desde la distribución π, la probabilidad marginal de encontrarlo en cualquier estado x a tiempo t sigue siendo $\pi(x)$.

Calculamos la esperanza del proceso a un tiempo t asumiendo que la distribución inicial de Y_0 es π:

$$E^\pi[f(Y_t)] = \sum_{x \in S} \pi(x) E^x[f(Y_t)]$$

Por definición del operador de transición, $E^x[f(Y_t)] = (P_t f)(x)$:

$$E^\pi[f(Y_t)] = \sum_{x \in S} \pi(x)(P_t f)(x) = \pi P_t f$$

Usando la propiedad de estacionariedad $\pi P_t = \pi$ que acabamos de derivar:

$$\pi P_t f = \pi f = \sum_{x \in S} \pi(x) f(x)$$

Por otro lado, evaluando la esperanza en el tiempo $t = 0$, sabemos directamente que $Y_0 \sim \pi$:

$$E^\pi[f(Y_0)] = \sum_{x \in S} \pi(x) f(x)$$

Igualando ambas expresiones, llegamos a nuestra conclusión:

$$\mathbf{E}^\pi[\mathbf{f}(\mathbf{Y_t})] = \mathbf{E}^\pi[\mathbf{f}(\mathbf{Y_0})]$$

Físicamente, esto garantiza que cuando el sistema termodinámico o estocástico ha alcanzado su estado de equilibrio, el valor esperado de cualquier función observable f permanece constante para toda la eternidad.

□

4.2. Proceso de Poisson

Ejercicio 4.4. Proceso de Poisson

Sea $(N_t)_{t\geq 0}$ un proceso de Poisson de tasa $\lambda > 0$.
(a) Escriba el generador $\mathcal{A}f(n) = \lambda[f(n+1) - f(n)]$ y verifique que $M_t = N_t - \lambda t$ es martingala.
(b) Demuestre que $M_t^2 - \lambda t$ también es martingala y use el teorema de paro para calcular $E^0[T_n]$ y $\mathrm{Var}^0(T_n)$, donde $T_n = \text{mín}\{t : N_t = n\}$.

Demostración (a): Generador y Martingala Compensada. **1. Generador Infinitesimal:**
Por definición, para un pequeño incremento de tiempo h, la probabilidad de que el proceso de Poisson dé exactamente un salto es $\lambda h + o(h)$, la de que no dé ninguno es $1 - \lambda h + o(h)$, y la de múltiples saltos es $o(h)$. Evaluamos la definición del generador:

$$\mathcal{A}f(n) = \lim_{h\downarrow 0} \frac{E^n[f(N_h)] - f(n)}{h}$$

Condicionando a los posibles saltos en el intervalo h:

$$\mathcal{A}f(n) = \lim_{h\downarrow 0} \frac{(1-\lambda h)f(n) + (\lambda h)f(n+1) - f(n)}{h}$$

$$\mathcal{A}f(n) = \lim_{h\downarrow 0} \frac{-\lambda h f(n) + \lambda h f(n+1)}{h} = \lambda[\mathbf{f(n+1) - f(n)}]$$

2. Martingala Compensada (M_t):
Para verificar que $M_t = N_t - \lambda t$ es martingala, calculamos su esperanza condicional hacia el futuro $t+s$:

$$E[M_{t+s} \mid \mathcal{F}_t] = E[N_{t+s} - \lambda(t+s) \mid \mathcal{F}_t]$$

Reescribimos N_{t+s} como $N_t + (N_{t+s} - N_t)$ usando la propiedad de incrementos independientes:

$$= E[N_t + (N_{t+s} - N_t) - \lambda t - \lambda s \mid \mathcal{F}_t]$$

Como N_t es medible respecto a $\mathcal{F}_t$, sale de la esperanza. El incremento $N_{t+s} - N_t$ es independiente del pasado y distribuye Poisson con media λs:

$$= N_t - \lambda t - \lambda s + E[N_{t+s} - N_t] = M_t - \lambda s + \lambda s = \mathbf{M_t}$$

Se comprueba que M_t es martingala. □

Demostración (b): Varianza y Teorema de Paro. **1. Verificación de la segunda martingala:** Calculamos la esperanza condicional de $M_{t+s}^2 - \lambda(t+s)$:

$$E[M_{t+s}^2 - \lambda(t+s) \mid \mathcal{F}_t] = E[(M_t + (M_{t+s} - M_t))^2 \mid \mathcal{F}_t] - \lambda(t+s)$$

Desarrollamos el binomio al cuadrado:

$$= E[M_t^2 + 2M_t(M_{t+s} - M_t) + (M_{t+s} - M_t)^2 \mid \mathcal{F}_t] - \lambda t - \lambda s$$

Por linealidad, analizamos cada término. El término cruzado se anula porque $E[M_{t+s} - M_t] = 0$. El último término es la varianza del incremento del proceso de Poisson, que sabemos es igual a su media λs:

$$E[(M_{t+s} - M_t)^2] = \mathrm{Var}(N_{t+s} - N_t - \lambda s) = \mathrm{Var}(N_{t+s} - N_t) = \lambda s$$

Sustituyendo todo de regreso:

$$= M_t^2 + 0 + \lambda s - \lambda t - \lambda s = \mathbf{M_t^2 - \lambda t}$$

Se comprueba que también es martingala.

2. Tiempo Esperado $E^0[T_n]$:
Aplicamos el Teorema de Paro Opcional a la primera martingala M_t con el tiempo de paro T_n (tiempo de llegada al estado n). Sabemos que exactamente en ese instante, el proceso vale $N_{T_n} = n$:

$$E^0[M_{T_n}] = M_0 = 0 \implies E^0[N_{T_n} - \lambda T_n] = 0$$

$$E^0[n - \lambda T_n] = 0 \implies n - \lambda E^0[T_n] = 0$$

$$\mathbf{E^0[T_n] = \frac{n}{\lambda}}$$

(Lógico: si llega a 1 cliente cada $1/\lambda$ minutos, para n clientes toma n/λ minutos).

3. Varianza del Tiempo $\mathbf{Var}^0(T_n)$:
Aplicamos el Teorema de Paro Opcional a la segunda martingala:

$$E^0[M_{T_n}^2 - \lambda T_n] = 0 \implies E^0[(N_{T_n} - \lambda T_n)^2] = \lambda E^0[T_n]$$

Sustituimos $N_{T_n} = n$ en el lado izquierdo, y $E^0[T_n] = n/\lambda$ en el lado derecho:

$$E^0[(n - \lambda T_n)^2] = \lambda \left(\frac{n}{\lambda}\right) = n$$

Factorizamos λ^2 dentro de la esperanza del lado izquierdo:

$$\lambda^2 E^0 \left[\left(\frac{n}{\lambda} - T_n\right)^2\right] = n$$

Reconocemos que el término dentro de la esperanza es exactamente la definición de la varianza $\mathrm{Var}(T_n) = E[(E[T_n] - T_n)^2]$:

$$\lambda^2 \mathrm{Var}^0(T_n) = n$$

$$\mathbf{Var^0(T_n) = \frac{n}{\lambda^2}}$$

(Esto confirma que el tiempo de espera T_n se comporta como una suma de n exponenciales independientes, es decir, una distribución Gamma). □

Ejercicio 4.5. Suma de Procesos y Distribución Condicional

Sean $N_t^{(1)}, N_t^{(2)}$ procesos de Poisson independientes de tasas λ_1, λ_2. Demuestre que su suma es Poisson de tasa $\lambda_1 + \lambda_2$ y calcule la distribución de $N_t^{(1)}$ dado $\{N_t^{(1)} + N_t^{(2)} = n\}$.

Demostración y Cálculo. **1. Suma de Procesos de Poisson:**
Sean $N_t^{(1)} \sim \text{Poisson}(\lambda_1 t)$ y $N_t^{(2)} \sim \text{Poisson}(\lambda_2 t)$ variables independientes. Usaremos la Función Generadora de Momentos (FGM) para encontrar la distribución de su suma $N_t = N_t^{(1)} + N_t^{(2)}$. La FGM de una variable Poisson de parámetro μ es $M(s) = \exp(\mu(e^s - 1))$. Por la independencia de los procesos, la FGM de la suma es el producto de sus respectivas FGM:

$$M_{N_t}(s) = E[e^{s(N_t^{(1)} + N_t^{(2)})}] = E[e^{sN_t^{(1)}}]E[e^{sN_t^{(2)}}]$$

$$M_{N_t}(s) = \exp(\lambda_1 t(e^s - 1)) \cdot \exp(\lambda_2 t(e^s - 1)) = \exp((\lambda_1 + \lambda_2)t(e^s - 1))$$

Esta es exactamente la FGM de una variable aleatoria Poisson con parámetro $(\lambda_1 + \lambda_2)t$. Por el teorema de unicidad de la FGM, concluimos que la suma es un proceso de Poisson de tasa $\lambda_1 + \lambda_2$.

2. Distribución Condicional (Filtrado Espacial):
Queremos calcular $P(N_t^{(1)} = k \mid N_t^{(1)} + N_t^{(2)} = n)$ para $0 \leq k \leq n$. Aplicando la definición de probabilidad condicional:

$$P(N_t^{(1)} = k \mid N_t = n) = \frac{P(N_t^{(1)} = k \text{ y } N_t^{(2)} = n - k)}{P(N_t = n)}$$

Por independencia en el numerador, factorizamos las probabilidades y sustituimos las fórmulas clásicas de Poisson:

$$= \frac{\left(e^{-\lambda_1 t} \frac{(\lambda_1 t)^k}{k!}\right)\left(e^{-\lambda_2 t} \frac{(\lambda_2 t)^{n-k}}{(n-k)!}\right)}{e^{-(\lambda_1+\lambda_2)t} \frac{((\lambda_1+\lambda_2)t)^n}{n!}}$$

Observamos que los términos exponenciales se cancelan perfectamente en el numerador y denominador ($e^{-\lambda_1 t} e^{-\lambda_2 t} = e^{-(\lambda_1+\lambda_2)t}$). Agrupamos los factoriales y las potencias de t (que también desaparecen al tener $t^k t^{n-k}/t^n = 1$):

$$= \frac{n!}{k!(n-k)!} \frac{\lambda_1^k \lambda_2^{n-k}}{(\lambda_1 + \lambda_2)^n}$$

Reconocemos el coeficiente binomial $\binom{n}{k}$ y separamos la fracción de las tasas para los términos a la potencia k y $n - k$:

$$= \binom{n}{k} \left(\frac{\lambda_1}{\lambda_1 + \lambda_2}\right)^k \left(\frac{\lambda_2}{\lambda_1 + \lambda_2}\right)^{n-k}$$

Conclusión: La distribución condicional es exactamente una **Binomial** $\mathcal{B}(n, p)$ donde el número de .enSayos.es n (el total de eventos ocurridos) y la probabilidad de éxito de que un evento provenga del primer proceso es directamente proporcional a su tasa: $\mathbf{p} = \frac{\lambda_1}{\lambda_1 + \lambda_2}$. □

Ejercicio 4.6. Densidad Conjunta de Tiempos de Llegada

Calcule la densidad conjunta de los primeros dos tiempos de llegada (T_1, T_2).

Cálculo mediante Tiempos de Inter-llegada. Sea T_1 el tiempo de la primera llegada y $S_2 = T_2 - T_1$ el tiempo que transcurre entre la primera y la segunda llegada. Por las propiedades fundamentales del proceso de Poisson, sabemos que los tiempos de inter-llegada son variables aleatorias continuas, independientes y ambas siguen una distribución Exponencial de parámetro λ.

La densidad marginal de T_1 es $f_{T_1}(t_1) = \lambda e^{-\lambda t_1}$ para $t_1 > 0$.
La densidad marginal de S_2 es $f_{S_2}(s_2) = \lambda e^{-\lambda s_2}$ para $s_2 > 0$.

Dado que los incrementos son independientes, su densidad conjunta es simplemente el producto de sus densidades marginales:

$$f_{T_1,S_2}(t_1, s_2) = f_{T_1}(t_1) f_{S_2}(s_2) = (\lambda e^{-\lambda t_1})(\lambda e^{-\lambda s_2}) = \lambda^2 e^{-\lambda(t_1+s_2)}$$

Queremos encontrar la densidad conjunta directa de (T_1, T_2). Para ello, realizamos un cambio de variable multivariable. El mapeo es $T_1 = t_1$ y $T_2 = t_1 + s_2$. Despejando obtenemos la inversa: $t_1 = T_1$ y $s_2 = T_2 - T_1$. El determinante de la matriz Jacobiana de esta transformación lineal es exactamente 1, por lo que la función de densidad se preserva al sustituir directamente las variables.

Sustituimos la equivalencia $s_2 = t_2 - t_1$ en nuestra función conjunta original:

$$f_{T_1,T_2}(t_1, t_2) = \lambda^2 e^{-\lambda(t_1+(t_2-t_1))}$$

Al simplificar el exponente, el término t_1 desaparece misteriosamente de la ecuación:

$$\mathbf{f_{T_1,T_2}(t_1, t_2) = \lambda^2 e^{-\lambda t_2}}$$

Dominio de validez: Es crucial notar que esta densidad solo existe en la región triangular donde los eventos ocurren en orden cronológico estricto, es decir, para $\mathbf{0 < t_1 < t_2 < \infty}$. Fuera de esta región, la densidad es cero. □

4.3. Proceso de nacimiento–muerte con absorción

Ejercicio 4.7. Proceso de nacimiento-muerte con absorción

Sea (Y_t) en $\{0, \ldots, M\}$ con $q(x, x+1) = \lambda$, $q(x, x-1) = \mu$ para $1 \leq x \leq M-1$, $q(0,1) = \lambda$, y M absorbente.
(a) Derive $\mathcal{A}v = -1$ para $v(x) = E^x[T_M]$ y escriba las condiciones de frontera.
(b) Resuelva para $\lambda \neq \mu$:

$$v(x) = \frac{M-x}{\lambda-\mu} + \frac{\mu}{(\lambda-\mu)^2}\left[\left(\frac{\mu}{\lambda}\right)^M - \left(\frac{\mu}{\lambda}\right)^x\right]$$

Verifique $v(0) - v(1) = 1/\lambda$.

Ecuación de Poisson en Tiempo Continuo

En tiempo discreto, el tiempo de paro esperado satisface $v(x) = 1 + \sum_y p(x,y)v(y)$, que es equivalente a $(P-I)v = -1$. En tiempo continuo, el equivalente del operador $(P-I)$ es el generador infinitesimal $\mathcal{A}$. Por lo tanto, esperamos que la ecuación diferencial equivalente sea $\mathcal{A}v = -1$.

Demostración (a): Derivación de la ecuación de Poisson. **1. Condicionamiento sobre el primer salto:**
Si el proceso está en el estado x (con $1 \leq x \leq M-1$), el tiempo que transcurre antes de dar el próximo salto sigue una distribución Exponencial con tasa total $q_x = \lambda+\mu$. La esperanza de este tiempo de espera es $1/(\lambda+\mu)$. Al saltar, el proceso va al estado $x+1$ con probabilidad $\lambda/(\lambda+\mu)$ o al estado $x-1$ con probabilidad $\mu/(\lambda+\mu)$.

Por la propiedad de Markov, el tiempo total esperado para llegar a M es el tiempo de espera inicial más el tiempo esperado desde el nuevo estado:

$$v(x) = \frac{1}{\lambda+\mu} + \left(\frac{\lambda}{\lambda+\mu}\right)v(x+1) + \left(\frac{\mu}{\lambda+\mu}\right)v(x-1)$$

2. Transformación al Generador Infinitesimal:
Multiplicamos toda la ecuación por la tasa de salida $(\lambda+\mu)$:

$$(\lambda+\mu)v(x) = 1 + \lambda v(x+1) + \mu v(x-1)$$

Reagrupando los términos para formar diferencias:

$$\lambda v(x+1) - \lambda v(x) + \mu v(x-1) - \mu v(x) = -1$$

$$\lambda[v(x+1) - v(x)] + \mu[v(x-1) - v(x)] = -1$$

Por definición, la acción del generador $\mathcal{A}$ sobre una función v se calcula como $\mathcal{A}v(x) = \sum_{y\neq x} q(x,y)[v(y) - v(x)]$. Aplicando esto a nuestras tasas:

$$\mathcal{A}v(x) = q(x,x+1)[v(x+1) - v(x)] + q(x,x-1)[v(x-1) - v(x)]$$

$$\mathcal{A}v(x) = \lambda[v(x+1) - v(x)] + \mu[v(x-1) - v(x)]$$

Igualando con nuestro resultado algebraico anterior, concluimos que para $1 \leq x \leq M-1$:

$$\mathcal{A}\mathbf{v}(\mathbf{x}) = -\mathbf{1}$$

3. Condiciones de frontera:

- En el borde absorbente $x = M$, el proceso ya llegó, por lo que el tiempo es cero: $\mathbf{v}(\mathbf{M}) = \mathbf{0}$.
- En el borde reflejante $x = 0$, el único salto posible es hacia 1 con tasa λ. Repitiendo el análisis: $v(0) = \frac{1}{\lambda} + 1 \cdot v(1)$. Multiplicando por λ y reordenando: $\lambda[v(1) - v(0)] = -1 \implies \mathcal{A}\mathbf{v}(\mathbf{0}) = -\mathbf{1}$.

□

Demostración (b): Verificación Algebraica. Se nos proporciona la fórmula general del tiempo esperado para un sistema asimétrico ($\lambda \neq \mu$):

$$v(x) = \frac{M-x}{\lambda-\mu} + \frac{\mu}{(\lambda-\mu)^2}\left[\left(\frac{\mu}{\lambda}\right)^M - \left(\frac{\mu}{\lambda}\right)^x\right]$$

Se nos pide verificar que la condición de frontera en $x = 0$ se cumple, es decir, que $v(0) - v(1) = 1/\lambda$. Evaluamos la función en estos dos puntos.

Para $x = 0$:

$$v(0) = \frac{M}{\lambda-\mu} + \frac{\mu}{(\lambda-\mu)^2}\left[\left(\frac{\mu}{\lambda}\right)^M - 1\right]$$

Para $x = 1$:

$$v(1) = \frac{M-1}{\lambda-\mu} + \frac{\mu}{(\lambda-\mu)^2}\left[\left(\frac{\mu}{\lambda}\right)^M - \frac{\mu}{\lambda}\right]$$

Calculamos la diferencia $v(0) - v(1)$ restando término a término:

$$v(0) - v(1) = \left(\frac{M}{\lambda-\mu} - \frac{M-1}{\lambda-\mu}\right) + \frac{\mu}{(\lambda-\mu)^2}\left[\left(\left(\frac{\mu}{\lambda}\right)^M - 1\right) - \left(\left(\frac{\mu}{\lambda}\right)^M - \frac{\mu}{\lambda}\right)\right]$$

En el primer bloque, M se cancela y nos queda $1/(\lambda - \mu)$. En el segundo bloque (los corchetes), el término de la potencia M se cancela:

$$v(0) - v(1) = \frac{1}{\lambda-\mu} + \frac{\mu}{(\lambda-\mu)^2}\left[\frac{\mu}{\lambda} - 1\right]$$

Simplificamos la expresión dentro de los corchetes buscando un denominador común:

$$\frac{\mu}{\lambda} - 1 = \frac{\mu-\lambda}{\lambda}$$

Sustituimos esto de regreso en nuestra ecuación:

$$v(0) - v(1) = \frac{1}{\lambda-\mu} + \frac{\mu}{(\lambda-\mu)^2}\left[\frac{\mu-\lambda}{\lambda}\right]$$

Reconocemos que $(\mu - \lambda) = -(\lambda - \mu)$. Esto nos permite cancelar uno de los factores del denominador al cuadrado:

$$v(0) - v(1) = \frac{1}{\lambda-\mu} - \frac{\mu}{\lambda(\lambda-\mu)}$$

Factorizamos $1/(\lambda - \mu)$ de ambos términos:

$$v(0) - v(1) = \frac{1}{\lambda-\mu}\left[1 - \frac{\mu}{\lambda}\right]$$

Volvemos a buscar un denominador común dentro de los corchetes:

$$1 - \frac{\mu}{\lambda} = \frac{\lambda-\mu}{\lambda}$$

Multiplicamos ambas fracciones:

$$v(0) - v(1) = \left(\frac{1}{\lambda-\mu}\right)\left(\frac{\lambda-\mu}{\lambda}\right)$$

Los términos $(\lambda - \mu)$ se cancelan perfectamente en el numerador y denominador, resultando en:

$$\mathbf{v(0) - v(1) = \frac{1}{\lambda}}$$

Queda analíticamente verificado que la solución propuesta satisface la condición de frontera en el origen, la cual surge naturalmente de la ecuación del generador $\mathcal{A}v(0) = -1$. □

Ejercicio 4.8. Caso Simétrico (Equilibrio de Tasas)

Resuelva para $\lambda = \mu$: $v(x) = (M(M+1) - x(x+1))/(2\lambda)$.

Resolución de la Ecuación en Diferencias. Si $\lambda = \mu$, la ecuación de Poisson del inciso (a), $\lambda[v(x+1) - v(x)] + \mu[v(x-1) - v(x)] = -1$, se simplifica dividiendo y factorizando λ:

$$\lambda[v(x+1) - 2v(x) + v(x-1)] = -1$$

$$v(x+1) - 2v(x) + v(x-1) = -\frac{1}{\lambda}$$

Esta es una ecuación en diferencias lineal no homogénea de segundo orden.

- **Solución Homogénea:** Las raíces de la ecuación característica para coeficientes $(1, -2, 1)$ son una raíz doble en $r = 1$. Por lo tanto, la solución homogénea es una línea recta: $v_h(x) = Ax + B$.
- **Solución Particular:** Como el lado derecho es una constante y la solución homogénea ya contiene a las constantes y a x, proponemos una solución particular de la forma $v_p(x) = Cx^2$. Sustituyendo en la ecuación:

  $$C(x+1)^2 - 2Cx^2 + C(x-1)^2 = C(x^2 + 2x + 1 - 2x^2 + x^2 - 2x + 1) = 2C$$

  Igualando con el lado derecho: $2C = -1/\lambda \implies C = -1/(2\lambda)$.

La solución general es la suma de ambas:

$$v(x) = Ax + B - \frac{x^2}{2\lambda}$$

Aplicamos nuestras condiciones de frontera del inciso (a): 1. Para $x = 0$, la condición de reflexión $\mathcal{A}v(0) = -1$ dictaba que $v(1) - v(0) = -1/\lambda$. Evaluamos nuestra función: $v(0) = B$ y $v(1) = A + B - 1/(2\lambda)$. Sustituimos en la condición:

$$(A + B - \frac{1}{2\lambda}) - B = -\frac{1}{\lambda} \implies A = -\frac{1}{\lambda} + \frac{1}{2\lambda} = -\frac{1}{2\lambda}$$

Actualizamos la solución general:

$$v(x) = B - \frac{x}{2\lambda} - \frac{x^2}{2\lambda} = B - \frac{x(x+1)}{2\lambda}$$

2. Para $x = M$, el borde absorbente dicta que $v(M) = 0$.

$$0 = B - \frac{M(M+1)}{2\lambda} \implies B = \frac{M(M+1)}{2\lambda}$$

Sustituyendo nuestra constante B final, llegamos exactamente a la fórmula solicitada:

$$\mathbf{v(x) = \frac{M(M+1) - x(x+1)}{2\lambda}}$$

□

Ejercicio 4.9. Límite Asintótico y Velocidad de Deriva

Calcule $\lim_{M\to\infty} v(0)/M$ para $\lambda > \mu$ e interprete en términos de la velocidad del proceso.

Cálculo del Límite e Interpretación Física. Utilizamos la solución general para el caso asimétrico deducida en el inciso (b), evaluada en el origen $x = 0$:

$$v(0) = \frac{M}{\lambda - \mu} + \frac{\mu}{(\lambda - \mu)^2}\left[\left(\frac{\mu}{\lambda}\right)^M - 1\right]$$

Dividimos toda la expresión entre M para analizar la proporción asintótica:

$$\frac{v(0)}{M} = \frac{1}{\lambda - \mu} + \frac{\mu}{M(\lambda - \mu)^2}\left[\left(\frac{\mu}{\lambda}\right)^M - 1\right]$$

Dado que $\lambda > \mu$ (nacimientos superan a las muertes), la fracción base es menor a uno: $\frac{\mu}{\lambda} < 1$. Por lo tanto, al tomar el límite cuando $M \to \infty$:

- La potencia geométrica decae a cero: $\left(\frac{\mu}{\lambda}\right)^M \to 0$.
- El segundo gran término contiene a M en el denominador y una constante entre los corchetes $(0 - 1 = -1)$, por lo que todo ese bloque tiende a cero: $\frac{\text{constante}}{M} \to 0$.

Nos quedamos únicamente con el primer término, el cual es independiente de M:

$$\lim_{\mathbf{M}\to\infty} \frac{\mathbf{v(0)}}{\mathbf{M}} = \frac{\mathbf{1}}{\lambda - \mu}$$

Interpretación en términos de velocidad (Drift):
Recordemos la fórmula básica de cinemática: Tiempo $= \frac{\text{Distancia}}{\text{Velocidad}}$. Aquí, $v(0)$ es el Tiempo esperado total, y M es la Distancia a recorrer desde el origen. Por lo tanto, el cociente $v(0)/M$ tiene unidades de *inverso de velocidad*. Si invertimos nuestro límite, obtenemos la velocidad neta del proceso estocástico a nivel macroscópico:

$$\text{Velocidad Efectiva} \approx \frac{M}{v(0)} = \lambda - \mu$$

Físicamente, esto significa que cuando la meta está infinitamente lejos, las fluctuaciones aleatorias locales (ruido") se promedian y dejan de importar. El proceso se comporta como un fluido determinista que avanza hacia la derecha con una velocidad constante exactamente igual a la diferencia entre la tasa de avance (λ) y la tasa de retroceso (μ). □

4.4. Ecuaciones de Kolmogorov hacia adelante

Ejercicio 4.10. Ecuaciones de Kolmogorov hacia adelante

Para el proceso del Ejercicio 4.3, sea $p_t(y) = P^0(Y_t = y)$.
(a) Escriba el sistema completo de ecuaciones hacia adelante para $p_t(y), y \in \{0, \ldots, M\}$.
(b) Escriba explícitamente $p_t'(0), p_t'(1)$ y $p_t'(M)$.

Balance de Probabilidad (Ecuación Maestra)

La ecuación de Kolmogorov hacia adelante, en su forma de sumatoria, se expresa como:

$$\frac{d}{dt}p_t(y) = \sum_{x \neq y} p_t(x)q(x,y) - p_t(y) \sum_{x \neq y} q(y,x)$$

Conceptualmente, la tasa de cambio de la probabilidad en el estado y es igual al flujo de probabilidad que **entra** desde los estados vecinos x, menos el flujo de probabilidad que **sale** de y hacia otros estados.

Solución (a): Sistema general hacia adelante. Para un estado interior $y \in \{1, 2, \ldots, M-1\}$, el proceso solo puede recibir probabilidad de sus vecinos inmediatos $y-1$ (mediante un nacimiento con tasa λ) y $y+1$ (mediante una muerte con tasa μ). De igual manera, la probabilidad solo puede escapar de y hacia $y+1$ (tasa λ) o hacia $y-1$ (tasa μ).

Aplicando la ecuación de balance:

- **Flujo entrante (Inflow):** $p_t(y-1)\lambda + p_t(y+1)\mu$
- **Flujo saliente (Outflow):** $p_t(y)(\lambda + \mu)$

Agrupando esto, el sistema completo de ecuaciones diferenciales para los estados interiores es:

$$\mathbf{p_t'(y) = \lambda p_t(y-1) + \mu p_t(y+1) - (\lambda + \mu) p_t(y) \quad \text{para } 1 \leq y \leq M-1}$$

□

Solución (b): Casos de Frontera. Evaluamos los tres casos específicos que se nos piden, teniendo especial cuidado con las condiciones de frontera definidas en el Ejercicio 4.3.

1. Para la frontera reflectante $y = 0$:

El estado 0 solo puede recibir probabilidad desde el estado 1 (muerte con tasa μ). Solo puede perder probabilidad hacia el estado 1 (nacimiento con tasa λ). No hay transiciones desde o hacia -1.

$$\mathbf{p_t'(0) = \mu p_t(1) - \lambda p_t(0)}$$

2. Para el estado $y = 1$:

Este es un estado interior regular, por lo que aplicamos directamente la fórmula general que dedujimos en el inciso (a), sustituyendo $y = 1$:

$$\mathbf{p_t'(1) = \lambda p_t(0) + \mu p_t(2) - (\lambda + \mu) p_t(1)}$$

3. Para la frontera absorbente $y = M$:

Al ser un estado absorbente, una vez que la cadena llega a M, se queda ahí para siempre. La tasa de salida es estrictamente cero ($\sum q(M, x) = 0$). Solo recibe probabilidad del estado anterior $M - 1$ (nacimiento con tasa λ). Por lo tanto, su derivada es puramente positiva (la probabilidad de absorción crece monótonamente):

$$\mathbf{p_t'(M) = \lambda p_t(M - 1)}$$

□

Ejercicio 4.11. Formulación Matricial y Absorción

Reformule como $\mathbf{p}'(t) = \mathbf{p}(t)Q$ e identifique la matriz Q. Argumente que $p_t(M) \to 1$ cuando $t \to \infty$.

Formulación Matricial y Límite. **1. Identificación de la matriz Q:**
Si definimos el vector de probabilidades como un vector fila $\mathbf{p}(t) = [p_t(0), p_t(1), \ldots, p_t(M)]$, el sistema de ecuaciones diferenciales deducido en los incisos (a) y (b) se puede escribir compactamente como la multiplicación de este vector por la matriz generadora Q.

La matriz Q de tamaño $(M+1) \times (M+1)$ contiene las tasas de transición, donde el elemento q_{ij} es la tasa para ir de i a j, y los elementos de la diagonal son estrictamente $q_{ii} = -\sum_{j \neq i} q_{ij}$. Evaluando nuestras tasas de nacimiento y muerte, la matriz resulta ser tridiagonal:

$$Q = \begin{pmatrix} -\lambda & \lambda & 0 & 0 & \ldots & 0 & 0 \\ \mu & -(\lambda+\mu) & \lambda & 0 & \ldots & 0 & 0 \\ 0 & \mu & -(\lambda+\mu) & \lambda & \ldots & 0 & 0 \\ \vdots & \vdots & \ddots & \ddots & \ddots & \vdots & \vdots \\ 0 & 0 & \ldots & \mu & -(\lambda+\mu) & \lambda & 0 \\ 0 & 0 & \ldots & 0 & \mu & -(\lambda+\mu) & \lambda \\ 0 & 0 & \ldots & 0 & 0 & 0 & 0 \end{pmatrix}$$

(Notemos la importancia de la última fila: son puros ceros porque una vez en M, no hay transiciones de salida. Es una trampa perfecta).

2. Argumento de Absorción asintótica:
Dado que $\lambda > 0$, existe un camino de probabilidad estrictamente positiva para llegar desde cualquier estado $x < M$ hasta M (basta con una racha ininterrumpida de $M - x$ nacimientos). En teoría de Cadenas de Markov, esto significa que todos los estados en $\{0, \ldots, M-1\}$ son **transitorios**, y el estado M es el único estado **recurrente**. Por conservación de la masa, la probabilidad fluye continuamente hacia M y, al ser una trampa con tasa de salida nula, nunca regresa. Conforme el tiempo se extiende al infinito, toda la probabilidad del sistema se acumulará obligatoriamente en ese sumidero:

$$\lim_{\mathbf{t} \to \infty} \mathbf{p_t(M) = 1}$$

□

Ejercicio 4.12. Espectro de la Matriz y Velocidad de Absorción

Explique por qué el espectro de la submatriz de Q en $\{0, \ldots, M-1\}$ determina la velocidad de absorción.

Explicación Espectral. Sea Q_0 la submatriz principal de tamaño $M \times M$ que resulta de eliminar la fila y columna correspondientes al estado absorbente M. Esta matriz "sub-estocásticarige exclusivamente la evolución de la probabilidad en los estados transitorios:

$$\mathbf{p}'_{tr}(t) = \mathbf{p}_{tr}(t)Q_0$$

La solución analítica estricta a este sistema es la exponencial matricial:

$$\mathbf{p}_{tr}(t) = \mathbf{p}_{tr}(0)e^{tQ_0}$$

La "velocidad de absorción"no es otra cosa que el ritmo al cual la masa de probabilidad abandona los estados transitorios para caer en M. La probabilidad de no haber sido absorbido al tiempo t depende directamente del decaimiento de la matriz e^{tQ_0}.

Al aplicar la descomposición espectral, sabemos que el comportamiento asintótico de la exponencial matricial está dictado por las exponenciales de sus eigenvalores (espectro). Dado que Q_0 rige un conjunto de estados puramente transitorios hacia una absorción segura, por el Teorema de Perron-Frobenius, todos los eigenvalores de Q_0 tienen una **parte real estrictamente negativa**.

Sea γ_1 el eigenvalor dominante de Q_0 (aquel con la parte real negativa más cercana a cero). La suma exponencial estará dominada por este término de decaimiento más lento. Por lo tanto, la probabilidad en los estados transitorios decae asintóticamente proporcional a:

$$e^{\mathrm{Re}(\gamma_1)t}$$

Conclusión: El proceso decae hacia cero a un ritmo exponencial determinado precisamente por este eigenvalor principal de la submatriz transitoria Q_0. Por lo tanto, el **espectro de Q_0 dicta el exponente de decaimiento**, determinando algebraicamente la **velocidad de absorción** de todo el sistema físico. □

4.5. Cola M/M/1

Ejercicio 4.13. Cola M/M/1

Cola M/M/1 en $\mathbb{N}_0$: $q(x, x+1) = \lambda$, $q(x, x-1) = \mu$ para $x \geq 1$, $q(0, 1) = \lambda$.
(a) Demuestre que $\pi(x) = (1-\rho)\rho^x$ ($\rho = \lambda/\mu < 1$) satisface el balance detallado y es la probabilidad estacionaria.
(b) Calcule $E^\pi[Y_t] = \rho/(1-\rho)$.

Condición de Estabilidad

El parámetro $\rho = \lambda/\mu$ se conoce como la *intensidad de tráfico*. La condición $\rho < 1$ garantiza que el servidor procesa trabajos más rápido de lo que llegan ($\mu > \lambda$). Si esta condición no se cumple, la fila crecería indefinidamente y no existiría una distribución estacionaria.

Demostración (a): Balance Detallado y Estacionariedad. **1. Verificación del Balance Detallado:**
La condición de balance detallado en tiempo continuo establece que el flujo de probabilidad entre cualquier par de estados adyacentes debe ser idéntico en ambas direcciones:

$$\pi(x)q(x, x+1) = \pi(x+1)q(x+1, x) \quad \text{para todo } x \geq 0$$

Sustituimos la propuesta $\pi(x) = (1-\rho)\rho^x$ y las tasas del problema ($q(x, x+1) = \lambda$ y $q(x+1, x) = \mu$):

- **Lado izquierdo (flujo hacia arriba):**

$$\pi(x)\lambda = (1-\rho)\rho^x\lambda$$

- **Lado derecho (flujo hacia abajo):**

$$\pi(x+1)\mu = (1-\rho)\rho^{x+1}\mu$$

Recordando que $\rho = \lambda/\mu$, podemos reescribir $\mu = \lambda/\rho$. Sustituyendo esto en el lado derecho:

$$(1-\rho)\rho^{x+1}\left(\frac{\lambda}{\rho}\right) = (1-\rho)\rho^x\rho\left(\frac{\lambda}{\rho}\right) = (1-\rho)\rho^x\lambda$$

Ambos lados son matemáticamente idénticos. Por lo tanto, **satisface el balance detallado**.

2. Verificación de Probabilidad Estacionaria:
Es un teorema fundamental que si una medida satisface el balance detallado, entonces automáticamente satisface las ecuaciones de balance global (es invariante/estacionaria). Solo falta demostrar que $\pi(x)$ es una verdadera distribución de probabilidad (es decir, que suma 1):

$$\sum_{x=0}^{\infty}\pi(x) = \sum_{x=0}^{\infty}(1-\rho)\rho^x = (1-\rho)\sum_{x=0}^{\infty}\rho^x$$

Dado que $\rho < 1$, aplicamos la convergencia de la serie geométrica $\sum_{x=0}^{\infty}\rho^x = \frac{1}{1-\rho}$:

$$\sum_{x=0}^{\infty}\pi(x) = (1-\rho)\left(\frac{1}{1-\rho}\right) = \mathbf{1}$$

Queda demostrado que es la única distribución de probabilidad estacionaria del sistema. □

Demostración (b): Número Esperado de Clientes en el Sistema. Queremos calcular la esperanza matemática de la variable aleatoria Y_t bajo su distribución estacionaria geométrica π:

$$E^{\pi}[Y_t] = \sum_{x=0}^{\infty} x\pi(x) = \sum_{x=0}^{\infty} x(1-\rho)\rho^x$$

Dado que el primer término (cuando $x = 0$) es cero, la suma realmente empieza en $x = 1$. Factorizamos $(1-\rho)$ y una ρ:

$$E^{\pi}[Y_t] = (1-\rho)\rho \sum_{x=1}^{\infty} x\rho^{x-1}$$

Para resolver esta sumatoria, utilizamos un truco analítico estándar. Sabemos que la serie geométrica es:

$$\sum_{x=0}^{\infty} \rho^x = \frac{1}{1-\rho}$$

Derivamos ambos lados de la ecuación con respecto a ρ:

$$\frac{d}{d\rho} \sum_{x=0}^{\infty} \rho^x = \frac{d}{d\rho}(1-\rho)^{-1}$$

$$\sum_{x=1}^{\infty} x\rho^{x-1} = (-1)(1-\rho)^{-2}(-1) = \frac{1}{(1-\rho)^2}$$

Sustituimos este resultado exacto de vuelta en nuestra ecuación de la esperanza:

$$E^{\pi}[Y_t] = (1-\rho)\rho \left[\frac{1}{(1-\rho)^2}\right]$$

Cancelamos un factor de $(1-\rho)$ en el numerador y el denominador:

$$\mathbf{E}^{\pi}[\mathbf{Y_t}] = \frac{\rho}{\mathbf{1}-\rho}$$

Este es uno de los resultados más famosos de la investigación de operaciones. Nos indica que conforme el tráfico ρ se acerca a 1 (el sistema se satura), el tamaño esperado de la fila crece de forma asintótica hacia el infinito. □

Ejercicio 4.14. Ley de Little e Inestabilidad

(c) Use la Ley de Little ($L = \lambda W$) para calcular el tiempo medio de espera de un cliente en el sistema.
(d) Muestre que si $\rho \geq 1$, el proceso es transiente y $Y_t \to \infty$ en probabilidad.

Componentes de la Ley de Little

La Ley de Little es un resultado universal que no depende de las distribuciones de llegada o servicio. Se define como:

- L: Número medio de clientes en el sistema (lo que llamamos $E^\pi[Y_t]$).
- λ: Tasa media de llegada de clientes.
- W: Tiempo medio que un cliente pasa en el sistema (espera + servicio).

Demostración (c): Cálculo del tiempo de espera W. Del inciso (b), ya conocemos el número esperado de clientes en equilibrio:

$$L = E^\pi[Y_t] = \frac{\rho}{1-\rho}$$

Aplicamos la Ley de Little despejando el tiempo medio W:

$$W = \frac{L}{\lambda} = \frac{1}{\lambda}\left(\frac{\rho}{1-\rho}\right)$$

Sustituimos la definición de la intensidad de tráfico $\rho = \lambda/\mu$:

$$W = \frac{1}{\lambda}\left(\frac{\lambda/\mu}{1-\lambda/\mu}\right)$$

Multiplicamos el numerador y denominador de la fracción interna por μ para simplificar:

$$W = \frac{1}{\lambda}\left(\frac{\lambda}{\mu-\lambda}\right)$$

Cancelamos la tasa de llegada λ:

$$\mathbf{W} = \frac{\mathbf{1}}{\mu-\lambda}$$

Interpretación: El tiempo que pasas en el banco o esperando a que tu servidor responda es inversamente proporcional a la çapacidad sobrante"del sistema ($\mu - \lambda$). Si la capacidad es muy ajustada, el tiempo de espera explota. □

Demostración (d): Inestabilidad y Transencia. Analizamos el comportamiento del sistema cuando la tasa de llegada iguala o supera a la de servicio ($\lambda \geq \mu$).

1. Transencia:

Recordemos que la cola M/M/1 es esencialmente una caminata aleatoria en $\mathbb{N}_0$. La probabilidad de retorno al origen (el estado vacío) en una caminata con deriva (drift) depende de la dirección del movimiento neto:

- Si $\rho > 1$ ($\lambda > \mu$): El drift es positivo. La partícula tiene una tendencia determinista a alejarse del origen. Por lo tanto, existe una probabilidad positiva de nunca regresar a cero, lo que hace que el proceso sea **transiente**.
- Si $\rho = 1$ ($\lambda = \mu$): La caminata es simétrica (como la caminata simple en $\mathbb{Z}$). Aunque es recurrente nula (regresa a cero), el tiempo esperado de retorno es infinito. En tiempo continuo, esto se traduce en que no existe una medida de probabilidad que sume 1 (la serie geométrica $\sum 1^x$ diverge).

2. Divergencia en Probabilidad:
Consideremos la evolución temporal de la esperanza de Y_t. La tasa de cambio instantánea es $\frac{d}{dt}E[Y_t] = \lambda - \mu$ (mientras $Y_t > 0$). Integrando respecto al tiempo:

$$E[Y_t] \approx (\lambda - \mu)t + Y_0$$

Si $\lambda > \mu$, entonces $(\lambda - \mu) > 0$. Al tomar el límite cuando $t \to \infty$:

$$\lim_{t\to\infty} E[Y_t] = \infty$$

Por la desigualdad de Markov o analizando la caminata con deriva, para cualquier valor $K > 0$, la probabilidad de que la fila sea menor a K tiende a cero:

$$\mathbf{P(Y_t > K) \to 1} \quad \text{cuando } \mathbf{t \to \infty}$$

Esto significa que $Y_t \to \infty$ **en probabilidad**. El sistema colapsa porque la fila crece más rápido de lo que puede ser atendida. $\square$

4.6. Reversibilidad en tiempo continuo

Ejercicio 4.15. Reversibilidad en tiempo continuo

Sea (Y_t) irreducible en S con generador $q(x,y)$ y medida estacionaria π.
(a) Demuestre que (Y_t) es reversible en el tiempo si y solo si satisface el balance detallado: $\pi(x)q(x,y) = \pi(y)q(y,x)$ para todo $x \neq y$.
(b) Demuestre que todo proceso de nacimiento-muerte con medida estacionaria es reversible.

Simetría Probabilística

La reversibilidad implica que la probabilidad de observar una trayectoria de estados es igual a la probabilidad de observar la trayectoria inversa. Esta propiedad simplifica enormemente el cálculo de medidas estacionarias, ya que el balance detallado es una condición mucho más fuerte (y fácil de verificar) que el balance global.

Demostración (a): Equivalencia del Balance Detallado. Un proceso es reversible si para cualquier par de estados x, y y cualquier tiempo t, se cumple:

$$P(Y_0 = x, Y_t = y) = P(Y_0 = y, Y_t = x)$$

Usando la definición de probabilidad condicional y el semigrupo de transición P_t:

$$\pi(x)P_t(x,y) = \pi(y)P_t(y,x)$$

1. Ida ($\Longrightarrow$):
Si el proceso es reversible, derivamos la identidad anterior con respecto a t y evaluamos en $t = 0$:

$$\frac{d}{dt}\Big|_{t=0}[\pi(x)P_t(x,y)] = \frac{d}{dt}\Big|_{t=0}[\pi(y)P_t(y,x)]$$

Dado que $\frac{d}{dt}P_t\big|_{t=0} = \mathcal{A}$ (el generador), y para $x \neq y$ la entrada del generador es la tasa $q(x,y)$, obtenemos:

$$\pi(\mathbf{x})\mathbf{q}(\mathbf{x},\mathbf{y}) = \pi(\mathbf{y})\mathbf{q}(\mathbf{y},\mathbf{x})$$

Se cumple el balance detallado.

2. Regreso ($\Longleftarrow$):
Supongamos que se cumple el balance detallado $\pi q = q^T\pi$. En forma matricial, esto es $\text{diag}(\pi)\mathcal{A} = \mathcal{A}^T\text{diag}(\pi)$. Como $P_t = e^{t\mathcal{A}}$, podemos expandir en serie de Taylor:

$$\text{diag}(\pi)P_t = \text{diag}(\pi)\sum\frac{t^k\mathcal{A}^k}{k!} = \sum\frac{t^k}{k!}(\text{diag}(\pi)\mathcal{A}^k)$$

Por inducción, si $\text{diag}(\pi)\mathcal{A} = \mathcal{A}^T\text{diag}(\pi)$, entonces $\text{diag}(\pi)\mathcal{A}^k = (\mathcal{A}^T)^k\text{diag}(\pi)$. Por lo tanto:

$$\text{diag}(\pi)P_t = P_t^T\text{diag}(\pi) \implies \pi(\mathbf{x})\mathbf{P_t}(\mathbf{x},\mathbf{y}) = \pi(\mathbf{y})\mathbf{P_t}(\mathbf{y},\mathbf{x})$$

El proceso es reversible. □

Demostración (b): Reversibilidad en Nacimiento-Muerte. En un proceso de nacimiento-muerte, las transiciones solo ocurren entre estados vecinos ($x \leftrightarrow x+1$).

Para cualquier par de estados que **no** sean vecinos, $q(x,y) = 0$ y $q(y,x) = 0$, por lo que la ecuación $0 = 0$ se cumple trivialmente.

Para estados vecinos x y $x+1$, la medida estacionaria se construye precisamente resolviendo las ecuaciones de balance local:

$$\pi(x)\lambda_x = \pi(x+1)\mu_{x+1}$$

Donde $\lambda_x = q(x, x+1)$ es la tasa de nacimiento y $\mu_{x+1} = q(x+1, x)$ es la tasa de muerte. Sustituyendo las tasas:

$$\boldsymbol{\pi(\mathbf{x})\mathbf{q}(\mathbf{x}, \mathbf{x}+\mathbf{1}) = \pi(\mathbf{x}+\mathbf{1})\mathbf{q}(\mathbf{x}+\mathbf{1}, \mathbf{x})}$$

Como el balance detallado se cumple para todos los pares de estados posibles en la estructura de la gráfica (que es un camino lineal), por el inciso (a) concluimos que **todo proceso de nacimiento-muerte es reversible**. □

Ejercicio 4.16. Verificación de Reversibilidad y Contraejemplo

(c) Verifique que la cola M/M/1 con $\rho < 1$ es reversible. Deduzca su medida estacionaria directamente del balance detallado.
(d) Construya un proceso irreducible en $\{1, 2, 3\}$ que no sea reversible. Verifique que el balance detallado falla para algún par.

Demostración (c): Reversibilidad en M/M/1. La cola M/M/1 es, por definición, un proceso de nacimiento-muerte sobre el espacio de estados $\mathbb{N}_0$, con tasas de nacimiento λ y muerte μ. Como demostramos en el inciso (b), **todo proceso de nacimiento-muerte con medida estacionaria es reversible**.

Para deducir la medida π, planteamos la ecuación de balance detallado para estados vecinos:

$$\pi(n)\lambda = \pi(n+1)\mu \implies \pi(n+1) = \left(\frac{\lambda}{\mu}\right)\pi(n) = \rho\pi(n)$$

Esta es una relación de recurrencia que define una progresión geométrica:

$$\pi(n) = \rho^n \pi(0)$$

Usando la condición de normalización $\sum_{n=0}^{\infty} \pi(n) = 1$:

$$\pi(0)\sum_{n=0}^{\infty} \rho^n = 1 \implies \pi(0)\left(\frac{1}{1-\rho}\right) = 1 \implies \pi(0) = 1 - \rho$$

Sustituyendo $\pi(0)$, recuperamos la medida estacionaria del Ejercicio 4.5:

$$\pi(\mathbf{n}) = (\mathbf{1} - \rho)\rho^{\mathbf{n}}$$

La simplicidad de este cálculo comparado con resolver el balance global (ecuaciones algebraicas simultáneas) demuestra el poder de la propiedad de reversibilidad. □

Construcción (d): El Ciclo no Reversible. Para que un proceso no sea reversible, debemos romper la simetría de los flujos. La forma más sencilla es crear un **ciclo orientado** de probabilidad.

Consideremos un proceso irreducible en $\{1, 2, 3\}$ con el siguiente generador $\mathcal{A}$ (matriz de tasas):

$$\mathcal{A} = \begin{pmatrix} -1 & 1 & 0 \\ 0 & -1 & 1 \\ 1 & 0 & -1 \end{pmatrix}$$

En este proceso, el flujo solo va en una dirección: $1 \to 2 \to 3 \to 1$. Por simetría de la matriz (es una matriz circulante), la medida estacionaria es uniforme: $\pi = [\mathbf{1/3}, \mathbf{1/3}, \mathbf{1/3}]$.

Verificación de la falla del Balance Detallado:
Evaluamos el par $(1, 2)$:

- Flujo $1 \to 2$: $\pi(1)q(1, 2) = (1/3)(1) = 1/3$
- Flujo $2 \to 1$: $\pi(2)q(2, 1) = (1/3)(0) = 0$

Como $1/3 \neq 0$, **el balance detallado falla**.

Interpretación: Si grabamos este proceso, veríamos a la partícula rotar siempre en el sentido de las manecillas del reloj. Si proyectamos el video en reversa, la veríamos rotar en sentido contrario. Como el video original y el de reversa son distinguibles, el proceso **no es reversible**. □

4.7. Cadena encajada y construcción

Ejercicio 4.17. Cadena encajada y construcción

Sea (Y_t) con generador $q(x,y)$ y tasa total $q(x) = \sum_{y \neq x} q(x,y) < \infty$.
(a) Demuestre la construcción por saltos: (Y_t) se obtiene de la cadena encajada (Z_n) con $\tilde{p}(x,y) = q(x,y)/q(x)$ y tiempos de permanencia $\Delta_n \sim \text{Exp}(q(Z_{n-1}))$.
(b) Justifique el algoritmo de Gillespie: (a) generar $\Delta t \sim \text{Exp}(q(x))$; (b) elegir y con probabilidad $\tilde{p}(x,y)$.

Construcción Dinámica

Físicamente, el sistema en el estado x está çompitiendo"por saltar a diferentes estados vecinos y. Cada posible transición tiene un reloj exponencial independiente con tasa $q(x,y)$. El primer reloj en sonar determina a dónde va el sistema y cuánto tiempo esperó.

Demostración (a): Construcción por Saltos. Sea el proceso en el estado x. Para cada $y \in S \setminus \{x\}$, definimos una variable $T_{xy} \sim \text{Exp}(q(x,y))$ que representa el tiempo que tardaría el proceso en saltar específicamente a y.

1. Tiempo de permanencia (Δ):
El tiempo que el proceso permanece en x es el mínimo de todos los relojes posibles:

$$\Delta = \min_{y \neq x} \{T_{xy}\}$$

Por propiedades de la distribución exponencial, el mínimo de exponenciales independientes es también una exponencial cuya tasa es la suma de las tasas individuales:

$$\Delta \sim \text{Exp}\left(\sum_{y \neq x} q(x,y)\right) = \text{Exp}(\mathbf{q}(\mathbf{x}))$$

2. Probabilidad de transición ($\tilde{p}$):
La probabilidad de que el proceso salte al estado j es la probabilidad de que el reloj T_{xj} sea el primero en sonar:

$$\tilde{p}(x,j) = P(T_{xj} = \min_{y \neq x} T_{xy})$$

Nuevamente, por propiedades de la exponencial, esta probabilidad es proporcional a la tasa del evento ganador sobre la tasa total:

$$\tilde{\mathbf{p}}(\mathbf{x},\mathbf{j}) = \frac{\mathbf{q}(\mathbf{x},\mathbf{j})}{\sum_{\mathbf{y} \neq \mathbf{x}} \mathbf{q}(\mathbf{x},\mathbf{y})} = \frac{\mathbf{q}(\mathbf{x},\mathbf{j})}{\mathbf{q}(\mathbf{x})}$$

□

Justificación (b): Algoritmo de Gillespie. El algoritmo de Gillespie (o Método de Monte Carlo Cinético) se justifica directamente por los resultados del inciso (a). Para simular la trayectoria de un sistema complejo:

1. **Paso de Tiempo:** En lugar de avanzar en pasos de tiempo fijos Δt (que pueden ser imprecisos), el algoritmo calcula el tiempo exacto al que ocurrirá el *próximo* evento basándose en la tasa total de salida del estado actual $q(x)$. Esto garantiza que no se pierdan eventos rápidos y que no se pierda tiempo computacional en estados lentos.

2. **Selección de Evento:** Una vez determinado *cuándo* ocurre algo, se decide *qué* ocurre tirando un dado pesado con las probabilidades de la cadena encajada $\tilde{p}(x, y)$.

Conclusión: Esta construcción es exacta y no una aproximación, porque respeta la propiedad de Markov (falta de memoria) y la naturaleza estocástica de las tasas infinitesimales del generador. $\square$

Ejercicio 4.18. Explosión y Medida Estacionaria

(c) ¿Bajo qué condición sobre $q(x)$ puede ocurrir explosión en tiempo finito? Dé un ejemplo explícito en $S = \mathbb{N}_0$.
(d) Relacione la medida estacionaria de (Y_t) con la de la cadena encajada (Z_n).

El concepto de Explosión

Un proceso estocástico *explota* si realiza una cantidad infinita de saltos en un intervalo de tiempo finito. Esto ocurre cuando los tiempos de permanencia en los estados se vuelven cada vez más cortos tan rápido que su suma total converge a un valor finito $\zeta < \infty$ (el tiempo de explosión).

Demostración (c): Condición de Explosión. Sea $\Delta_n \sim \text{Exp}(q(Z_{n-1}))$ el tiempo que el proceso pasa en el n-ésimo estado visitado. El tiempo total para realizar n saltos es $T_n = \sum_{i=1}^{n} \Delta_i$. Decimos que hay explosión si el límite de estos tiempos es finito: $P(\lim_{n\to\infty} T_n < \infty) > 0$.

1. Condición necesaria y suficiente:
Para que ocurra explosión, la suma de los valores esperados de los tiempos de permanencia debe converger:

$$\sum_{\mathbf{n=1}}^{\infty} \frac{\mathbf{1}}{\mathbf{q(Z_n)}} < \infty$$

Si las tasas de salida $q(x)$ crecen lo suficientemente rápido conforme el proceso se aleja, el tiempo "se acaba.ªntes de que el proceso deje de saltar.

2. Ejemplo explícito en $S = \mathbb{N}_0$:
Consideremos un proceso de puro nacimiento donde la tasa de salto desde el estado n es $q(n) = 2^n$ (o cualquier potencia n^p con $p > 1$). El tiempo esperado de explosión desde el origen sería:

$$E[T_\infty] = \sum_{n=0}^{\infty} \frac{1}{2^n} = \frac{1}{1 - 1/2} = 2 \text{ unidades de tiempo}$$

Interpretación: En solo 2 segundos, el proceso habrá visitado una cantidad infinita de estados y se habrá .ºcapado"del espacio de estados numerable. □

Demostración (d): Relación de Medidas Estacionarias. Sea π la medida estacionaria del proceso en tiempo continuo (Y_t) y ν la medida estacionaria de su cadena encajada (Z_n).

La cadena encajada solo cuenta los *saltos*, ignorando cuánto tiempo se queda el proceso en cada lugar. Sin embargo, en el tiempo continuo, un estado es "más importante"(tiene más peso en π) si la cadena lo visita seguido **y** si se queda mucho tiempo en él.

Como el tiempo medio de estancia en x es $1/q(x)$, la relación es:

$$\pi(\mathbf{x}) \propto \frac{\nu(\mathbf{x})}{\mathbf{q}(\mathbf{x})}$$

Para que π sea una probabilidad normalizada, dividimos por la suma total:

$$\pi(\mathbf{x}) = \frac{\nu(\mathbf{x})/\mathbf{q}(\mathbf{x})}{\sum_{\mathbf{y}\in\mathbf{S}} \nu(\mathbf{y})/\mathbf{q}(\mathbf{y})}$$

$\square$

5. Teoremas límite

5.1. Teorema central del límite para cadenas.

Ejercicio 5.1. Teorema central del límite para cadenas

Sea (X_n) irreducible y recurrente positiva con probabilidad estacionaria π, y $f : S \to \mathbb{R}$ con $\pi(f) = 0$ y $\pi(f^2) < \infty$.
(a) Enuncie el TCL para cadenas: existe $\sigma^2 \geq 0$ tal que $n^{-1/2} \sum_{k=0}^{n-1} f(X_k) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2)$. Exprese σ^2 en términos de la función de Green.
(b) Calcule σ^2 para la cadena de nacimiento-muerte con $p_x = p < q$ y $f(x) = x - \pi(\mathrm{id})$.
(c) Demuestre que $\sigma^2 = 0$ si y solo si $f = Pg - g$ para algún $g \in L^2(\pi)$ (coborde).
(d) Aplique el TCL para cuantificar el error en la estimación Monte Carlo de $\pi(g) = (1/n) \sum_{k=0}^{n-1} g(X_k)$.

El TCL en Cadenas de Markov

A diferencia de las variables i.i.d., en una Cadena de Markov los estados están correlacionados. El TCL sigue siendo válido, pero la varianza asintótica σ^2 no es solo la varianza estática $\pi(f^2)$, sino que debe incluir la suma de todas las autocovarianzas temporales.

Solución (a): Enunciado del TCL y Función de Green. **Enunciado Formal:**
Sea $(X_n)_{n\geq 0}$ una cadena de Markov irreducible y recurrente positiva con distribución estacionaria π. Si $f \in L^2(\pi)$ cumple que $E^\pi[f(X_0)] = \pi(f) = 0$, entonces la suma parcial reescalada converge en distribución a una variable aleatoria normal:

$$\frac{1}{\sqrt{n}} \sum_{k=0}^{n-1} f(X_k) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2) \quad \text{cuando } n \to \infty$$

Varianza Asintótica y Función de Green:
La varianza asintótica σ^2 se define clásicamente como la suma de las covarianzas:

$$\sigma^2 = \mathrm{Var}^\pi(f(X_0)) + 2 \sum_{k=1}^{\infty} \mathrm{Cov}^\pi(f(X_0), f(X_k))$$

Sabiendo que $\pi(f) = 0$, tenemos que $\mathrm{Cov}^\pi(f(X_0), f(X_k)) = \pi(fP^k f)$. Sustituyendo:

$$\sigma^2 = \pi(f^2) + 2 \sum_{k=1}^{\infty} \pi(fP^k f)$$

Definimos la *Función de Green* (o matriz fundamental) centrada como $G = \sum_{k=0}^{\infty} (P^k - \Pi)$, donde Π es la matriz con filas π. Como $\Pi f = 0$, la acción de G sobre f es $Gf = \sum_{k=0}^{\infty} P^k f$. Descomponiendo la suma de la varianza:

$$\sigma^2 = -\pi(f^2) + 2 \sum_{k=0}^{\infty} \pi(fP^k f) = -\pi(f^2) + 2\pi(fGf)$$

Por lo tanto, la expresión formal en términos del operador de Green es:

$$\boldsymbol{\sigma^2 = \langle \mathbf{f}, (2\mathbf{G} - \mathbf{I})\mathbf{f} \rangle_\pi}$$

□

Solución (b): Varianza Asintótica para Nacimiento-Muerte. Tenemos una cadena con $p_{x,x+1} = p$ y $p_{x,x-1} = q$ (asumiremos $p_{x,x} = 0$ por simplicidad del modelo clásico, aunque el resultado de la varianza es robusto a lazos si ajustamos la escala). La medida estacionaria es $\pi(x) \propto (p/q)^x$. La media es $\mu = \pi(\mathrm{id}) = \frac{p}{q-p}$. Queremos la varianza para $f(x) = x - \mu$.

Utilizaremos la Ecuación de Poisson $(I - P)g = f$. Para una cadena de nacimiento-muerte, esto implica:

$$g(x) - [pg(x+1) + qg(x-1)] = x - \mu$$

La solución a esta ecuación de diferencias para la función de desviación es de la forma $g(x) = Ax^2 + Bx$. Resolviendo el sistema algebraico (como hicimos implícitamente en el Ejercicio 4.3 para tiempos de paso), encontramos que el gradiente (o diferencia finita) de g es constante en la escala ajustada:

$$\Delta g(x) = g(x+1) - g(x) = \frac{x+1}{q-p}$$

La varianza asintótica se puede calcular de manera exacta mediante el producto de la medida estacionaria y la variación del operador (el *carré du champ*):

$$\sigma^2 = \pi\left(P(g^2) - (Pg)^2\right) = \sum_{x=0}^{\infty} \pi(x)\left[p(g(x+1) - g(x))^2 + q(g(x-1) - g(x))^2\right]$$

Sustituyendo Δg:

$$\sigma^2 = \sum_{x=0}^{\infty} \pi(x)\left[p\left(\frac{x+1}{q-p}\right)^2 + q\left(\frac{x}{q-p}\right)^2\right]$$

$$\sigma^2 = \frac{1}{(q-p)^2}\sum_{x=0}^{\infty} \pi(x)\left[p(x^2+2x+1) + qx^2\right]$$

$$\sigma^2 = \frac{1}{(q-p)^2}\left[(p+q)\pi(\mathrm{id}^2) + 2p\pi(\mathrm{id}) + p\right]$$

Sustituimos los momentos de la distribución estacionaria geométrica ($\pi(\mathrm{id}) = \frac{p}{q-p}$ y $\pi(\mathrm{id}^2) = \frac{p(p+q)}{(q-p)^2}$):

$$\sigma^2 = \frac{1}{(q-p)^2}\left[(p+q)\frac{p(p+q)}{(q-p)^2} + 2p\frac{p}{q-p} + p\right]$$

Al buscar un denominador común $(q-p)^2$ dentro de los corchetes y expandir los binomios, los términos cruzados se simplifican magistralmente:

$$\sigma^2 = \frac{p}{(q-p)^4}\left[(p+q)^2 + 2p(q-p) + (q-p)^2\right] = \frac{p}{(q-p)^4}[2q^2 + 2pq]$$

Factorizando $2q$:

$$\boldsymbol{\sigma^2 = \frac{2pq(p+q)}{(q-p)^4}}$$

□

Solución (c): La Condición de Coborde *($\sigma^2 = 0$).* Queremos demostrar que la varianza asintótica se anula si y solo si f es un çoborde".

Toda función f con $\pi(f) = 0$ admite una descomposición de martingala. Sea g la solución a la ecuación de Poisson $f = g - Pg$. Definimos el incremento de martingala $D_k = g(X_{k+1}) - Pg(X_k)$. Podemos reescribir $f(X_k)$:

$$f(X_k) = g(X_k) - Pg(X_k) = g(X_k) - g(X_{k+1}) + g(X_{k+1}) - Pg(X_k) = g(X_k) - g(X_{k+1}) + D_k$$

Sumando sobre $k = 0, \ldots, n-1$, obtenemos una suma telescópica y una martingala M_n:

$$\sum_{k=0}^{n-1} f(X_k) = g(X_0) - g(X_n) + \sum_{k=0}^{n-1} D_k$$

La varianza asintótica σ^2 depende exclusivamente del término de martingala, ya que el término telescópico $g(X_0) - g(X_n)$ está acotado en varianza al dividir por n:

$$\sigma^2 = \mathrm{Var}^{\pi}(D_0) = \mathrm{Var}^{\pi}(g(X_1) - Pg(X_0)) = \pi(g^2) - \pi((Pg)^2)$$

Ida y Vuelta: Para que $\sigma^2 = 0$, la varianza de la martingala debe ser cero. Esto implica que $D_k = 0$ casi seguramente, es decir:

$$g(X_1) = Pg(X_0) \quad \text{casi seguramente respecto a } \pi.$$

Si sustituimos esto en nuestra descomposición original de f:

$$f(X_0) = g(X_0) - g(X_1) \quad \text{c.s.}$$

Tomando la esperanza condicional dado X_0 a ambos lados:

$$f(X_0) = g(X_0) - E[g(X_1)|X_0] = g(X_0) - Pg(X_0)$$

Multiplicando por -1 y redefiniendo la función como su negativo (dado que el espacio es lineal), obtenemos exactamente la condición solicitada:

$$\mathbf{f} = \mathbf{Pg} - \mathbf{g} \quad \text{para algún } \mathbf{g} \in \mathbf{L^2}(\pi)$$

□

Solución (d): Cuantificación del Error en MCMC. En la integración de Monte Carlo vía Cadenas de Markov (MCMC), queremos estimar la media teórica $\mu = \pi(g)$ utilizando el promedio empírico $\hat{\mu}_n = \frac{1}{n}\sum_{k=0}^{n-1} g(X_k)$.

Definimos la función centrada $f(x) = g(x) - \mu$, la cual cumple $\pi(f) = 0$. Aplicando el TCL del inciso (a) a nuestra función f:

$$\sqrt{n}\left(\frac{1}{n}\sum_{k=0}^{n-1} g(X_k) - \mu\right) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma_g^2)$$

Donde σ_g^2 es la varianza asintótica asociada a la función g. A partir de este límite, deducimos que para un tamaño de muestra n suficientemente grande, el error de estimación $\epsilon_n = \hat{\mu}_n - \mu$ sigue aproximadamente una distribución normal:

$$\epsilon_n \sim \mathcal{N}\left(0, \frac{\sigma_g^2}{n}\right)$$

Podemos construir un **Intervalo de Confianza** del $(1-\alpha)$ para nuestra estimación. El error absoluto estará acotado por:

$$|\hat{\mu}_\mathbf{n} - \pi(\mathbf{g})| \leq \mathbf{z_{1-\alpha/2}} \frac{\sigma_\mathbf{g}}{\sqrt{\mathbf{n}}}$$

Donde $z_{1-\alpha/2}$ es el cuantil correspondiente de la normal estándar (ej. 1,96 para el 95 %). □

5.2. Grandes desviaciones

Ejercicio 5.2. Grandes desviaciones

Sea (X_n) irreducible aperiódica en S finito con medida empírica $L_n = (1/n)\sum_{k=0}^{n-1}\delta_{X_k}$.
(a) Enuncie el principio de grandes desviaciones para L_n (Donsker-Varadhan). La función de tasa es $I(\mu) = \sup_{f>0}\left(-\sum_x \mu(x)\log\frac{Pf(x)}{f(x)}\right)$.
(b) Demuestre que $I(\mu) \geq 0$ con $I(\pi) = 0$.
(c) Para $S = \{0,1\}$ con $p(0,1) = p$ y $p(1,0) = q$, calcule $I(\mu)$ explícitamente en función de $\mu(0)$.
(d) Deduzca una cota de la tasa de decaimiento de $P(n^{-1}\sum f(X_k) \geq a)$ para $a > \pi(f)$.

Principio de Grandes Desviaciones (PGD)

El PGD establece que la probabilidad de observar una medida empírica lejos del equilibrio decae exponencialmente rápido con n. La función de tasa $I(\mu)$ actúa como un "potencial entrópico": mientras mayor sea $I(\mu)$, más rara es la desviación.

Solución (a): Enunciado del PGD de Donsker-Varadhan. La sucesión de medidas empíricas $(L_n)_{n\geq 1}$ satisface un Principio de Grandes Desviaciones en el espacio de medidas de probabilidad $\mathcal{P}(S)$ con una función de tasa $I : \mathcal{P}(S) \to [0,\infty]$, si para todo conjunto cerrado $F \subset \mathcal{P}(S)$ y todo abierto $G \subset \mathcal{P}(S)$ se cumple:

Cota Superior:

$$\limsup_{n\to\infty}\frac{1}{n}\log P(L_n \in F) \leq -\inf_{\mu\in F} I(\mu)$$

Cota Inferior:

$$\liminf_{n\to\infty}\frac{1}{n}\log P(L_n \in G) \geq -\inf_{\mu\in G} I(\mu)$$

Para una Cadena de Markov irreducible y finita, la función de tasa convexa y semicontinua inferiormente está dada explícitamente por el supremo sobre las funciones estrictamente positivas f:

$$\mathbf{I}(\mu) = \sup_{\mathbf{f>0}}\left(-\sum_{\mathbf{x\in S}}\mu(\mathbf{x})\log\left(\frac{\mathbf{Pf(x)}}{\mathbf{f(x)}}\right)\right)$$

□

Solución (b): No negatividad y Raíz en el Equilibrio. **1. Demostración de $I(\mu) \geq 0$:**
Dado que $I(\mu)$ se define como un supremo sobre *todas* las funciones $f > 0$, su valor debe ser mayor o igual al valor evaluado en cualquier función de prueba específica. Elijamos la función constante $f(x) = c > 0$. Al aplicar el operador de transición, tenemos $Pf(x) = \sum_y P(x,y)c = c\sum_y P(x,y) = c$. Evaluando el argumento del supremo para esta función:

$$-\sum_x \mu(x)\log\left(\frac{c}{c}\right) = -\sum_x \mu(x)\log(1) = 0$$

Por lo tanto, el supremo debe ser mayor o igual a cero: $\mathbf{I}(\mu) \geq \mathbf{0}$.

2. Demostración de $I(\pi) = 0$:
Queremos demostrar que para $\mu = \pi$ (la distribución estacionaria), la sumatoria es siempre menor o igual a cero para toda $f > 0$, lo que forzará al supremo a ser exactamente 0. Utilizamos la desigualdad de Jensen sobre la función cóncava logaritmo natural, con la medida de probabilidad condicional $P(x,\cdot)$:

$$\log(Pf(x)) = \log\left(\sum_y P(x,y)f(y)\right) \geq \sum_y P(x,y)\log f(y)$$

Multiplicamos ambos lados por $\pi(x)$ y sumamos sobre todo el espacio $x \in S$:

$$\sum_x \pi(x) \log(Pf(x)) \geq \sum_x \pi(x) \sum_y P(x,y) \log f(y)$$

Reagrupando el lado derecho e intercambiando sumas:

$$\sum_y \left(\sum_x \pi(x) P(x,y) \right) \log f(y)$$

Por definición de medida estacionaria, $\sum_x \pi(x)P(x,y) = \pi(y)$. Sustituyendo:

$$\sum_x \pi(x) \log(Pf(x)) \geq \sum_y \pi(y) \log f(y)$$

$$\sum_x \pi(x)[\log(Pf(x)) - \log f(x)] \geq 0$$

$$-\sum_x \pi(x) \log \left(\frac{Pf(x)}{f(x)} \right) \leq 0$$

Como la expresión es ≤ 0 para toda f, y evaluada en $f = 1$ nos da exactamente 0, el supremo es obligatoriamente cero. $\mathbf{I}(\pi) = \mathbf{0}$. □

Solución (c): Cálculo Explícito para $S = \{0, 1\}$. Sea $\mu(0) = \alpha$ y $\mu(1) = 1 - \alpha$. Sea la función estricta y positiva $f = (f_0, f_1)^T$. Dado que el logaritmo evalúa una razón, el sistema depende de un solo grado de libertad. Definamos $x = f_1/f_0 > 0$.

Evaluamos el ratio Pf/f para ambos estados utilizando la matriz P:

- Estado 0: $Pf(0)/f(0) = \frac{(1-p)f_0 + pf_1}{f_0} = 1 - p + px$
- Estado 1: $Pf(1)/f(1) = \frac{qf_0 + (1-q)f_1}{f_1} = \frac{q}{x} + 1 - q$

La función a maximizar es $g(x) = -\alpha \log(1 - p + px) - (1 - \alpha) \log\left(1 - q + \frac{q}{x}\right)$. Buscamos el punto crítico derivando e igualando a cero:

$$g'(x) = -\frac{\alpha p}{1 - p + px} - (1 - \alpha) \frac{-q/x^2}{1 - q + q/x} = -\frac{\alpha p}{1 - p + px} + \frac{(1 - \alpha)q}{x(x(1 - q) + q)} = 0$$

Igualando ambos términos y multiplicando cruzado:

$$\alpha px(x(1 - q) + q) = (1 - \alpha)q(1 - p + px)$$

$$\alpha p(1 - q)x^2 + \alpha pqx = (1 - \alpha)q(1 - p) + (1 - \alpha)pqx$$

Agrupamos todo a la izquierda para formar una ecuación cuadrática en x:

$$\alpha p(1 - q)x^2 + [\alpha pq - (1 - \alpha)pq]x - (1 - \alpha)q(1 - p) = 0$$

$$[\alpha \mathbf{p}(\mathbf{1} - \mathbf{q})]\mathbf{x}^2 + [\mathbf{pq}(\mathbf{2}\alpha - \mathbf{1})]\mathbf{x} - [(\mathbf{1} - \alpha)\mathbf{q}(\mathbf{1} - \mathbf{p})] = \mathbf{0}$$

Dado que $\alpha, p, q \in (0, 1)$, el coeficiente principal es positivo y el término constante es negativo. Por la regla de los signos de Descartes, existe una **única raíz real positiva** que denotaremos como x^*:

$$x^* = \frac{-pq(2\alpha - 1) + \sqrt{p^2q^2(2\alpha - 1)^2 + 4\alpha(1 - \alpha)pq(1 - p)(1 - q)}}{2\alpha p(1 - q)}$$

Finalmente, el supremo se alcanza explícitamente evaluando la función en esta raíz:

$$\mathbf{I}(\alpha) = -\alpha \log(\mathbf{1} - \mathbf{p} + \mathbf{px}^*) - (\mathbf{1} - \alpha) \log\left(\mathbf{1} - \mathbf{q} + \frac{\mathbf{q}}{\mathbf{x}^*}\right)$$

□

Solución (d): Cota de Tasa de Decaimiento. Queremos acotar la probabilidad $P\left(\frac{1}{n}\sum_{k=0}^{n-1} f(X_k) \geq a\right)$.

Observamos que la suma es el valor esperado de la función f con respecto a la medida empírica L_n. Es decir, $\frac{1}{n}\sum f(X_k) = \sum_x L_n(x)f(x) = L_n(f)$.

El evento $\{L_n(f) \geq a\}$ es equivalente a decir que la medida empírica L_n pertenece al conjunto cerrado F_a:

$$F_a = \{\mu \in \mathcal{P}(S) : \mu(f) \geq a\}$$

Aplicando la cota superior del Principio de Grandes Desviaciones (inciso a) para el conjunto cerrado F_a:

$$\limsup_{n\to\infty} \frac{1}{n} \log P(L_n \in F_a) \leq -\inf_{\mu \in F_a} I(\mu)$$

Como $a > \pi(f)$ y el mínimo global de $I(\mu)$ está en $I(\pi) = 0$ (el cual está estrictamente fuera de F_a), el ínfimo sobre F_a será un valor estrictamente positivo $C_a > 0$. Despejando analíticamente, obtenemos la cota de decaimiento exponencial:

$$\mathbf{P}\left(\frac{\mathbf{1}}{\mathbf{n}}\sum_{\mathbf{k=0}}^{\mathbf{n-1}} \mathbf{f}(\mathbf{X_k}) \geq \mathbf{a}\right) \lessapprox \exp\left(-\mathbf{n} \inf_{\mu:\mu(\mathbf{f})\geq \mathbf{a}} \mathbf{I}(\mu)\right)$$

Conclusión: La probabilidad de que el promedio empírico se desvíe por encima de la media teórica decae a una tasa exponencial, gobernada por el çosto"mínimo $I(\mu)$ necesario para forzar a la medida a alcanzar ese umbral. □

6. Aplicaciones

Ejercicio 6.1. Genética de poblaciones: modelo de Wright-Fisher

En una población de N individuos, $X_n \in \{0, \dots, N\}$ es el número de copias del alelo A. El modelo de Wright-Fisher supone que la generación $n+1$ se forma muestreando N alelos con reemplazo: $X_{n+1} \mid X_n = k \sim \text{Binomial}(N, k/N)$.
(a) Verifique que (X_n) es una cadena de Markov en $S = \{0, \dots, N\}$ e identifique los estados absorbentes y transientes.
(b) Demuestre que X_n es martingala y calcule $\text{Var}^k(X_{n+1}) = k(N-k)/N$.
(c) Use la martingala X_n y el teorema de paro para demostrar que la probabilidad de fijación del alelo A es $u(k) = P^k(T_{\{N\}} < T_{\{0\}}) = k/N$.
(d) Estime el tiempo esperado de fijación $E^k[T_{\{0\}} \wedge T_{\{N\}}]$ usando la martingala $X_n(N - X_n) + nk(N-k)/N$ y muestre que es $O(N)$.

Solución (a): Propiedad de Markov y Clasificación de Estados. **Propiedad de Markov:**
Por definición del problema, la distribución probabilística de la generación $n+1$ depende *exclusivamente* del número de alelos en la generación actual n, mediante la relación $X_{n+1} \mid X_n \sim \text{Binomial}(N, X_n/N)$. Dado que no requiere información de $X_{n-1}, X_{n-2}, \dots$, cumple formalmente la falta de memoria, siendo una Cadena de Markov en $S = \{0, 1, \dots, N\}$.

Clasificación de Estados:
Analizamos las probabilidades de transición $p_{i,j} = P(X_{n+1} = j \mid X_n = i) = \binom{N}{j}(i/N)^j(1 - i/N)^{N-j}$.

- **Estados Absorbentes (0 y N):** Si $X_n = 0$, la probabilidad de éxito es $0/N = 0$. Por lo tanto, $X_{n+1} \sim \text{Binomial}(N, 0)$, lo que implica $p_{0,0} = 1$. El alelo se extinguió. Si $X_n = N$, la probabilidad de éxito es $N/N = 1$. Así, $X_{n+1} \sim \text{Binomial}(N, 1)$, lo que implica $p_{N,N} = 1$. El alelo se fijó.
- **Estados Transientes ($1, \dots, N-1$):** Para cualquier estado intermedio, existe una probabilidad estrictamente positiva de llegar a 0 en un solo paso: $p_{i,0} = (1 - i/N)^N > 0$. Una vez en 0, la cadena nunca regresa a i. Por definición, esto hace que todos los estados interiores sean transientes.

□

Solución (b): Martingala y Varianza. **1. Demostración de Martingala:**
Una secuencia adaptada (X_n) es una martingala si cumple $E[X_{n+1} \mid \mathcal{F}_n] = X_n$. Sabiendo que la esperanza condicional depende solo del estado actual por la propiedad de Markov:

$$E[X_{n+1} \mid X_n] = E[\text{Binomial}(N, X_n/N)]$$

La esperanza de una variable aleatoria $\text{Binomial}(n_{trials}, p)$ es $n_{trials} \cdot p$. Sustituyendo nuestros parámetros:

$$E[X_{n+1} \mid X_n] = N \cdot \left(\frac{X_n}{N}\right) = \mathbf{X_n}$$

Queda demostrado que la frecuencia de alelos es un juego justo (martingala).

2. Cálculo de la Varianza:
La varianza condicional de una $\text{Binomial}(n_{trials}, p)$ es $n_{trials} \cdot p \cdot (1 - p)$. Evaluando con la condición inicial $X_n = k$:

$$\text{Var}(X_{n+1} \mid X_n = k) = N \cdot \left(\frac{k}{N}\right) \cdot \left(1 - \frac{k}{N}\right)$$

Distribuyendo y simplificando:

$$\text{Var}(X_{n+1} \mid X_n = k) = k \cdot \left(\frac{N-k}{N}\right) = \frac{\mathbf{k(N-k)}}{\mathbf{N}}$$

□

Solución (c): Probabilidad de Fijación. Sea $T = T_{\{0\}} \wedge T_{\{N\}}$ el tiempo de paro correspondiente al primer instante en que la cadena alcanza la extinción o la fijación. Como los estados intermedios son transientes en un espacio de estados finito, la absorción es segura: $P(T < \infty) = 1$.

Aplicamos el **Teorema de Paro Opcional** a la martingala acotada X_n (acotada porque $0 \leq X_n \leq N$):

$$E^k[X_T] = E^k[X_0] = k$$

Por otro lado, evaluamos la esperanza $E^k[X_T]$ condicionando sobre los dos únicos resultados posibles en el tiempo de paro T:

$$E^k[X_T] = 0 \cdot P^k(X_T = 0) + N \cdot P^k(X_T = N)$$

Sabiendo que $P^k(X_T = N)$ es exactamente la probabilidad de fijación $u(k)$:

$$E^k[X_T] = N \cdot u(k)$$

Igualando ambas expresiones para la esperanza de X_T:

$$N \cdot u(k) = k \implies \mathbf{u(k)} = \frac{\mathbf{k}}{\mathbf{N}}$$

□

Solución (d): Estimación del Tiempo de Fijación. Se nos pide estimar el tiempo de paro esperado $E^k[T]$ utilizando el proceso $M_n = X_n(N - X_n) + n\frac{k(N-k)}{N}$. Asumiendo por instrucción del problema que M_n opera como una martingala (ver Nota aclaratoria abajo), aplicamos nuevamente el Teorema de Paro Opcional:

$$E^k[M_T] = E^k[M_0]$$

Evaluamos el valor inicial en $n = 0$:

$$M_0 = X_0(N - X_0) + 0 = k(N - k)$$

Evaluamos la esperanza en el tiempo de paro T:

$$E^k[M_T] = E^k\left[X_T(N - X_T) + T\frac{k(N-k)}{N}\right]$$

Por la definición del tiempo de absorción, sabemos que $X_T \in \{0, N\}$. En cualquiera de los dos casos, el término cuadrático se anula ($0(N - 0) = 0$ y $N(N - N) = 0$). Por linealidad de la esperanza:

$$E^k[M_T] = 0 + E^k[T]\frac{k(N-k)}{N}$$

Igualando $E^k[M_T]$ con M_0:

$$E^k[T]\frac{k(N-k)}{N} = k(N - k)$$

Dividiendo ambos lados por el factor común $k(N - k)$ (asumiendo $0 < k < N$, pues si $k = 0$ o $k = N$ el tiempo $T = 0$):

$$\frac{E^k[T]}{N} = 1 \implies \mathbf{E^k[T] = N}$$

Conclusión: El tiempo esperado para que la población se homogenice es directamente proporcional al tamaño de la población, es decir, $\mathbf{E^k[T]} \in \mathcal{O}(\mathbf{N})$. □

Precisión sobre la Martingala de Varianza

Como tu asistente de IA, debo hacerte una pequeña precisión matemática para tu acervo en MAC: estrictamente hablando, la expresión $X_n(N - X_n) + nk(N - k)/N$ **no** es una martingala exacta.

El verdadero compensador que hace que la heterocigosis sea una martingala requiere sumar la varianza condicional real en cada paso: $X_n(N - X_n) + \frac{1}{N}\sum_{i=0}^{n-1} X_i(N - X_i)$. El ejercicio del libro sustituye la varianza dinámica $\frac{X_i(N-X_i)}{N}$ por su valor inicial $\frac{k(N-k)}{N}$ a modo de **aproximación lineal**. Esto es un truco estándar en genética teórica para estimar rápidamente el orden de magnitud ($\mathcal{O}(N)$) sin resolver ecuaciones en diferencias complejas. ¡Funciona perfecto para la estimación solicitada!

6.1. Epidemia SIS

Ejercicio 6.2. Epidemia SIS

Población de N individuos: cada uno es susceptible (S) o infeccioso (I). Sea X_n el número de infecciosos. Las probabilidades de transición son: $p(k, k+1) = \beta k(N-k)/N$, $p(k, k-1) = \gamma k$, $p(k, k) = 1 - p(k, k+1) - p(k, k-1)$, con $R_0 = \beta/\gamma$ el número de reproducción.
(a) Identifique el estado absorbente e interprete epidemiológicamente.
(b) Analice el signo del drift $p(k, k+1) - p(k, k-1)$: muestre que si $R_0 \leq 1$, la epidemia se extingue con probabilidad 1.
(c) Para $R_0 > 1$ y N grande, halle el equilibrio endémico k^* tal que $p(k^*, k^*+1) = p(k^*, k^*-1)$ y verifique que $k^*/N \approx 1 - 1/R_0$.
(d) Plantee la ecuación en diferencias para $v(k) = E^k[T_{\{0\}}]$ y argumente cualitativamente que $v(k^*) \gg v(1)$ cuando $R_0 > 1$.

El Número Básico de Reproducción (R_0)

El R_0 es el parámetro central en epidemiología. Representa el número promedio de casos secundarios producidos por un solo individuo infeccioso introducido en una población totalmente susceptible. El umbral $R_0 = 1$ dictamina matemáticamente si un brote puede sostenerse en el tiempo o si está destinado a desaparecer.

Solución (a): Identificación del Estado Absorbente. Para identificar estados absorbentes, debemos buscar aquellos estados k donde la probabilidad de permanecer en ellos mismos es 1, es decir, $p(k, k) = 1$. Esto ocurre si y solo si las probabilidades de salto son nulas:

$$p(k, k+1) = 0 \quad \text{y} \quad p(k, k-1) = 0$$

Evaluamos el estado $k = 0$:

$$p(0, 1) = \beta(0)(N-0)/N = 0$$
$$p(0, -1) = \gamma(0) = 0$$

Por lo tanto, $p(0, 0) = 1$. El estado $\mathbf{k = 0}$ es absorbente.

Interpretación Epidemiológica: Si el número de infecciosos llega a cero, el virus ha sido completamente erradicado de la población. Dado que la enfermedad se transmite por contacto entre infecciosos y susceptibles, sin infecciosos no puede haber nuevos contagios. La epidemia termina definitivamente. □

Solución (b): Análisis del Drift y Extinción. El *drift* o deriva esperada del proceso en el estado k se define como el cambio esperado en un paso:

$$\Delta(k) = E[X_{n+1} - X_n \mid X_n = k] = (+1)p(k, k+1) + (-1)p(k, k-1) + (0)p(k, k)$$

Sustituimos las probabilidades dadas:

$$\Delta(k) = \beta k \frac{N-k}{N} - \gamma k$$

Factorizamos γk e introducimos la definición de $R_0 = \beta/\gamma$:

$$\Delta(k) = \gamma k \left(\frac{\beta}{\gamma} \frac{N-k}{N} - 1 \right) = \gamma k \left(R_0 \left(1 - \frac{k}{N} \right) - 1 \right)$$

Análisis del Signo:
Supongamos que $R_0 \leq 1$. Para cualquier estado transiente $k \geq 1$, sabemos que el factor de susceptibles $(1 - k/N)$ es estrictamente menor a 1. Por lo tanto:

$$R_0 \left(1 - \frac{k}{N} \right) < R_0 \leq 1 \implies R_0 \left(1 - \frac{k}{N} \right) - 1 < 0$$

Como $\gamma k > 0$ para todo $k \geq 1$, concluimos que el drift $\Delta(k)$ es **estrictamente negativo** para todo estado activo:

$$\mathbf{\Delta(k) < 0 \quad \forall k \in \{1, \ldots, N\}}$$

Conclusión:
Al tener un drift estrictamente negativo en un espacio de estados finito, el proceso X_n es una *supermartingala* estricta fuera del origen. Existe una "fuerza determinista"que empuja constantemente el número de infectados hacia abajo. Por los teoremas de convergencia de Cadenas de Markov, el tiempo de primera llegada al estado absorbente es casi seguramente finito. La epidemia se **extingue con probabilidad 1**. □

Solución (c): El Equilibrio Endémico. Asumimos $R_0 > 1$. Buscamos el estado k^* donde las fuerzas de infección y recuperación se equilibran perfectamente, anulando el drift:

$$p(k^*, k^* + 1) = p(k^*, k^* - 1)$$

Sustituyendo las tasas:

$$\beta k^* \frac{N - k^*}{N} = \gamma k^*$$

Dado que buscamos un equilibrio activo (endémico), asumimos $k^* \neq 0$ y podemos dividir toda la ecuación entre γk^*:

$$\frac{\beta}{\gamma} \frac{N - k^*}{N} = 1$$

Sustituyendo R_0:

$$R_0 \left(1 - \frac{k^*}{N}\right) = 1$$

Despejando analíticamente la fracción de la población infectada:

$$1 - \frac{k^*}{N} = \frac{1}{R_0}$$

$$\mathbf{\frac{k^*}{N} = 1 - \frac{1}{R_0}}$$

Si multiplicamos por N, obtenemos $k^* = N(1 - 1/R_0)$. Este es el atractor macroscópico del sistema. Las fluctuaciones aleatorias ocurrirán alrededor de este valor. □

Solución (d): Ecuación en Diferencias y Metastabilidad. **1. Planteamiento de la ecuación:**
Sea $v(k) = E^k[T_{\{0\}}]$ el tiempo esperado para la extinción iniciando con k infecciosos. Condicionando en el primer salto por la Ley de Esperanza Total:

$$v(k) = 1 + p(k, k+1)v(k+1) + p(k, k-1)v(k-1) + p(k, k)v(k)$$

Para darle forma de generador estocástico discreto, restamos $v(k)$ a ambos lados. Sabiendo que $p(k, k) - 1 = -p(k, k+1) - p(k, k-1)$, agrupamos los términos:

$$p(k, k+1)[v(k+1) - v(k)] + p(k, k-1)[v(k-1) - v(k)] = -1$$

Esta es una ecuación en diferencias lineal de segundo orden con la condición de frontera absorbente $v(0) = 0$.

2. Argumento cualitativo de Metastabilidad ($v(k^*) \gg v(1)$):
Cuando $R_0 > 1$, el drift es positivo para todo $k < k^*$ y negativo para $k > k^*$. El estado k^* actúa como un "pozo de potencial"(un atractor fuerte).

- **Iniciando en $k = 1$:** Hay una alta probabilidad de que la primera transición sea una recuperación ($p(1, 0) = \gamma > 0$) antes de que la epidemia tenga oportunidad de crecer. Por lo tanto, $v(1)$ es relativamente pequeño porque la extinción rápida es un escenario muy probable.

- **Iniciando en k^*:** El proceso se encuentra .ªtrapado.ᵉⁿ el equilibrio endémico. Para que la epidemia se extinga, el proceso debe moverse en contra de la fuerza del drift (escalar el pozo de potencial) de manera repetida, realizando una secuencia larga e ininterrumpida de recuperaciones puras. Matemáticamente, este es un evento de **grandes desviaciones**.

Por la teoría de grandes desviaciones (como la vista en el Teorema de Donsker-Varadhan), el tiempo esperado para superar esta barrera de potencial crece exponencialmente con el tamaño de la población N. Concluimos tajantemente que el tiempo de extinción desde la endemia es órdenes de magnitud mayor que desde un paciente cero aislado:

$$\mathbf{v}(\mathbf{k}^*) \gg \mathbf{v}(\mathbf{1})$$

$\square$

6.2. Cola M/M/s

Ejercicio 6.3. Cola M/M/s

Cola M/M/s ($s \geq 1$ servidores) en $\mathbb{N}_0$: $q(x, x+1) = \lambda$ y $q(x, x-1) = \text{mín}(x, s)\mu$. Sea $\rho = \lambda/(s\mu)$.
(a) Escriba el generador e identifique la estructura de nacimiento-muerte.
(b) Demuestre que la medida estacionaria satisface

$$\pi(x) = \pi(0)\frac{(\lambda/\mu)^x}{x!}, \quad x \leq s; \qquad \pi(x) = \pi(0)\frac{(\lambda/\mu)^x}{s!s^{x-s}}, \quad x > s.$$

Concluya que π es normalizable si y solo si $\rho < 1$.
(c) Calcule la *fórmula de Erlang C*: la probabilidad de que un cliente llegue y encuentre todos los servidores ocupados.
(d) Use la Ley de Little para calcular el tiempo medio de espera antes de ser atendido.

Solución (a): Generador y Estructura. El sistema modela el número de clientes. Los nacimientos (llegadas) ocurren a una tasa constante $\lambda_x = \lambda$. Las muertes (salidas) dependen de cuántos servidores están activos: si hay $x \leq s$ clientes, hay x servidores trabajando, por lo que la tasa es $x\mu$. Si hay $x > s$ clientes, los s servidores están a máxima capacidad, por lo que la tasa se estanca en $s\mu$.

Esto define una clásica **cadena de nacimiento-muerte** con tasas:

$$\lambda_x = \lambda \quad \forall x \geq 0; \qquad \mu_x = \begin{cases} x\mu & \text{si } 1 \leq x \leq s \\ s\mu & \text{si } x > s \end{cases}$$

El generador infinitesimal $\mathcal{A}$ aplicado a una función de prueba f se escribe como:

$$\mathcal{A}f(x) = \lambda[f(x+1) - f(x)] + \text{mín}(x, s)\mu[f(x-1) - f(x)]$$

□

Solución (b): Medida Estacionaria y Normalización. Al ser un proceso de nacimiento-muerte, la distribución estacionaria obedece las ecuaciones de balance detallado locales: $\pi(x)\mu_x = \pi(x-1)\lambda_{x-1}$. Iterando desde el estado 0:

$$\pi(x) = \pi(0)\prod_{i=1}^{x}\frac{\lambda_{i-1}}{\mu_i} = \pi(0)\frac{\lambda^x}{\prod_{i=1}^{x}\mu_i}$$

Separamos el análisis en dos casos debido a la función definida a trozos de μ_x:
Caso 1 ($x \leq s$): Todos los servidores atienden. El producto del denominador es $\prod_{i=1}^{x}(i\mu) = x!\mu^x$.

$$\pi(\mathbf{x}) = \pi(\mathbf{0})\frac{\lambda^{\mathbf{x}}}{\mathbf{x}!\mu^{\mathbf{x}}} = \pi(\mathbf{0})\frac{(\lambda/\mu)^{\mathbf{x}}}{\mathbf{x}!}$$

Caso 2 ($x > s$): La capacidad topa. El producto del denominador incluye los primeros s términos (que dan $s!\mu^s$) multiplicados por los restantes $x - s$ términos (que valen constantemente $s\mu$).

$$\prod_{i=1}^{x}\mu_i = (s!\mu^s) \times (s\mu)^{x-s} = s!\, s^{x-s}\mu^x$$

Sustituyendo en la fórmula iterada:

$$\pi(\mathbf{x}) = \pi(\mathbf{0})\frac{\lambda^{\mathbf{x}}}{\mathbf{s!}\,\mathbf{s}^{\mathbf{x-s}}\mu^{\mathbf{x}}} = \pi(\mathbf{0})\frac{(\lambda/\mu)^{\mathbf{x}}}{\mathbf{s!}\,\mathbf{s}^{\mathbf{x-s}}}$$

Condición de Normalización: Para que π sea una distribución de probabilidad válida, la suma total debe ser finita: $\sum_{x=0}^{\infty}\pi(x) = 1$. Separamos la suma en las dos regiones:

$$\sum_{x=0}^{\infty}\pi(x) = \pi(0)\left(\sum_{x=0}^{s}\frac{(\lambda/\mu)^x}{x!} + \sum_{x=s+1}^{\infty}\frac{(\lambda/\mu)^x}{s!\,s^{x-s}}\right)$$

Nos enfocamos en la serie infinita. Reescribimos el término aislando el factor s:

$$\sum_{x=s+1}^{\infty} \frac{(\lambda/\mu)^s(\lambda/\mu)^{x-s}}{s!\, s^{x-s}} = \frac{(\lambda/\mu)^s}{s!} \sum_{x=s+1}^{\infty} \left(\frac{\lambda}{s\mu}\right)^{x-s}$$

Haciendo el cambio de índice $j = x - s$:

$$\frac{(\lambda/\mu)^s}{s!} \sum_{j=1}^{\infty} \rho^j$$

Esta es una serie geométrica estándar. Sabemos por análisis matemático que converge **si y solo si** la razón estrictamente cumple $\rho < 1$. Si $\rho \geq 1$, la serie diverge al infinito, haciendo imposible encontrar un $\pi(0) > 0$. Por lo tanto, el sistema es estable y normalizable $\iff \rho < 1$. □

Solución (c): Fórmula de Erlang C. La fórmula de Erlang $C(s, \lambda/\mu)$ es la probabilidad de que todos los servidores estén ocupados, lo que equivale al evento de que haya s o más clientes en el sistema:

$$C = P(X \geq s) = \sum_{x=s}^{\infty} \pi(x)$$

Usando la expresión del Caso 2, y reconociendo que $\pi(s) = \pi(0)\frac{(\lambda/\mu)^s}{s!}$:

$$C = \sum_{x=s}^{\infty} \pi(s) \frac{(\lambda/\mu)^{x-s}}{s^{x-s}} = \pi(s) \sum_{j=0}^{\infty} \left(\frac{\lambda}{s\mu}\right)^j$$

Reconociendo nuevamente $\rho = \lambda/(s\mu)$ y evaluando la serie geométrica desde 0:

$$\mathbf{C} = \pi(\mathbf{s}) \sum_{\mathbf{j=0}}^{\infty} \rho^{\mathbf{j}} = \frac{\pi(\mathbf{s})}{\mathbf{1} - \rho}$$

(Donde $\pi(s)$ depende de $\pi(0)$, el cual se obtiene forzando a que toda la distribución sume 1). □

Solución (d): Ley de Little para Tiempo de Espera. Para aplicar la Ley de Little a la "fila de espera"(sin contar a los que están siendo atendidos), primero calculamos la longitud esperada de la cola, L_q:

$$L_q = E[\text{máx}(X - s, 0)] = \sum_{x=s}^{\infty} (x - s)\pi(x)$$

Haciendo el cambio de variable $j = x - s$:

$$L_q = \sum_{j=0}^{\infty} j\pi(s + j) = \sum_{j=0}^{\infty} j\pi(s)\rho^j = \pi(s)\rho \sum_{j=1}^{\infty} j\rho^{j-1}$$

Reconocemos que la serie es la derivada de la serie geométrica: $\sum_{j=1}^{\infty} j\rho^{j-1} = \frac{d}{d\rho}\left(\frac{1}{1-\rho}\right) = \frac{1}{(1-\rho)^2}$.

$$L_q = \pi(s)\frac{\rho}{(1-\rho)^2}$$

Nota que podemos reescribir esto en términos de Erlang C (ya que $C = \pi(s)/(1-\rho)$):

$$L_q = C\frac{\rho}{1-\rho}$$

Finalmente, aplicamos la **Ley de Little** para la cola: $L_q = \lambda W_q$, donde W_q es el tiempo medio de espera en fila:

$$W_q = \frac{L_q}{\lambda} = \frac{C\rho}{\lambda(1-\rho)}$$

Sustituyendo $\rho = \lambda/(s\mu)$:

$$\mathbf{W_q} = \frac{\mathbf{C}}{\mathbf{s}\mu(\mathbf{1} - \rho)}$$

El tiempo de espera es proporcional a la probabilidad de encontrar congestión (Erlang C), e inversamente proporcional a la capacidad "sobrante"de la red de servidores. □

6.3. Modelo de Ising y dinámica de Glauber

Ejercicio 6.4. Modelo de Ising y dinámica de Glauber

Sea $E = \{-1, +1\}^n$ el espacio de configuraciones de spins. La dinámica de Glauber es una cadena en E donde en cada paso se elige un sitio i uniformemente y se actualiza su spin según la distribución condicional de Gibbs a temperatura $T = 1/\beta$:

$$P(\sigma_i = +1 \mid \sigma_{-i}) = \frac{e^{\beta J \sum_{j\sim i} \sigma_j}}{e^{\beta J \sum_{j\sim i} \sigma_j} + e^{-\beta J \sum_{j\sim i} \sigma_j}}$$

(a) Escriba las probabilidades de transición $p(\sigma, \sigma')$ donde σ' difiere de σ solo en el sitio i.
(b) Demuestre que la medida de Gibbs $\pi(\sigma) \propto e^{-\beta H(\sigma)}$, con $H(\sigma) = -J \sum_{i\sim j} \sigma_i \sigma_j$, es estacionaria y que la cadena es reversible.
(c) Usando la desigualdad de Poincaré, argumente que el tiempo de mezcla es $O(n)$ cuando β es pequeño (alta temperatura).
(d) Explique cualitativamente por qué el tiempo de mezcla puede ser exponencial en n para β grande (baja temperatura, efectos metaestables).

El Hamiltoniano y la Medida de Gibbs

El Hamiltoniano $H(\sigma)$ mide la energía total. Si los vecinos .están de acuerdo"(mismo signo), el producto es $+1$ y la energía baja (es más estable). La medida de Gibbs $\pi(\sigma) = \frac{1}{Z} e^{-\beta H(\sigma)}$ dicta que las configuraciones de menor energía son exponencialmente más probables, siendo β el regulador de esta severidad.

Solución (a): Probabilidades de Transición. Sea σ la configuración actual y σ' la nueva configuración. Si σ' difiere de σ en más de un sitio, la probabilidad de transición es 0 (ya que Glauber solo actualiza un sitio a la vez).

Si σ y σ' difieren a lo sumo en el sitio i (es decir, $\sigma_{-i} = \sigma'_{-i}$ y el nuevo spin en i es $\sigma'_i \in \{-1, +1\}$), la transición requiere dos eventos independientes: 1. Elegir el sitio i (probabilidad $1/n$). 2. Asignar el nuevo valor σ'_i dado el entorno σ_{-i}.

Notemos que la probabilidad condicional dada se puede escribir de forma compacta para cualquier valor $s \in \{-1, +1\}$ como:

$$P(\sigma_i = s \mid \sigma_{-i}) = \frac{e^{\beta J s \sum_{j\sim i} \sigma_j}}{e^{\beta J \sum_{j\sim i} \sigma_j} + e^{-\beta J \sum_{j\sim i} \sigma_j}}$$

Por lo tanto, la probabilidad de transición completa es:

$$\mathbf{p}(\sigma, \sigma') = \frac{\mathbf{1}}{\mathbf{n}} \frac{\mathbf{e}^{\beta \mathbf{J} \sigma'_{\mathbf{i}} \sum_{\mathbf{j}\sim\mathbf{i}} \sigma_{\mathbf{j}}}}{\mathbf{e}^{\beta \mathbf{J} \sum_{\mathbf{j}\sim\mathbf{i}} \sigma_{\mathbf{j}}} + \mathbf{e}^{-\beta \mathbf{J} \sum_{\mathbf{j}\sim\mathbf{i}} \sigma_{\mathbf{j}}}}$$

□

Solución (b): Reversibilidad y Medida Estacionaria. Para demostrar que π es estacionaria, es suficiente demostrar que la cadena es reversible respecto a π, es decir, que cumple el **balance detallado**:

$$\pi(\sigma) p(\sigma, \sigma') = \pi(\sigma') p(\sigma', \sigma)$$

Asumimos que σ y σ' difieren únicamente en el sitio i. Por lo tanto, $\sigma'_i = -\sigma_i$. Evaluamos el lado izquierdo usando la definición de $\pi(\sigma) = \frac{1}{Z} e^{-\beta H(\sigma)}$:

$$\pi(\sigma) p(\sigma, \sigma') = \frac{1}{Z} e^{-\beta H(\sigma)} \frac{1}{n} \frac{e^{\beta J \sigma'_i S_i}}{e^{\beta J S_i} + e^{-\beta J S_i}}$$

Donde $S_i = \sum_{j\sim i} \sigma_j$ es la suma de los vecinos de i (que es idéntica en ambas configuraciones).

Descomponemos el Hamiltoniano $H(\sigma)$ separando las interacciones que involucran al sitio i de las que no:

$$H(\sigma) = -J\sigma_i \sum_{j\sim i} \sigma_j - J \sum_{k\sim l,\, k,l\neq i} \sigma_k \sigma_l = -J\sigma_i S_i + H_{\text{resto}}$$

Sustituyendo esto en el término exponencial de la medida:

$$e^{-\beta H(\sigma)} e^{\beta J \sigma_i' S_i} = e^{\beta J \sigma_i S_i} e^{-\beta H_{\text{resto}}} e^{\beta J \sigma_i' S_i} = e^{\beta J S_i (\sigma_i + \sigma_i')} e^{-\beta H_{\text{resto}}}$$

Dado que $\sigma_i' = -\sigma_i$, la suma $\sigma_i + \sigma_i' = 0$. Esto colapsa el primer exponencial a $e^0 = 1$:

$$\pi(\sigma) p(\sigma, \sigma') = \frac{1}{Z \cdot n} \frac{e^{-\beta H_{\text{resto}}}}{e^{\beta J S_i} + e^{-\beta J S_i}}$$

Observemos la expresión final: el término H_{resto} no depende de i, y el denominador tampoco depende del estado del spin en i. Por lo tanto, toda la expresión es perfectamente simétrica respecto al intercambio de σ y σ'. Si evaluamos $\pi(\sigma')p(\sigma', \sigma)$, llegaremos exactamente al mismo resultado analítico.

Al cumplirse el balance detallado, **la cadena es reversible** y, por el teorema general de Cadenas de Markov, $\pi(\sigma)$ **es su medida estacionaria**. □

Solución (c): Tiempo de Mezcla a Alta Temperatura. A muy alta temperatura, el parámetro $\beta \to 0$. Evaluando la probabilidad de transición condicional:

$$P(\sigma_i = +1 \mid \sigma_{-i}) \approx \frac{e^0}{e^0 + e^0} = \frac{1}{2}$$

Significa que los spins ignoran a sus vecinos y cambian de estado como si fueran monedas justas independientes. La desigualdad de Poincaré acota la varianza de cualquier función a través de la forma de Dirichlet $\mathcal{E}(f, f)$, proveyendo una cota inferior para el salto espectral (spectral gap) $\text{gap}(P)$.

Para n sitios independientes que se actualizan con probabilidad $1/n$ en cada paso, la constante de Poincaré dicta que el salto espectral es del orden $\Omega(1/n)$. El *tiempo de relajación* (inverso del gap) es, por tanto, $\mathcal{O}(n)$.

Dado que en cada paso de tiempo se actualiza un solo sitio, en promedio toma n pasos actualizar todos los sitios del sistema. Por lo tanto, el sistema .ºlvida"su condición inicial y alcanza el equilibrio en un tiempo proporcional al tamaño del sistema.

$$\mathbf{t}_{\text{mix}} \sim \mathcal{O}(\mathbf{n})$$

(Nota rigurosa: Si definimos el tiempo de mezcla a través de la distancia en variación total, el fenómeno del recolector de cuponesïntroduce un factor logarítmico, siendo el tiempo de mezcla estricto $\mathcal{O}(n \log n)$, pero el tiempo de relajación espectral es exactamente $\mathcal{O}(n)$). □

Solución (d): Metaestabilidad a Baja Temperatura. A muy baja temperatura (cuando β es grande), el sistema busca minimizar su energía (el Hamiltoniano). El Hamiltoniano tiene dos mínimos globales absolutos:

1. Todos los spins son $+1$ (Magnetización positiva pura).
2. Todos los spins son -1 (Magnetización negativa pura).

Supongamos que el sistema inicia en el estado de "todos $+1$". Para que el sistema se mezcle (es decir, para que alcance el estado estacionario π que es simétrico y asigna igual probabilidad a la configuración de "todos -1"), debe transitar desde el estado $+1$ al estado -1.

Para lograr esto mediante la dinámica de Glauber, que solo voltea un spin a la vez, el sistema está obligado a crear una ïsla.º gota de spins -1 rodeada de spins $+1$. El borde de esta isla contiene muchas conexiones vecinas desiguales ($\sigma_i \neq \sigma_j$), lo cual incrementa dramáticamente la energía del sistema.

Esta barrera energética de superficie es del orden de la longitud de la frontera, lo que requiere un incremento de energía $\Delta E \propto n^\alpha$ (donde α depende de la dimensión de la red, para $d \geq 2$, $\Delta E \to \infty$ conforme $n \to \infty$).

Dado que las transiciones a estados de mayor energía están penalizadas por el factor de Boltzmann $e^{-\beta\Delta E}$, la probabilidad de que el sistema logre escalar esta barrera energética es exponencialmente pequeña. El sistema se queda .ªtrapado"(metaestable) en uno de los pozos de potencial durante una cantidad masiva de tiempo antes de lograr una fluctuación gigante que lo pase al otro lado.

Por esta razón, el tiempo de mezcla escala exponencialmente con el tamaño del sistema y el inverso de la temperatura:

$$\mathbf{t}_{\text{mix}} \sim \exp(\mathbf{c}\beta\boldsymbol{\Delta}\mathbf{E}) \implies \mathbf{t}_{\text{mix}} \sim \exp(\mathcal{O}(\mathbf{n}^{\alpha}))$$

$\square$

6.4. Cadena de Metropolis–Hastings

Ejercicio 6.5. Cadena de Metropolis-Hastings

Sea π una probabilidad objetivo en S finito y $q(x,y) = q(y,x)$ una propuesta simétrica irreducible.
(a) Defina la cadena de Metropolis-Hastings:

$$p(x,y) = q(x,y) \operatorname{mín}\left(1, \frac{\pi(y)}{\pi(x)}\right), \quad x \neq y.$$

Demuestre que satisface el balance detallado y que π es estacionaria.
(b) Generalice al caso asimétrico $q(x,y) \neq q(y,x)$: proponga tasas de aceptación que garanticen el balance detallado respecto de π.
(c) ¿Cómo se relaciona el tiempo de mezcla de la cadena de Metropolis-Hastings con el de la propuesta q?
(d) Implemente conceptualmente el muestreo de la distribución de Gibbs del Ejercicio 6.4 mediante Metropolis-Hastings.

El Motor del MCMC

La magia de Metropolis-Hastings es que nos permite muestrear de una distribución $\pi(x)$ sin necesidad de conocer su constante de normalización (la cual suele ser intratable), ya que al tomar el cociente $\pi(y)/\pi(x)$, dicha constante se cancela perfectamente.

Solución (a): Balance Detallado (Caso Simétrico). Para demostrar que la cadena satisface el balance detallado, debemos probar que para todo par de estados $x \neq y$:

$$\pi(x)p(x,y) = \pi(y)p(y,x)$$

Sustituimos la definición de las probabilidades de transición $p(x,y)$ en el lado izquierdo de la ecuación:

$$\pi(x)p(x,y) = \pi(x)q(x,y) \operatorname{mín}\left(1, \frac{\pi(y)}{\pi(x)}\right)$$

Dado que $\pi(x) > 0$, podemos introducirla dentro de la función mínimo:

$$\pi(x)p(x,y) = q(x,y) \operatorname{mín}(\pi(x), \pi(y))$$

Ahora analizamos el lado derecho de la ecuación de balance detallado:

$$\pi(y)p(y,x) = \pi(y)q(y,x) \operatorname{mín}\left(1, \frac{\pi(x)}{\pi(y)}\right)$$

$$\pi(y)p(y,x) = q(y,x) \operatorname{mín}(\pi(y), \pi(x))$$

Por hipótesis, la distribución de propuesta es simétrica, es decir, $q(x,y) = q(y,x)$. Además, la función mínimo es conmutativa, por lo que $\operatorname{mín}(\pi(x), \pi(y)) = \operatorname{mín}(\pi(y), \pi(x))$. Igualando ambas expresiones, concluimos que:

$$\pi(\mathbf{x})\mathbf{p}(\mathbf{x},\mathbf{y}) = \pi(\mathbf{y})\mathbf{p}(\mathbf{y},\mathbf{x})$$

Al cumplirse el balance detallado, la cadena es reversible respecto a π. Un corolario directo de la reversibilidad es que π **es la medida estacionaria** de la cadena. □

Solución (b): Generalización Asimétrica (Hastings). Si $q(x,y) \neq q(y,x)$, introducimos una tasa de aceptación general $\alpha(x,y)$ tal que $p(x,y) = q(x,y)\alpha(x,y)$. Queremos forzar el balance detallado:

$$\pi(x)q(x,y)\alpha(x,y) = \pi(y)q(y,x)\alpha(y,x)$$

Despejando la razón de las tasas de aceptación:

$$\frac{\alpha(x,y)}{\alpha(y,x)} = \frac{\pi(y)q(y,x)}{\pi(x)q(x,y)}$$

Para maximizar la movilidad de la cadena (y no rechazar transiciones innecesariamente), si la razón en el lado derecho es mayor a 1, definimos $\alpha(x,y) = 1$ y ajustamos $\alpha(y,x)$ en consecuencia. Si es menor a 1, definimos $\alpha(y,x) = 1$. Esta lógica se encapsula elegantemente en la función mínimo:

$$\alpha(\mathbf{x},\mathbf{y}) = \text{mín}\left(\mathbf{1}, \frac{\pi(\mathbf{y})\mathbf{q}(\mathbf{y},\mathbf{x})}{\pi(\mathbf{x})\mathbf{q}(\mathbf{x},\mathbf{y})}\right)$$

Esta es la famosa corrección de Hastings (1970) al algoritmo original de Metropolis (1953). □

Solución (c): Tiempo de Mezcla y Propuesta). El tiempo de mezcla de la cadena de Metropolis-Hastings (t_{mix}^{MH}) está íntimamente ligado al de la cadena de propuesta (t_{mix}^{q}), pero se ve ralentizado por los **rechazos**.

Dado que la probabilidad de transición real es $p(x,y) = q(x,y)\alpha(x,y)$, la cadena MH da "pasos nulos"(se queda en el mismo estado) con probabilidad $1 - \sum_{y \neq x} p(x,y)$. A través de la conductancia (o cuello de botella isoperimétrico), si la tasa de aceptación promedio es baja, la conductancia de MH será mucho menor que la de q.

Por el teorema de comparación de formas de Dirichlet, si $\alpha(x,y) \geq \alpha_{\min}$ para todo x, y, entonces el salto espectral de la cadena MH está acotado por el salto de la propuesta:

$$\text{gap}_{MH} \geq \alpha_{\min} \cdot \text{gap}_q$$

Como el tiempo de mezcla es inversamente proporcional al salto espectral ($t_{\text{mix}} \propto 1/\text{gap}$), deducimos cualitativamente que:

$$\mathbf{t}_{\text{mix}}^{\mathbf{MH}} \gtrsim \frac{\mathbf{1}}{\alpha_{\min}} \mathbf{t}_{\text{mix}}^{\mathbf{q}}$$

Conclusión: La cadena de Metropolis-Hastings siempre mezcla más lento que la propuesta libre q (es "perezosa"debido a los rechazos). Si la propuesta no explora bien el espacio o propone zonas de bajísima probabilidad (muchos rechazos), el tiempo de mezcla explota. □

Solución (d): Implementación Conceptual para el Modelo de Ising. Para muestrear la distribución de Gibbs $\pi(\sigma) \propto e^{-\beta H(\sigma)}$ del Ejercicio 6.4 usando Metropolis, procedemos así:

1. Propuesta Simétrica $q(\sigma, \sigma')$:

Estando en la configuración σ, elegimos un sitio $i \in \{1, \ldots, n\}$ uniformemente al azar y proponemos voltear su spin: $\sigma'_i = -\sigma_i$ (y $\sigma'_{-i} = \sigma_{-i}$). Dado que ir de σ a σ' y regresar implica elegir el mismo sitio i, $q(\sigma, \sigma') = 1/n = q(\sigma', \sigma)$. La propuesta es simétrica.

2. Tasa de Aceptación $\alpha(\sigma, \sigma')$:

Por ser propuesta simétrica, aplicamos la regla de Metropolis del inciso (a):

$$\alpha(\sigma, \sigma') = \text{mín}\left(1, \frac{\pi(\sigma')}{\pi(\sigma)}\right) = \text{mín}\left(1, \frac{e^{-\beta H(\sigma')}}{e^{-\beta H(\sigma)}}\right) = \text{mín}\left(1, e^{-\beta \Delta H}\right)$$

Donde $\Delta H = H(\sigma') - H(\sigma)$ es el cambio local de energía al voltear el spin i. Sabiendo que $H(\sigma) = -J \sum_{k \sim l} \sigma_k \sigma_l$, el cambio de energía solo depende de los vecinos de i:

$$\Delta H = 2J\sigma_i \sum_{j \sim i} \sigma_j$$

3. Algoritmo Conceptual:

1. Iniciar en una configuración arbitraria σ.
2. Elegir un sitio i al azar uniformemente.
3. Calcular $\Delta H = 2J\sigma_i \sum_{j \sim i} \sigma_j$.
4. Si $\Delta H \leq 0$ (baja la energía), aceptar el cambio $\sigma \to \sigma'$ con probabilidad 1.

5. Si $\Delta H > 0$ (sube la energía), aceptar el cambio con probabilidad $e^{-\beta \Delta H}$. Para ello, generar $U \sim \text{Uniforme}(0,1)$ y si $U < e^{-\beta \Delta H}$, aceptar el cambio. Si no, quedarse en σ.

6. Repetir desde el paso 2.

Este procedimiento garantiza que las muestras generadas asintóticamente sigan la distribución exacta de Gibbs a temperatura $1/\beta$. $\square$

6.5. Caminata aleatoria en árboles

Ejercicio 6.6. Caminata aleatoria en árboles

Sea $\mathbb{T}_d$ el árbol d-regular infinito ($d \geq 2$) y (X_n) la caminata simple: $p(x, y) = 1/d$ para vecinos y de x.
(a) Para $d \geq 3$, calcule $P^o(T_o^+ < \infty)$ mediante análisis del primer paso en la dirección radial.
(b) Para $d = 2$, muestre que $\mathbb{T}_2 \cong \mathbb{Z}$ e identifique la caminata con la simple en $\mathbb{Z}$.
(c) Para $d \geq 3$, demuestre que existe la velocidad de fuga $v = \lim_{n\to\infty} d(X_n, o)/n$ casi seguramente y calcule $v = (d-2)/d$.
(d) Contraste con la caminata en $\mathbb{Z}^d$ para $d \geq 3$: ¿existe velocidad de fuga? Justifique.

Procesos de Ramificación y Distancia Radial

En un árbol libre, no hay ciclos. Si te encuentras a una distancia $k > 0$ del origen, exactamente 1 de tus d vecinos te acerca al origen, mientras que los $d-1$ vecinos restantes te alejan. Esto permite proyectar la caminata multidimensional en un proceso unidimensional de nacimiento-muerte.

Solución (a): Probabilidad de Retorno al Origen. Definimos el proceso de la distancia radial $Y_n = d(X_n, o)$. Si el caminante está en el origen ($Y_n = 0$), forzosamente el siguiente paso lo aleja: $P(Y_{n+1} = 1 \mid Y_n = 0) = 1$. Si está en una distancia $k > 0$, las probabilidades de transición son constantes:

$$p = P(Y_{n+1} = k+1 \mid Y_n = k) = \frac{d-1}{d}$$

$$q = P(Y_{n+1} = k-1 \mid Y_n = k) = \frac{1}{d}$$

Queremos calcular $P^o(T_o^+ < \infty)$. Condicionando en el primer paso (que nos lleva obligatoriamente a $Y_1 = 1$), necesitamos calcular la probabilidad de ruina u_1, donde u_k es la probabilidad de alcanzar el estado 0 iniciando desde k:

$$P^o(T_o^+ < \infty) = 1 \cdot u_1$$

La ecuación de diferencias para u_k (con $k \geq 1$) es:

$$u_k = pu_{k+1} + qu_{k-1}$$

Esta es la ecuación clásica de la ruina del jugador. La ecuación característica $pr^2 - r + q = 0$ tiene raíces $r = 1$ y $r = q/p$. Dado que $d \geq 3$, sabemos que $d - 1 > 1$, por lo que $p > q$. La raíz q/p es estrictamente menor a 1. La solución general es $u_k = A(1)^k + B(q/p)^k$.

Por condiciones de frontera, $u_0 = 1$. Además, como el drift es positivo ($p > q$), el proceso es transiente hacia infinito, por lo que $\lim_{k\to\infty} u_k = 0$. Esto fuerza a que $A = 0$ y $B = 1$. Por lo tanto:

$$u_k = \left(\frac{q}{p}\right)^k = \left(\frac{1/d}{(d-1)/d}\right)^k = \left(\frac{1}{d-1}\right)^k$$

Evaluando en $k = 1$, concluimos que la probabilidad de retorno es:

$$\mathbf{P^o(T_o^+ < \infty) = \frac{1}{d-1}}$$

Como la probabilidad es estrictamente menor a 1 para $d \geq 3$, la caminata es transiente. □

Solución (b): El Caso Degenerado $d = 2$. Un árbol $\mathbb{T}_2$ es un grafo conexo, sin ciclos, donde cada vértice tiene exactamente grado 2. Topológicamente, el único grafo infinito que cumple esta propiedad es una línea infinita, la cual es isomorfa al conjunto de los números enteros $\mathbb{Z}$.

En este grafo, si etiquetamos los nodos consecutivamente con enteros, el origen es 0. Los únicos vecinos del estado x son $x - 1$ y $x + 1$. La caminata simple en $\mathbb{T}_2$ elige a un vecino con probabilidad 1/2. Esto

coincide exactamente con las probabilidades de transición de la caminata aleatoria simple y simétrica en $\mathbb{Z}$:

$$P(X_{n+1} = x + 1 \mid X_n = x) = \frac{1}{2}, \quad P(X_{n+1} = x - 1 \mid X_n = x) = \frac{1}{2}$$

Por lo tanto, la dinámica es idéntica y la caminata es **recurrente nula**. □

Solución (c): Existencia y Cálculo de la Velocidad de Fuga. Sea el incremento de la distancia radial $\Delta Y_i = Y_i - Y_{i-1}$. Como demostramos en el inciso (a), para $d \geq 3$ el proceso es transiente. Esto significa que visita el origen un número finito de veces casi seguramente (c.s.). Existe un tiempo aleatorio pero finito N_0 a partir del cual $Y_n > 0$ para todo $n \geq N_0$.

A partir de N_0, los incrementos ΔY_i son variables aleatorias independientes e idénticamente distribuidas, tomando el valor $+1$ con probabilidad $\frac{d-1}{d}$ y -1 con probabilidad $\frac{1}{d}$.

El valor esperado del incremento es:

$$E[\Delta Y_i] = (+1)\left(\frac{d-1}{d}\right) + (-1)\left(\frac{1}{d}\right) = \frac{d-2}{d}$$

Podemos escribir la distancia en el tiempo n como una suma de incrementos:

$$Y_n = Y_{N_0} + \sum_{i=N_0+1}^{n} \Delta Y_i$$

Dividiendo entre n y tomando el límite cuando $n \to \infty$, el término inicial constante desaparece. Aplicando la **Ley Fuerte de los Grandes Números (SLLN)** a la suma de incrementos i.i.d.:

$$\lim_{n\to\infty} \frac{Y_n}{n} = \lim_{n\to\infty} \frac{1}{n} \sum_{i=N_0+1}^{n} \Delta Y_i = E[\Delta Y_i] \quad \text{casi seguramente.}$$

Por lo tanto, la velocidad de fuga existe y es exactamente:

$$\mathbf{v} = \frac{\mathbf{d-2}}{\mathbf{d}}$$

□

Solución (d): Contraste con el Retículo $\mathbb{Z}^d$. Para la caminata aleatoria simple simétrica en $\mathbb{Z}^d$ ($d \geq 3$), el Teorema de Pólya nos asegura que la caminata también es **transiente** (escapa hacia el infinito). Sin embargo, la *forma* en que escapa es radicalmente distinta.

Consideremos la distancia euclidiana al cuadrado $||X_n||^2$. En cada paso, la caminata altera una sola coordenada en ± 1, por lo que la esperanza de la norma cuadrada obedece a $E[||X_n||^2] = n$.

Por la desigualdad de Jensen aplicada a la función convexa $f(x) = x^2$, sabemos que $(E[||X_n||])^2 \leq E[||X_n||^2] = n$. Por lo tanto, el crecimiento esperado de la distancia radial está acotado por:

$$E[||X_n||] \leq \sqrt{n}$$

Calculamos la velocidad de fuga esperada dividiendo por n:

$$E\left[\frac{||X_n||}{n}\right] \leq \frac{\sqrt{n}}{n} = \frac{1}{\sqrt{n}}$$

Cuando $n \to \infty$, la cota superior tiende a 0. Dado que la distancia siempre es no negativa, por el Teorema del Emparedado, la velocidad de fuga es cero casi seguramente.

$$\mathbf{v}_{\mathbb{Z}^d} = \lim_{\mathbf{n}\to\infty} \frac{||\mathbf{X_n}||}{\mathbf{n}} = \mathbf{0}$$

Justificación geométrica: En un árbol d-regular, no hay lazos (ciclos). Cualquier paso que te aleje del origen requiere exactamente dar la vuelta completa por ese mismo camino para volver a acercarte. En cambio, $\mathbb{Z}^d$ es un espacio altamente interconectado (reticulado"); existen infinitos caminos para rodear el origen sin aumentar estrictamente el radio. Esta "difusión.^es^pacial hace que la caminata regrese sobre sí misma constantemente, aniquilando el momento radial lineal y resultando en una expansión puramente difusiva ($\sim \sqrt{n}$) en lugar de balística ($\sim n$). □

6.6. Modelo PageRank

Ejercicio 6.7. Modelo PageRank

Sea $G = (V, E_G)$ una gráfica dirigida de N páginas web. La caminata de PageRank en V es: con probabilidad α se sigue un enlace saliente (elegido uniformemente), y con probabilidad $1 - \alpha$ se salta a un vértice elegido uniformemente de V. Formalmente, $p(x, y) = \alpha/d^+(x) + (1 - \alpha)/N$ cuando x tiene enlace a y, y $p(x, y) = (1 - \alpha)/N$ en otro caso, donde $d^+(x)$ es el grado de salida de x.
(a) Demuestre que la cadena es irreducible y aperiódica, de modo que tiene una única medida estacionaria π (el vector PageRank).
(b) Escriba la ecuación $\pi = \pi P$ en forma matricial y dé una interpretación de $\pi(x)$ como la proporción de tiempo que la caminata pasa en x.
(c) Para $N = 3$ y G con aristas $1 \to 2$, $2 \to 3$, $3 \to 1$, calcule π explícitamente con parámetro α.
(d) Explique por qué el parámetro $\alpha < 1$ es esencial para evitar el problema del *dangling node* (vértice sin aristas de salida).

El Factor de Amortiguación

El parámetro $\alpha \in (0, 1)$ (originalmente ajustado por Larry Page y Sergey Brin en 0,85) no es solo un truco de comportamiento, sino una necesidad algebraica. Asegura que la matriz de Markov cumpla con las hipótesis del Teorema de Perron-Frobenius, garantizando la existencia y unicidad del ranking.

Solución (a): Irreducibilidad y Aperiodicidad. Asumiendo que el factor de amortiguación cumple $\alpha < 1$, entonces $1 - \alpha > 0$. Para cualquier par de estados $x, y \in V$, la probabilidad de transición $p(x, y)$ está acotada inferiormente por la probabilidad de salto aleatorio:

$$p(x, y) \geq \frac{1 - \alpha}{N} > 0$$

Dado que todas las entradas de la matriz de transición P son estrictamente mayores a cero ($P > 0$), se cumplen dos propiedades inmediatas:

1. **Irreducibilidad:** Es posible ir de cualquier estado x a cualquier estado y en un solo paso. Todos los estados se comunican.
2. **Aperiodicidad:** Como $p(x, x) > 0$ para todo x, la cadena permite bucles de longitud 1. El máximo común divisor de las longitudes de los caminos de retorno es trivialmente 1.

Por el Teorema Ergódico para Cadenas de Markov finitas, una cadena irreducible y aperiódica posee una **única medida estacionaria** π a la cual converge independientemente del estado inicial. □

Solución (b): Forma Matricial e Interpretación. Definimos la matriz de adyacencia estocástica por filas H, donde $H_{xy} = 1/d^+(x)$ si hay un enlace $x \to y$, y 0 en otro caso. Definimos también la matriz E de tamaño $N \times N$ llena de unos ($E = \mathbf{1}\mathbf{1}^T$).

La matriz de transición de PageRank se escribe como:

$$P = \alpha H + \frac{1 - \alpha}{N} E$$

La ecuación de la medida estacionaria $\pi = \pi P$ (donde π es un vector fila) se escribe:

$$\pi = \alpha \pi H + \frac{1 - \alpha}{N} \pi E$$

Sabiendo que π es una distribución de probabilidad, sus elementos suman 1 ($\pi \mathbf{1} = 1$). Por lo tanto, el producto πE resulta en un vector fila de puros unos. La ecuación matricial final es:

$$\pi = \alpha \pi \mathbf{H} + \frac{\mathbf{1} - \alpha}{\mathbf{N}} \mathbf{1^T}$$

Interpretación: Por el Teorema del Límite de las Cadenas de Markov, $\pi(x)$ representa la proporción asintótica de tiempo que un usuario (que navega infinitamente haciendo clics y saltos aleatorios) pasará visitando la página x. Las páginas más enlazadas por páginas importantes serán visitadas con mayor frecuencia, obteniendo un mayor "PageRank". □

Solución (c): Cálculo Explícito para $N = 3$ cíclico. En este grafo anillo ($1 \to 2 \to 3 \to 1$), el grado de salida de todos los nodos es $d^+(x) = 1$. La matriz de navegación H es:

$$H = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}$$

La matriz completa P es:

$$P = \begin{pmatrix} \frac{1-\alpha}{3} & \alpha + \frac{1-\alpha}{3} & \frac{1-\alpha}{3} \\ \frac{1-\alpha}{3} & \frac{1-\alpha}{3} & \alpha + \frac{1-\alpha}{3} \\ \alpha + \frac{1-\alpha}{3} & \frac{1-\alpha}{3} & \frac{1-\alpha}{3} \end{pmatrix}$$

Notemos que la suma de las columnas de H es 1 (además de sus filas), por lo que H es *doblemente estocástica*. Como la matriz E también es doblemente estocástica, la matriz final P es una combinación lineal convexa de matrices doblemente estocásticas, por lo tanto, P es doblemente estocástica.

Es un teorema conocido que toda matriz doblemente estocástica tiene como distribución estacionaria al vector uniforme. Verifiquémoslo con $\pi = (1/3, 1/3, 1/3)$:

$$\pi P = \frac{1}{3}\mathbf{1}^T P = \frac{1}{3}\begin{pmatrix} \sum P_{i1} & \sum P_{i2} & \sum P_{i3} \end{pmatrix}$$

Como las columnas de P suman 1:

$$\pi P = \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right) = \pi$$

Por lo tanto, **independientemente del valor de** α, la medida es:

$$\pi = \left[\frac{\mathbf{1}}{\mathbf{3}}, \frac{\mathbf{1}}{\mathbf{3}}, \frac{\mathbf{1}}{\mathbf{3}}\right]$$

□

Solución (d): El problema del Dangling Node. Si un vértice x no tiene aristas de salida ($d^+(x) = 0$), el término $\alpha/d^+(x)$ se indefine en el algoritmo original de navegación por clics.

Si se intenta parchar este problema asumiendo $\alpha = 1$ (sin saltos aleatorios) y creando un .ªuto-enlace"$p(x, x) = 1$ para que la matriz no tenga filas de ceros, el estado x se convierte en un **estado absorbente**.

Consecuencias de un estado absorbente si $\alpha = 1$:

1. Se pierde la irreducibilidad de la cadena.
2. Todo el "flujo de probabilidad"(el PageRank) de la red terminará drenándose y acumulándose en los nodos sin salida a medida que el tiempo avance a infinito ($n \to \infty$). Las páginas con salida terminarán con un PageRank de 0.

Al fijar $\alpha < \mathbf{1}$, el sumando $\frac{1-\alpha}{N}$ garantiza que, sin importar que no haya enlaces HTML de salida, el usuario tiene una probabilidad no nula de "teclear una nueva dirección URLz escapar del nodo ciego. Esto restaura la irreducibilidad de la red global y asegura un ranking justo y matemáticamente estable para toda la web. □

6.7. Modelo de ruina multiclase

Ejercicio 6.8. Modelo de ruina multiclase

Una compañía de seguros cobra primas a tasa $c > 0$ y paga siniestros de tamaño 1 a tasa $\lambda > 0$ (proceso de Poisson). Sea X_t el capital de la compañía en el tiempo t: $X_t = x + ct - N_t$, donde N_t es el número de siniestros hasta el tiempo t.
(a) Modele (X_t) como proceso de Markov a tiempo continuo en $\mathbb{Z}$ (o en $\mathbb{N}_0$ con estado de ruina en 0).
(b) Sea $\psi(x) = P^x$(ruina en tiempo finito). Derive la ecuación diferencial ordinaria que satisface ψ en el régimen continuo $c\psi'(x) = \lambda[\psi(x) - \psi(x-1)]$.
(c) Muestre que $\psi(x) = (\lambda/c)^x\psi(0)$ es solución cuando $\lambda < c$ y calcule $\psi(0)$. ¿Cuál es la condición para que $\psi(x) < 1$?
(d) Interprete el resultado: ¿qué ocurre cuando $\lambda \geq c$?

Solución (a): Modelado en Tiempo Continuo sobre $\mathbb{Z}$. Para modelar X_t como una Cadena de Markov a Tiempo Continuo (CTMC) en el espacio de estados $S = \mathbb{Z}$, interpretamos la entrada de primas y los siniestros como saltos discretos:

- El capital aumenta en $+1$ (cobro acumulado de prima) con una tasa de transición constante $q(x, x+1) = c$.
- El capital disminuye en -1 (pago de siniestro) con una tasa de transición constante $q(x, x-1) = \lambda$.

Los estados de ruina se definen como $R = \{x \in \mathbb{Z} : x \leq 0\}$. Una vez que la cadena toca 0, consideramos el proceso absorbido, por lo que $q(0, y) = 0$ para todo y. □

Solución (b): Derivación de la Ecuación de Balance. Para un estado $x > 0$, la probabilidad de ruina $\psi(x)$ debe satisfacer la ecuación del generador infinitesimal $\mathcal{A}\psi(x) = 0$, ya que la probabilidad de absorción es una función armónica del proceso antes de ser absorbido.

Aplicando el generador de nuestra CTMC a la función ψ:

$$\mathcal{A}\psi(x) = c[\psi(x+1) - \psi(x)] + \lambda[\psi(x-1) - \psi(x)] = 0$$

Reordenando los términos para separar las tasas:

$$c[\psi(x+1) - \psi(x)] = \lambda[\psi(x) - \psi(x-1)]$$

Como se mencionó en la nota, adoptando la notación del enunciado donde $\psi'(x)$ denota la diferencia finita $\psi(x+1) - \psi(x)$, obtenemos directamente la ecuación en diferencias (descrita como diferencial en el texto):

$$\mathbf{c}\psi'(\mathbf{x}) = \lambda[\psi(\mathbf{x}) - \psi(\mathbf{x} - \mathbf{1})]$$

□

Solución (c): Verificación de la Solución y Condiciones. **1. Verificación de la solución propuesta:**
Se propone la solución $\psi(x) = \psi(0)\left(\frac{\lambda}{c}\right)^x$. Evaluamos esta función en el lado izquierdo (L.I.) y derecho (L.D.) de la ecuación en diferencias explícita derivada en (b).

Lado Izquierdo:

$$\text{L.I.} = c[\psi(x+1) - \psi(x)] = c\psi(0)\left[\left(\frac{\lambda}{c}\right)^{x+1} - \left(\frac{\lambda}{c}\right)^x\right]$$

Factorizamos el término común $\left(\frac{\lambda}{c}\right)^x$:

$$\text{L.I.} = c\psi(0)\left(\frac{\lambda}{c}\right)^x\left(\frac{\lambda}{c} - 1\right) = \psi(0)\left(\frac{\lambda}{c}\right)^x(\lambda - c)$$

Lado Derecho:

$$\text{L.D.} = \lambda[\psi(x) - \psi(x-1)] = \lambda\psi(0)\left[\left(\frac{\lambda}{c}\right)^x - \left(\frac{\lambda}{c}\right)^{x-1}\right]$$

Factorizamos el término común $\left(\frac{\lambda}{c}\right)^x$:

$$\text{L.D.} = \lambda\psi(0)\left(\frac{\lambda}{c}\right)^x\left(1 - \frac{c}{\lambda}\right) = \psi(0)\left(\frac{\lambda}{c}\right)^x(\lambda - c)$$

Como L.I. = L.D., la función es efectivamente una solución de la ecuación.

2. Cálculo de $\psi(0)$:
Por definición, $\psi(0)$ es la probabilidad de ruina dado que el capital inicial es cero. Como el estado 0 es el límite de la ruina y el proceso ya se encuentra ahí, la ruina es un evento seguro que ya ha ocurrido.

$$\psi(\mathbf{0}) = \mathbf{1}$$

Por lo tanto, la fórmula final es $\psi(x) = (\lambda/c)^x$.

3. Condición para $\psi(x) < 1$:
Dado un capital inicial estrictamente positivo ($x > 0$), para que la probabilidad de ruina sea estrictamente menor a 1, necesitamos que la base de la potencia sea menor a la unidad:

$$\left(\frac{\lambda}{c}\right)^x < 1 \implies \frac{\lambda}{c} < 1 \implies \lambda < \mathbf{c}$$

Esto se conoce en la industria aseguradora como la çondición de recargo de seguridad": la tasa de recaudo debe ser mayor a la tasa esperada de siniestros. □

Solución (d): Interpretación cuando $\lambda \geq c$. Matemáticamente, si $\lambda \geq c$, la base de nuestra solución es ≥ 1, lo que daría probabilidades sin sentido físico si usáramos la misma fórmula. Sin embargo, recurriendo a la teoría de caminatas aleatorias, $\lambda \geq c$ significa que la tendencia (drift) del proceso es hacia la izquierda (negativa o cero):

$$E[X_{t+1} - X_t] = c - \lambda \leq 0$$

En una caminata aleatoria, un drift negativo asegura que el proceso se desplazará hacia $-\infty$ casi seguramente. Si el drift es exactamente cero (caminata simétrica), el proceso es *recurrente nulo* y visita todos los estados con probabilidad 1. En ambos casos, el proceso cruzará el umbral de 0 inevitablemente.

Interpretación económica: Si la tasa de siniestros es igual o superior a la tasa a la que se cobran las primas, la aseguradora está operando a pérdida (o sin margen de ganancia real para soportar la varianza natural del riesgo). Las fluctuaciones aleatorias agotarán cualquier cantidad de capital inicial finito en algún momento del tiempo. En este régimen, **la ruina es absolutamente certera para cualquier capital** x, es decir, $\psi(\mathbf{x}) = \mathbf{1} \quad \forall \mathbf{x}$. □

6.8. Simulación Monte Carlo vía cadenas de Markov (MCMC).

Ejercicio 6.9. Simulación Monte Carlo vía cadenas de Markov (MCMC)

Se desea calcular $\pi(f) = \sum_x \pi(x)f(x)$ para una distribución π compleja en un espacio de estados S grande.
(a) Explique el principio de MCMC: construir una cadena de Markov irreducible aperiódica con medida estacionaria π y estimar $\pi(f) \approx (1/n)\sum_{k=0}^{n-1} f(X_k)$ por la ley ergódica.
(b) ¿Cuál es el error estándar del estimador MCMC? Expresélo en términos de la varianza asintótica σ^2 del Ejercicio 5.1.
(c) Explique la diferencia entre muestreo i.i.d. de π (error $\mathcal{O}(1/\sqrt{n})$ con varianza $\mathrm{Var}_\pi(f)$) y MCMC (error $\mathcal{O}(1/\sqrt{n})$ con varianza σ^2). ¿Cuándo $\sigma^2 > \mathrm{Var}_\pi(f)$?
(d) Proponga una estrategia para reducir σ^2 en la práctica (calentamiento, diezmado, variantes de la cadena).

MCMC

Cuando el espacio de estados S es astronómicamente grande (ej. todas las posibles configuraciones del Modelo de Ising), calcular la suma exacta $\sum \pi(x)f(x)$ es computacionalmente imposible. MCMC nos permite aproximar esta suma paseando inteligentemente por las zonas de alta probabilidad del espacio.

Solución (a): El Principio de MCMC y la Ley Ergódica. El principio fundamental del MCMC radica en el **Teorema Ergódico para Cadenas de Markov**. Si logramos diseñar una matriz de transición P (por ejemplo, usando el algoritmo de Metropolis-Hastings del Ejercicio 6.5) que sea:

1. **Irreducible:** Puede alcanzar cualquier estado en S.
2. **Aperiódica:** No se queda atrapada en ciclos deterministas.
3. **Reversible respecto a π:** Satisface el balance detallado $\pi(x)P(x,y) = \pi(y)P(y,x)$.

Entonces, la cadena tiene a π como su única distribución estacionaria. El Teorema Ergódico garantiza que, para cualquier función f con esperanza finita, el promedio temporal a lo largo de una única trayectoria de la cadena convergerá casi seguramente al promedio espacial (la esperanza teórica):

$$\lim_{n\to\infty} \frac{1}{n}\sum_{k=0}^{n-1} f(X_k) = \sum_{x\in S} f(x)\pi(x) = \pi(f) \quad \text{c.s.}$$

Esto nos permite sustituir una sumatoria intratable por un simple promedio empírico de las muestras generadas por la simulación. □

Solución (b): Error Estándar del Estimador MCMC. Sea nuestro estimador empírico $\hat{\mu}_n = \frac{1}{n}\sum_{k=0}^{n-1} f(X_k)$. Del Ejercicio 5.1, sabemos que el Teorema Central del Límite (TCL) para cadenas de Markov establece que:

$$\sqrt{n}(\hat{\mu}_n - \pi(f)) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2)$$

Donde σ^2 es la varianza asintótica de la cadena. A partir de esta convergencia en distribución, la varianza del estimador $\hat{\mu}_n$ para un n grande es aproximadamente $\mathrm{Var}(\hat{\mu}_n) \approx \frac{\sigma^2}{n}$.

El **error estándar** (EE) es la desviación estándar del estimador, por lo tanto:

$$\mathbf{EE_{MCMC}} \approx \frac{\sigma}{\sqrt{\mathbf{n}}}$$

□

Solución (c): Muestreo i.i.d. vs. MCMC. **1. Diferencia fundamental:**
En el muestreo independiente e idénticamente distribuido (i.i.d.), cada muestra X_k es completamente independiente de X_{k-1}. La varianza del promedio empírico es simplemente la varianza de la función dividida por n: $\mathrm{Var}(\hat{\mu}_n) = \frac{\mathrm{Var}_\pi(f)}{n}$.

En MCMC, las muestras se obtienen de una caminata aleatoria, por lo que X_k depende fuertemente de X_{k-1}. Esta *autocorrelación* modifica la varianza. Recordando el Ejercicio 5.1, la varianza asintótica es:

$$\sigma^2 = \mathrm{Var}_\pi(f) + 2\sum_{k=1}^{\infty} \mathrm{Cov}_\pi(f(X_0), f(X_k))$$

2. ¿Cuándo $\sigma^2 > \mathbf{Var}_\pi(f)$?
Esta desigualdad estricta ocurre cuando la suma de las autocovarianzas es **positiva**. En la gran mayoría de los algoritmos MCMC (como el muestreo de Gibbs o Metropolis-Hastings estándar), las transiciones son locales; el proceso se mueve lentamente por el espacio de estados. Esto genera una **autocorrelación fuertemente positiva** entre muestras sucesivas ($\mathrm{Cov}_\pi > 0$). En consecuencia, σ^2 es significativamente mayor que $\mathrm{Var}_\pi(f)$, lo que implica que el MCMC requiere muchas más muestras que el muestreo i.i.d. para alcanzar el mismo nivel de precisión. □

Solución (d): Estrategias Prácticas en MCMC. Para mitigar los problemas de convergencia y la alta varianza asintótica, en la práctica se aplican las siguientes estrategias:

1. **Calentamiento (Burn-in):** Dado que la cadena comienza en un estado X_0 arbitrario que puede tener muy baja probabilidad bajo π, las primeras muestras introducen un fuerte sesgo en el estimador. La estrategia consiste en descartar las primeras m muestras (periodo de calentamiento) y calcular el promedio solo con las muestras posteriores: $\frac{1}{n-m}\sum_{k=m}^{n-1} f(X_k)$. Aunque esto no reduce σ^2 intrínsecamente, elimina el sesgo inicial (reduce el Error Cuadrático Medio empírico).

2. **Diezmado (Thinning):** Para reducir la fuerte autocorrelación positiva descrita en el inciso (c), se guarda solo una de cada k muestras generadas (ej. saltar de 10 en 10). La nueva sub-cadena obtenida tiene muestras que se comportan mucho más como variables i.i.d., lo que reduce la varianza empírica del lote almacenado y ahorra memoria en espacios de alta dimensión.

3. **Variantes de la Cadena (Mejores Propuestas):** La forma más efectiva de reducir la varianza asintótica σ^2 de raíz es diseñar algoritmos que eviten el comportamiento difusivo (caminata aleatoria simple).

   - *Hamiltonian Monte Carlo (HMC):* Utiliza la geometría diferencial y el gradiente de la distribución objetivo para proponer saltos deterministas y lejanos con altas tasas de aceptación.
   - *Cadenas No-Reversibles:* Romper el balance detallado (manteniendo el balance global $\pi = \pi P$) introduce un drift direccional que evita que la cadena regrese sobre sus propios pasos, reduciendo dramáticamente el tiempo de mezcla y la varianza asintótica.

□

6.9. Proceso de decaimiento radioactivo

Ejercicio 6.10. Proceso de decaimiento radioactivo

Sea X_t el número de átomos radiactivos en el tiempo t. Cada átomo decae independientemente con tasa λ. Cuando quedan x átomos, la tasa de decaimiento es $x\lambda$.
(a) Escriba el generador del proceso: $q(x, x-1) = x\lambda$, $q(x, y) = 0$ para $y \neq x-1$. Verifique que 0 es absorbente.
(b) Calcule $E^x[X_t] = xe^{-\lambda t}$ resolviendo las ecuaciones de Kolmogorov hacia atrás para $E^x[X_t]$.
(c) Calcule $\mathrm{Var}^x(X_t) = xe^{-\lambda t}(1 - e^{-\lambda t})$ y muestre que $X_t \mid X_0 = x$ tiene distribución Binomial$(x, e^{-\lambda t})$.
(d) Calcule el tiempo esperado de extinción $E^x[T_{\{0\}}]$ usando el generador $\mathcal{A}v(x) = -1$.

Solución (a): Generador y Estado Absorbente. El proceso es de muerte pura. Desde el estado x, la única transición posible es hacia $x-1$. Como los x átomos son independientes y cada uno tiene una tasa λ de decaer (mínimo de x exponenciales independientes), la tasa total de salto es la suma de las tasas individuales:

$$q(x, x-1) = x\lambda$$

Y para cualquier otro estado $y \neq x-1$, la tasa es nula: $q(x, y) = 0$.

El generador infinitesimal $\mathcal{A}$ aplicado a una función f toma la forma:

$$\mathcal{A}f(x) = \sum_y q(x, y)[f(y) - f(x)] = x\lambda[f(x-1) - f(x)]$$

Para verificar que 0 es absorbente, evaluamos las tasas de salida desde el estado $x = 0$:

$$q(0, -1) = 0 \cdot \lambda = 0$$

Como todas las tasas de salida son nulas, una vez que la cadena llega a 0, se queda ahí para siempre. El estado **0 es absorbente**. □

Solución (b): Ecuación de Kolmogorov Hacia Atrás. Sea $u(t, x) = E^x[X_t]$ la esperanza condicionada a iniciar en x. La ecuación de Kolmogorov hacia atrás establece que $\frac{\partial}{\partial t}u(t, x) = \mathcal{A}u(t, x)$. Sustituyendo el generador:

$$\frac{\partial}{\partial t}u(t, x) = x\lambda[u(t, x-1) - u(t, x)]$$

Resolveremos esto por inducción sobre x. Para $x = 1$ (un solo átomo), sabiendo que $u(t, 0) = 0$ (el estado absorbente no tiene átomos):

$$\frac{\partial}{\partial t}u(t, 1) = 1\lambda[0 - u(t, 1)] = -\lambda u(t, 1)$$

La solución a esta EDO con condición inicial $u(0, 1) = 1$ es $u(t, 1) = e^{-\lambda t}$.

Supongamos como hipótesis de inducción que para $x-1$ se cumple $u(t, x-1) = (x-1)e^{-\lambda t}$. Sustituimos en la ecuación para x:

$$\frac{\partial}{\partial t}u(t, x) + x\lambda u(t, x) = x\lambda(x-1)e^{-\lambda t}$$

Esta es una EDO lineal de primer orden. Multiplicamos por el factor integrante $e^{x\lambda t}$:

$$e^{x\lambda t}\frac{\partial}{\partial t}u(t, x) + x\lambda e^{x\lambda t}u(t, x) = x\lambda(x-1)e^{(x-1)\lambda t}$$

$$\frac{\partial}{\partial t}\left[u(t, x)e^{x\lambda t}\right] = x\lambda(x-1)e^{(x-1)\lambda t}$$

Integramos respecto a t:

$$u(t, x)e^{x\lambda t} = \frac{x\lambda(x-1)}{(x-1)\lambda}e^{(x-1)\lambda t} + C = xe^{(x-1)\lambda t} + C$$

Despejando $u(t,x)$ al multiplicar por $e^{-x\lambda t}$:

$$u(t,x) = xe^{-\lambda t} + Ce^{-x\lambda t}$$

Usando la condición inicial $u(0,x) = x$:

$$x = xe^0 + Ce^0 \implies x = x + C \implies C = 0$$

Por lo tanto, queda rigurosamente demostrado que:

$$\mathbf{E^x[X_t] = xe^{-\lambda t}}$$

□

Solución (c): Distribución Binomial y Varianza. En lugar de resolver ecuaciones diferenciales de segundo orden, podemos usar un argumento probabilístico directo. El enunciado nos indica que *çada átomo decae independientemente"*.

Consideremos un átomo individual $i \in \{1, \ldots, x\}$. Su tiempo de vida T_i sigue una distribución exponencial $\text{Exp}(\lambda)$. La probabilidad de que el átomo i siga "vivo"(no haya decaído) en el tiempo t es:

$$p(t) = P(T_i > t) = e^{-\lambda t}$$

Podemos definir una variable indicadora $I_i(t)$ que vale 1 si el átomo sobrevive al tiempo t, y 0 si decae. Por lo tanto, $I_i(t) \sim \text{Bernoulli}(e^{-\lambda t})$.

El número total de átomos sobrevivientes en el tiempo t es la suma de estas indicadoras:

$$X_t = \sum_{i=1}^{x} I_i(t)$$

Dado que las $I_i(t)$ son variables aleatorias independientes e idénticamente distribuidas, su suma sigue exactamente una distribución Binomial. Por lo tanto:

$$\mathbf{X_t \mid X_0 = x \sim \text{Binomial}(x, e^{-\lambda t})}$$

Sabiendo que la varianza de una variable $Y \sim \text{Binomial}(n,p)$ es $np(1-p)$, aplicamos directamente la fórmula para obtener la varianza solicitada:

$$\mathbf{\text{Var}^x(X_t) = xe^{-\lambda t}(1 - e^{-\lambda t})}$$

□

Solución (d): Tiempo Esperado de Extinción. Sea $v(x) = E^x[T_{\{0\}}]$ el tiempo esperado para que decaigan todos los átomos iniciando con x. La ecuación de Poisson para tiempos de absorción es $\mathcal{A}v(x) = -1$ para $x > 0$, con la condición de frontera $v(0) = 0$.

Aplicando el generador derivado en el inciso (a):

$$x\lambda[v(x-1) - v(x)] = -1$$

Despejando la diferencia $v(x) - v(x-1)$:

$$v(x) - v(x-1) = \frac{1}{x\lambda}$$

Esto nos dice que el tiempo esperado adicional que toma pasar de x átomos a $x-1$ átomos es exactamente la esperanza de una exponencial con tasa $x\lambda$ (el tiempo mínimo de falla entre los x átomos). Para hallar el tiempo total $v(x)$, sumamos estas diferencias telescópicas desde $k = 1$ hasta x:

$$\sum_{k=1}^{x}[v(k) - v(k-1)] = \sum_{k=1}^{x} \frac{1}{k\lambda}$$

El lado izquierdo colapsa a $v(x) - v(0)$. Como $v(0) = 0$, obtenemos el resultado final:

$$\mathbf{E^x[T_{\{0\}}] = \frac{1}{\lambda} \sum_{k=1}^{x} \frac{1}{k}}$$

Interpretación: El tiempo esperado de extinción escala de forma logarítmica con el número inicial de átomos, ya que la suma armónica $\sum_{k=1}^{x} \frac{1}{k} \approx \ln(x) + \gamma$, *donde* γ *es la constante de Euler-Mascheroni.* □

6.10. Proceso de Yule (nacimiento puro).

Ejercicio 6.11. Proceso de Yule (nacimiento puro)

El proceso de Yule modela el crecimiento de una población: cada individuo se reproduce a tasa λ independientemente. Así $q(k, k+1) = k\lambda$ y $q(k, y) = 0$ para $y \neq k+1$. Suponga $X_0 = 1$.
(a) Resuelva las ecuaciones de Kolmogorov hacia adelante para $p_k(t) = P^1(X_t = k)$: demuestre que $p_k(t) = e^{-\lambda t}(1 - e^{-\lambda t})^{k-1}$.
(b) Calcule $E^1[X_t] = e^{\lambda t}$ y $\mathrm{Var}^1(X_t) = e^{\lambda t}(e^{\lambda t} - 1)$.
(c) Muestre que $X_t e^{-\lambda t} \to W$ casi seguramente, donde W tiene distribución Exp(1). *Sugerencia:* use que $X_t e^{-\lambda t}$ es martingala.
(d) Calcule el tiempo esperado para que la población alcance el tamaño n: $E^1[T_n] = (1/\lambda)\sum_{k=1}^{n-1} 1/k$.

Solución (a): Ecuaciones de Kolmogorov hacia adelante. Las ecuaciones de Kolmogorov hacia adelante (FKE) dictan cómo evoluciona la probabilidad de estar en el estado k:

$$p_k'(t) = \sum_j p_j(t) q(j, k)$$

Dado que las únicas transiciones hacia k provienen de $k-1$ (con tasa $(k-1)\lambda$) y las salidas desde k son hacia $k+1$ (con tasa $k\lambda$), la ecuación diferencial es:

$$p_k'(t) = (k-1)\lambda p_{k-1}(t) - k\lambda p_k(t)$$

Para demostrar que $p_k(t) = e^{-\lambda t}(1 - e^{-\lambda t})^{k-1}$ es la solución, procedemos a verificarla derivándola directamente. Definamos $u(t) = e^{-\lambda t}$, por lo que $u'(t) = -\lambda e^{-\lambda t}$. La función propuesta es $p_k(t) = u(1-u)^{k-1}$. Usando la regla del producto y la cadena:

$$p_k'(t) = u'(1-u)^{k-1} + u(k-1)(1-u)^{k-2}(-u')$$

Sustituyendo $u = e^{-\lambda t}$ y $u' = -\lambda e^{-\lambda t}$:

$$p_k'(t) = -\lambda e^{-\lambda t}(1 - e^{-\lambda t})^{k-1} + \lambda e^{-2\lambda t}(k-1)(1 - e^{-\lambda t})^{k-2}$$

Factorizamos el término común $\lambda e^{-\lambda t}(1 - e^{-\lambda t})^{k-2}$:

$$p_k'(t) = \lambda e^{-\lambda t}(1 - e^{-\lambda t})^{k-2}\left[-(1 - e^{-\lambda t}) + (k-1)e^{-\lambda t}\right]$$

Simplificando el interior del corchete:

$$-1 + e^{-\lambda t} + ke^{-\lambda t} - e^{-\lambda t} = -1 + ke^{-\lambda t}$$

Por lo tanto:

$$\mathbf{p_k'(t) = \lambda e^{-\lambda t}(1 - e^{-\lambda t})^{k-2}[ke^{-\lambda t} - 1]}$$

Ahora, evaluamos el lado derecho de la FKE con la solución propuesta:

$$(k-1)\lambda p_{k-1}(t) - k\lambda p_k(t) = (k-1)\lambda e^{-\lambda t}(1 - e^{-\lambda t})^{k-2} - k\lambda e^{-\lambda t}(1 - e^{-\lambda t})^{k-1}$$

Factorizando de manera idéntica:

$$\lambda e^{-\lambda t}(1 - e^{-\lambda t})^{k-2}\left[(k-1) - k(1 - e^{-\lambda t})\right]$$

Simplificando el corchete:

$$k - 1 - k + ke^{-\lambda t} = ke^{-\lambda t} - 1$$

Como ambos lados coinciden matemáticamente y la condición inicial se cumple ($p_1(0) = 1$ y $p_k(0) = 0$ para $k > 1$), **la solución propuesta es correcta y única**. □

Solución (b): Esperanza y Varianza. Observamos cuidadosamente la forma de la distribución:

$$P(X_t = k) = e^{-\lambda t}(1 - e^{-\lambda t})^{k-1}$$

Para cualquier tiempo fijo t, esta es exactamente la función de masa de probabilidad de una **distribución Geométrica** (definiéndola como el número de ensayos hasta el primer éxito), donde la probabilidad de éxito es $p = e^{-\lambda t}$.

Sabiendo por teoría de probabilidad que para una variable $X \sim \text{Geo}(p)$ (con soporte $k \in \{1, 2, \dots\}$), su esperanza es $1/p$ y su varianza es $(1-p)/p^2$, obtenemos directamente:

$$\mathbf{E^1[X_t] = \frac{1}{e^{-\lambda t}} = e^{\lambda t}}$$

$$\mathbf{\text{Var}^1(X_t) = \frac{1 - e^{-\lambda t}}{(e^{-\lambda t})^2} = \frac{1 - e^{-\lambda t}}{e^{-2\lambda t}} = e^{\lambda t}(e^{\lambda t} - 1)}$$

□

Solución (c): Convergencia de Martingala a la Exponencial. Sea el proceso $M_t = X_t e^{-\lambda t}$. Dado un tiempo $s < t$, la propiedad de ramificación nos dice que la población en el tiempo t es la suma de los descendientes de los X_s individuos vivos en el tiempo s. Cada uno forma un proceso de Yule independiente.

$$E[X_t \mid \mathcal{F}_s] = X_s \cdot E^1[X_{t-s}] = X_s e^{\lambda(t-s)}$$

Multiplicando por la constante $e^{-\lambda t}$:

$$E[M_t \mid \mathcal{F}_s] = e^{-\lambda t} X_s e^{\lambda(t-s)} = X_s e^{-\lambda s} = M_s$$

Por lo tanto, $\mathbf{M_t}$ **es una martingala**. Como $X_t \geq 0$, la martingala es no negativa. Por el Teorema de Convergencia de Martingalas, existe una variable aleatoria W tal que $M_t \xrightarrow{c.s.} W$.

Para hallar la distribución de W, analizamos la probabilidad de cola de M_t para un valor $w > 0$:

$$P(X_t e^{-\lambda t} > w) = P(X_t > we^{\lambda t}) = \sum_{k=\lfloor we^{\lambda t} \rfloor + 1}^{\infty} p_k(t)$$

La cola de una distribución geométrica $P(X > x) = (1-p)^x$. Usando $x = we^{\lambda t}$:

$$P(M_t > w) \approx (1 - e^{-\lambda t})^{we^{\lambda t}}$$

Tomando el límite cuando $t \to \infty$, reconocemos la definición del número e en el límite $(1 + x/n)^n \to e^x$:

$$\lim_{t \to \infty} P(M_t > w) = e^{-w}$$

Reconocemos que $P(W > w) = e^{-w}$ es la función de supervivencia de una distribución Exponencial con parámetro 1.

$$\mathbf{W} \sim \text{Exp}(\mathbf{1})$$

□

Solución (d): Tiempo esperado para alcanzar la población n. Sea T_k el tiempo que el proceso pasa exactamente en el estado k antes de transitar al estado $k+1$. Por la definición de las cadenas de Markov en tiempo continuo, los tiempos de permanencia son variables aleatorias exponenciales independientes, cuya tasa es igual a la tasa de salida del estado. En el proceso de Yule, la tasa de salida de k es $k\lambda$.

$$T_k \sim \text{Exp}(k\lambda) \implies E[T_k] = \frac{1}{k\lambda}$$

El tiempo total para que la población alcance el tamaño n comenzando desde 1 es simplemente la suma de los tiempos de permanencia en los estados $1, 2, \ldots, n-1$:

$$T_n = \sum_{k=1}^{n-1} T_k$$

Aplicando la linealidad de la esperanza:

$$E^1[T_n] = E\left[\sum_{k=1}^{n-1} T_k\right] = \sum_{k=1}^{n-1} E[T_k] = \sum_{k=1}^{n-1} \frac{1}{k\lambda}$$

Factorizando la constante de tasa:

$$\mathbf{E^1[T_n] = \frac{1}{\lambda} \sum_{k=1}^{n-1} \frac{1}{k}}$$

Al igual que en el modelo de decaimiento radiactivo, este tiempo crece de manera logarítmica respecto a la población final n, lo cual es el comportamiento característico de cualquier crecimiento exponencial. $\square$

6.11. Modelo SIR a tiempo continuo

Ejercicio 6.12. Modelo SIR a tiempo continuo

Un modelo SIR estocástico en población N: el estado es (S_t, I_t) con $S_t + I_t \leq N$, $R_t = N - S_t - I_t$ (recuperados). Las tasas son: $q((s,i),(s-1,i+1)) = \beta si/N$ (nueva infección) y $q((s,i),(s,i-1)) = \gamma i$ (recuperación).
(a) Escriba el espacio de estados y el generador del proceso. Identifique los estados absorbentes.
(b) Escriba las ecuaciones de Kolmogorov hacia adelante para $p_{s,i}(t) = P(S_t = s, I_t = i \mid S_0 = N-1, I_0 = 1)$.
(c) Para N grande, derive el sistema de ecuaciones diferenciales ordinarias (aproximación de campo medio): $ds/dt = -\beta si$, $di/dt = \beta si - \gamma i$, con $s = S/N$, $i = I/N$. Muestre que si $s(0)R_0 > 1$ la epidemia crece inicialmente.
(d) Muestre que el modelo estocástico puede extinguirse en tiempo $\mathcal{O}(1/\gamma)$ incluso cuando $R_0 > 1$, y contraste con la predicción determinista.

El Límite de Fluido (Teorema de Kurtz)

La conexión entre el inciso (b) estocástico y el inciso (c) determinista está dada por la Ley de los Grandes Números para procesos de Markov. A medida que $N \to \infty$, las fluctuaciones aleatorias relativas se desvanecen en escala $1/\sqrt{N}$, y las trayectorias estocásticas convergen casi seguramente a las soluciones de las EDOs (el límite de fluido).

Solución (a): Espacio, Generador y Absorción. **Espacio de Estados:**
Dado que la población total es N, el número de susceptibles S_t e infecciosos I_t son enteros no negativos cuya suma no puede exceder N.

$$E = \{(s,i) \in \mathbb{N}_0 \times \mathbb{N}_0 : s + i \leq N\}$$

Generador Infinitesimal:
El operador generador $\mathcal{A}$ actúa sobre funciones de prueba $f(s,i)$ sumando todas las transiciones posibles ponderadas por sus tasas:

$$\mathcal{A}f(s,i) = \frac{\beta si}{N}[f(s-1,i+1) - f(s,i)] + \gamma i[f(s,i-1) - f(s,i)]$$

Estados Absorbentes:
Un estado es absorbente si todas sus tasas de salida son cero. Las tasas son $\frac{\beta si}{N}$ y γi. Ambas son proporcionales a i. Si $i = 0$, ambas tasas se anulan independientemente del valor de s. Por lo tanto, el conjunto de estados absorbentes (la epidemia terminó) es:

$$\mathbf{A} = \{(\mathbf{s}, \mathbf{0}) : \mathbf{0} \leq \mathbf{s} \leq \mathbf{N}\}$$

□

Solución (b): Ecuaciones de Kolmogorov hacia adelante. Las ecuaciones de Kolmogorov hacia adelante describen la conservación de probabilidad (entradas menos salidas). Para el estado (s,i):

Flujos de Entrada (Inflows):

- Desde $(s+1, i-1)$ mediante una infección: con tasa $\frac{\beta(s+1)(i-1)}{N}$.
- Desde $(s, i+1)$ mediante una recuperación: con tasa $\gamma(i+1)$.

Flujos de Salida (Outflows):

- Hacia $(s-1, i+1)$ o hacia $(s, i-1)$: la tasa total de salida es la suma de las tasas del estado actual $\left(\frac{\beta si}{N} + \gamma i\right)$.

Agrupando todo esto en la ecuación diferencial para $p_{s,i}(t)$:

$$\mathbf{p'_{s,i}(t) = \frac{\beta(s+1)(i-1)}{N} p_{s+1,i-1}(t) + \gamma(i+1)p_{s,i+1}(t) - \left(\frac{\beta si}{N} + \gamma i\right) p_{s,i}(t)}$$

(Con la condición inicial $p_{N-1,1}(0) = 1$ y 0 para el resto de los estados). □

Solución (c): Aproximación de Campo Medio. Sea el cambio esperado en un paso infinitesimal dt:

$$E[dS_t \mid S_t, I_t] = (-1)\frac{\beta S_t I_t}{N} dt$$

$$E[dI_t \mid S_t, I_t] = (+1)\frac{\beta S_t I_t}{N} dt + (-1)\gamma I_t dt$$

Definimos las fracciones poblacionales $s = S/N$ y $i = I/N$. Aplicando el Límite de Fluido ($N \to \infty$), las esperanzas deterministas dominan el sistema. Dividiendo las ecuaciones anteriores por Ndt:

$$\frac{ds}{dt} = -\beta \mathbf{si}$$

$$\frac{di}{dt} = \beta \mathbf{si} - \gamma \mathbf{i}$$

Crecimiento inicial de la epidemia:
Para que la epidemia crezca en $t = 0$, la derivada de los infectados debe ser positiva:

$$\left.\frac{di}{dt}\right|_{t=0} > 0 \implies \beta s(0)i(0) - \gamma i(0) > 0$$

Factorizando $\gamma i(0)$ y asumiendo $i(0) > 0$:

$$\gamma i(0)\left(\frac{\beta}{\gamma}s(0) - 1\right) > 0$$

Recordando la definición del número de reproducción $R_0 = \beta/\gamma$:

$$\mathbf{s(0)R_0 > 1}$$

Si esta condición se cumple, el modelo determinista asegura un brote exponencial. □

Solución (d): Extinción Estocástica Temprana. Consideremos la dinámica estocástica real desde el instante $t = 0$, con el paciente cero ($I_0 = 1$ y $S_0 = N - 1$). Existen dos posibles primeros eventos competitivos en el sistema:

1. Infección: Ocurre con tasa $\lambda_{\text{inf}} = \frac{\beta(N-1)(1)}{N} \approx \beta$.
2. Recuperación: Ocurre con tasa $\lambda_{\text{rec}} = \gamma(1) = \gamma$.

Por las propiedades de los relojes exponenciales competitivos, la probabilidad de que el paciente cero se recupere *antes* de infectar a alguien es:

$$P(\text{Extinción inmediata}) = \frac{\lambda_{\text{rec}}}{\lambda_{\text{inf}} + \lambda_{\text{rec}}} \approx \frac{\gamma}{\beta + \gamma}$$

Dividiendo el numerador y denominador por γ:

$$P(\text{Extinción inmediata}) \approx \mathbf{\frac{1}{R_0 + 1}}$$

Dado que $\gamma > 0$ y $\beta > 0$, esta probabilidad es estrictamente mayor a cero, **incluso si** $R_0 > 1$. El tiempo esperado para que ocurra este primer evento competitivo es $\frac{1}{\beta+\gamma}$, que es del orden $\mathcal{O}(\mathbf{1}/\gamma)$.

Conclusión:
Si $R_0 > 1$, la predicción determinista de las EDOs (inciso c) afirma categóricamente que $di/dt > 0$, garantizando un brote macroscópico sin excepciones. Sin embargo, el modelo estocástico revela que la naturaleza discreta del paciente cero implica un juego de azar inicial. Existe una probabilidad genuina ($\approx 1/(R_0+1)$) de que la epidemia sea sofocada en unos pocos días ($\mathcal{O}(1/\gamma)$) simplemente porque el primer individuo tuvo un sistema inmunológico rápido o suerte en sus contactos, evidenciando el profundo "punto ciego"de las ecuaciones diferenciales en tamaños poblacionales pequeños. □

6.12. Modelo de filas en tándem

Ejercicio 6.13. Modelo de filas en tándem

Dos colas en tándem: los clientes llegan a la cola 1 (tasa λ, servicio μ_1) y al terminar pasan a la cola 2 (servicio μ_2). Sea (X_t, Y_t) el par de números de clientes en cada cola.
(a) Escriba el generador del proceso en $\mathbb{N}_0 \times \mathbb{N}_0$ identificando las tasas de transición.
(b) Use el teorema de Burke: si $\lambda < \mu_1$, la salida de la cola 1 es un proceso de Poisson de tasa λ. Enuncie y justifique este resultado.
(c) Deduzca que en equilibrio (X_t, Y_t) tiene distribución producto: $\pi(x, y) = \pi_1(x)\pi_2(y)$, donde π_j es la estacionaria de M/M/1 con $\rho_j = \lambda/\mu_j < 1$.
(d) Calcule el tiempo medio total en el sistema (ambas colas) usando la Ley de Little.

Teorema de Burke y Redes de Jackson

El Teorema de Burke es el pilar de la teoría de redes de colas. Nos asegura que un servidor M/M/1 estable no solo procesa clientes, sino que "mantiene la forma"probabilística del flujo original: entra Poisson, sale Poisson. Esto permite descomponer redes complejas en colas independientes.

Solución (a): Generador del Proceso. El espacio de estados es bidimensional: $S = \mathbb{N}_0 \times \mathbb{N}_0$. Identificamos los tres eventos posibles y sus respectivas tasas de transición desde un estado genérico (x, y):

- **Llegada del exterior a la Cola 1:** Incrementa X_t en 1.

$$q((x, y), (x + 1, y)) = \lambda$$

- **Servicio en Cola 1 y paso a Cola 2:** Decrementa X_t en 1 e incrementa Y_t en 1. Solo ocurre si hay clientes en la primera cola ($x > 0$).

$$q((x, y), (x - 1, y + 1)) = \mu_1 \quad \text{si } x > 0$$

- **Servicio en Cola 2 y salida del sistema:** Decrementa Y_t en 1. Solo ocurre si hay clientes en la segunda cola ($y > 0$).

$$q((x, y), (x, y - 1)) = \mu_2 \quad \text{si } y > 0$$

Para cualquier otro par de estados que no siga estos patrones, la tasa de transición es 0. □

Solución (b): Teorema de Burke. **Enunciado:** En estado estacionario, el proceso de salidas de una cola M/M/1 estable (con tasa de llegada λ y tasa de servicio μ_1, donde $\lambda < \mu_1$) es un proceso de Poisson con tasa λ. Además, en cualquier instante t, el número de clientes en el sistema es independiente del proceso de salidas antes de t.

Justificación (por Reversibilidad): Una cola M/M/1 es un proceso de nacimiento-muerte estocástico, y sabemos (por el Ejercicio 4.6) que todo proceso de nacimiento-muerte estacionario es **reversible en el tiempo**.

Si grabamos la dinámica de la cola y la reproducimos en reversa (hacia atrás en el tiempo):

1. Las *salidas* (muertes) en el tiempo hacia adelante se convierten visualmente en *llegadas* (nacimientos) en el tiempo hacia atrás.

2. Como el proceso es reversible, el comportamiento probabilístico hacia atrás debe ser idéntico al comportamiento hacia adelante.

3. Dado que las llegadas hacia adelante forman un proceso de Poisson de tasa λ, las "llegadas hacia atrás"también deben ser un proceso de Poisson de tasa λ.

Por lo tanto, concluimos que las salidas originales también forman rigurosamente un proceso de Poisson de tasa λ. □

Solución (c): Distribución Producto en Equilibrio. Para la primera cola, es un sistema M/M/1 estándar. Su distribución estacionaria marginal es conocida:

$$\pi_1(x) = (1-\rho_1)\rho_1^x, \quad \text{donde } \rho_1 = \lambda/\mu_1 < 1$$

Por el **Teorema de Burke** justificado en el inciso anterior, el flujo de clientes que abandona la cola 1 (y por ende, el que ingresa a la cola 2) es un proceso de Poisson puro de tasa λ. Además, este flujo es independiente del estado actual de la cola 1.

Desde la perspectiva de la Cola 2, recibe llegadas de Poisson a tasa λ y tiene tiempos de servicio exponenciales a tasa μ_2. Esto la convierte matemáticamente en **otra cola M/M/1 pura**. Su distribución marginal es:

$$\pi_2(y) = (1-\rho_2)\rho_2^y, \quad \text{donde } \rho_2 = \lambda/\mu_2 < 1$$

Debido a la independencia de las colas en estado estacionario (garantizada por la segunda parte del Teorema de Burke), la probabilidad conjunta es simplemente el producto de sus probabilidades marginales:

$$\boldsymbol{\pi(\mathbf{x},\mathbf{y}) = \pi_1(\mathbf{x})\pi_2(\mathbf{y}) = (1-\rho_1)(1-\rho_2)\rho_1^{\mathbf{x}}\rho_2^{\mathbf{y}}}$$

□

Solución (d): Tiempo Medio Total (Ley de Little). Para encontrar el tiempo medio total W que un cliente pasa en el sistema (esperando y siendo servido en ambas colas), aplicamos la **Ley de Little**: $L = \lambda W$.

Primero calculamos el número medio total de clientes en el sistema, L. Dado que $L = E[X] + E[Y]$, y cada cola es una M/M/1 independiente:

$$E[X] = \frac{\rho_1}{1-\rho_1} = \frac{\lambda}{\mu_1 - \lambda}$$

$$E[Y] = \frac{\rho_2}{1-\rho_2} = \frac{\lambda}{\mu_2 - \lambda}$$

Sumamos para obtener L:

$$L = \frac{\lambda}{\mu_1 - \lambda} + \frac{\lambda}{\mu_2 - \lambda}$$

Finalmente, despejamos W dividiendo entre la tasa de llegadas global λ:

$$W = \frac{L}{\lambda} = \frac{1}{\lambda}\left[\frac{\lambda}{\mu_1 - \lambda} + \frac{\lambda}{\mu_2 - \lambda}\right]$$

$$\mathbf{W} = \frac{\mathbf{1}}{\mu_1 - \lambda} + \frac{\mathbf{1}}{\mu_2 - \lambda}$$

Interpretación: El tiempo total esperado es exactamente la suma de los tiempos esperados de dos sistemas M/M/1 aislados. El cuello de botella (la μ más cercana a λ) dominará el tiempo total de espera. □

6.13. Canal de comunicación binario

Ejercicio 6.14. Canal de comunicación binario

Se transmite una secuencia de bits por un canal ruidoso. Sea (X_n) una cadena en $\{0,1\}$: $p(0,1) = \epsilon$, $p(1,0) = \epsilon$ (tasa de error simétrica).
(a) Calcule la medida estacionaria $\pi(0) = \pi(1) = 1/2$ y verifique la reversibilidad.
(b) Calcule $p^n(0,0) = \frac{1}{2}(1 + (1-2\epsilon)^n)$ y analice la convergencia al equilibrio.
(c) Si el bit transmitido es x y el recibido es Y con $P(Y \neq x) = \epsilon$, calcule la capacidad del canal $C = 1 - H(\epsilon)$, donde $H(\epsilon) = -\epsilon \log_2 \epsilon - (1-\epsilon)\log_2(1-\epsilon)$ es la entropía binaria.
(d) Sea $(X_0, X_1, \ldots, X_{n-1})$ la secuencia de bits original y $(Y_0, \ldots, Y_{n-1})$ la recibida. Calcule la probabilidad de que la secuencia recibida tenga exactamente k errores.

Entropía y Ruido

La entropía binaria $H(\epsilon)$ mide la incertidumbre introducida por el canal. Si $\epsilon = 0{,}5$, el canal es puro ruido y no transmite información ($C = 0$). Si $\epsilon = 0$, el canal es perfecto ($C = 1$). Curiosamente, si $\epsilon = 1$, el canal también tiene capacidad $C = 1$, ¡solo hay que invertir todos los bits recibidos!

Solución (a): Medida Estacionaria y Reversibilidad. La matriz de transición del canal es:

$$P = \begin{pmatrix} 1-\epsilon & \epsilon \\ \epsilon & 1-\epsilon \end{pmatrix}$$

Para hallar la medida estacionaria $\pi = (\pi_0, \pi_1)$, resolvemos $\pi P = \pi$:

$$\pi_0(1-\epsilon) + \pi_1\epsilon = \pi_0 \implies \pi_1\epsilon = \pi_0\epsilon \implies \pi_1 = \pi_0$$

Dado que $\pi_0 + \pi_1 = 1$, obtenemos $\pi(\mathbf{0}) = \pi(\mathbf{1}) = \mathbf{1/2}$.

Para verificar la **reversibilidad**, comprobamos el balance detallado $\pi(x)p(x,y) = \pi(y)p(y,x)$:

$$\pi(0)p(0,1) = \frac{1}{2} \cdot \epsilon$$

$$\pi(1)p(1,0) = \frac{1}{2} \cdot \epsilon$$

Como ambos términos son idénticos, la cadena es reversible. Físicamente, esto significa que el canal es estadísticamente igual si lo recorremos en cualquier sentido de transmisión. □

Solución (b): Probabilidades de n-pasos y Convergencia. Utilizamos la diagonalización de la matriz P. Los valores propios de P son $\lambda_1 = 1$ (siempre para matrices estocásticas) y $\lambda_2 = (1-\epsilon)-\epsilon = 1-2\epsilon$. La matriz de transición de n pasos tiene la forma:

$$P^n = \frac{1}{2}\begin{pmatrix} 1+\lambda_2^n & 1-\lambda_2^n \\ 1-\lambda_2^n & 1+\lambda_2^n \end{pmatrix}$$

Extrayendo la entrada $p^n(0,0)$:

$$\mathbf{p^n(0,0) = \frac{1}{2}(1 + (1-2\epsilon)^n)}$$

Análisis de convergencia:
Si $0 < \epsilon < 1$, entonces $|1-2\epsilon| < 1$. Al tomar el límite cuando $n \to \infty$:

$$\lim_{n\to\infty} p^n(0,0) = \frac{1}{2}(1+0) = \frac{1}{2} = \pi(0)$$

La cadena converge al equilibrio uniformemente. La velocidad de convergencia depende de cuán lejos esté ϵ de 0,5. Si $\epsilon = 0{,}5$, el equilibrio es instantáneo en un solo paso. □

Solución (c): Capacidad del Canal de Shannon. La capacidad C de un canal simétrico se define como el máximo de la información mutua $I(X;Y)$ sobre todas las distribuciones de entrada $P(X)$.

$$I(X;Y) = H(Y) - H(Y|X)$$

Para un canal simétrico, $H(Y|X)$ es constante e igual a la entropía del ruido en cada bit:

$$H(Y|X = x) = -\epsilon \log_2 \epsilon - (1-\epsilon)\log_2(1-\epsilon) = H(\epsilon)$$

Para maximizar $I(X;Y)$, debemos maximizar $H(Y)$. El valor máximo de la entropía para una variable binaria es 1 bit, alcanzado cuando Y es uniforme ($P(Y=0) = P(Y=1) = 1/2$). Como demostramos en el inciso (a), si la entrada X es uniforme, la salida Y también lo es. Por lo tanto:

$$\mathbf{C = 1 - H}(\epsilon)$$

□

Solución (d): Probabilidad de k errores. En un canal de comunicación binario, se asume que cada bit se transmite de forma independiente (ruido blanco). Para cada bit i, definimos una variable de error E_i tal que $E_i = 1$ si $Y_i \neq X_i$ (ocurre un error con probabilidad ϵ) y $E_i = 0$ si $Y_i = X_i$ (transmisión correcta con probabilidad $1-\epsilon$).

El número total de errores en una secuencia de longitud n es $K = \sum_{i=0}^{n-1} E_i$. Dado que los errores son ensayos de Bernoulli independientes con probabilidad de éxito ϵ, la variable aleatoria K sigue una **distribución Binomial**:

$$\mathbf{P(K = k) = \binom{n}{k} \epsilon^{k} (1-\epsilon)^{n-k}}$$

□

6.14. Modelo de inventario

Ejercicio 6.15. Modelo de inventario

Un almacén tiene capacidad máxima M. Al inicio de cada periodo, si el inventario $X_n \leq s$ (nivel de reorden), se hace un pedido que eleva el nivel a S. Luego llega una demanda D_n i.i.d. con distribución $P(D = k) = d_k$ $(k \geq 0)$, y el nivel al final del periodo es $X_{n+1} = \text{máx}(S - D_n, 0)$ si se hizo pedido, o $X_{n+1} = \text{máx}(X_n - D_n, 0)$ en otro caso.
(a) Modele (X_n) como cadena de Markov en $\{0, \ldots, M\}$ y escriba las probabilidades de transición $p(x, y)$.
(b) Determine bajo qué condiciones la cadena es irreducible y establezca la existencia de una medida estacionaria π.
(c) Calcule $E^\pi[X_n]$ (nivel medio de inventario) y $P^\pi(X_n = 0)$ (probabilidad de agotamiento).
(d) Use la ley ergódica para estimar el costo medio por periodo $c(X_n) = hX_n + b\mathbf{1}_{\{X_n=0\}}$, donde h es el costo de mantenimiento y b la penalización por agotamiento.

Política de Inventario

Esta política busca equilibrar dos costos contrapuestos: el costo de ordenar (que favorece pedidos grandes y poco frecuentes) y el costo de almacenamiento (que favorece mantener poco inventario). El nivel s protege contra la incertidumbre de la demanda mientras llega el pedido.

Solución (a): Modelado y Probabilidades de Transición. El estado X_n representa el inventario al final del periodo n. La dinámica de transición depende de si el nivel actual x activa o no un pedido:

Caso 1: $x \leq s$ (se hace pedido). El nivel sube inmediatamente a S y luego se resta la demanda D_n. Entonces:

$$p(x, y) = \begin{cases} d_{S-y} & \text{si } 1 \leq y \leq S, \\ \sum_{k=S}^{\infty} d_k & \text{si } y = 0, \\ 0 & \text{si } y > S. \end{cases}$$

Caso 2: $x > s$ (no se hace pedido). El nivel permanece en x y se resta la demanda D_n. Entonces:

$$p(x, y) = \begin{cases} d_{x-y} & \text{si } 1 \leq y \leq x, \\ \sum_{k=x}^{\infty} d_k & \text{si } y = 0, \\ 0 & \text{si } y > x. \end{cases}$$

En ambos casos, $p(x, y)$ no depende de n, por lo que (X_n) es una cadena de Markov homogénea. □

Solución (b): Irreducibilidad y estacionariedad. **Irreducibilidad:** La cadena es irreducible si todos los estados se comunican. Una condición suficiente es:

1. $d_k > 0$ para todo $k \in \{0, \ldots, S\}$,
2. $S \leq M$ (consistencia del modelo).

Bajo estas condiciones:

- Desde cualquier estado se puede alcanzar 0 con probabilidad positiva.
- Desde 0 se alcanza S (por la política de reorden).
- Desde S se puede alcanzar cualquier estado intermedio.

Por lo tanto, la cadena es irreducible.

Existencia de π: Como el espacio de estados $\{0, \ldots, M\}$ es finito e irreducible, la cadena es positiva recurrente y existe una única distribución estacionaria π que satisface

$$\pi P = \pi, \quad \sum_{j=0}^{M} \pi(j) = 1.$$

□

Solución (c): Nivel medio y agotamiento. Una vez obtenida la distribución estacionaria π, los estadísticos de interés son:

Nivel medio de inventario:

$$E^{\pi}[X_n] = \sum_{j=0}^{M} j\,\pi(j).$$

Probabilidad de agotamiento:

$$P^{\pi}(X_n = 0) = \pi(0).$$

□

Solución (d): Costo medio. Por la ley ergódica para cadenas de Markov finitas e irreducibles:

$$\lim_{n\to\infty} \frac{1}{n} \sum_{k=1}^{n} c(X_k) = E^{\pi}[c(X)].$$

Sustituyendo $c(x) = hx + b\mathbf{1}_{\{x=0\}}$:

$$E^{\pi}[c(X)] = h \sum_{j=0}^{M} j\pi(j) + b\pi(0).$$

Por lo tanto,

$$E^{\pi}[c(X)] = h\,E^{\pi}[X_n] + b\,\pi(0).$$

Este valor representa el costo promedio por periodo en el largo plazo. □

6.15. Proceso de degradación y mantenimiento.

Ejercicio 6.16. Proceso de degradación y mantenimiento

Un sistema se degrada con el tiempo. Sea $X_n \in \{0, 1, 2, 3\}$ el nivel de condición: 0 = nuevo, 3 = falla. Las probabilidades de transición son: $p(i, i+1) = \alpha_i$ (degradación) y $p(i, 0) = \beta_i$ (mantenimiento preventivo), con $\alpha_i + \beta_i \leq 1$ y la parte restante en $p(i, i) = 1 - \alpha_i - \beta_i$.
(a) Escriba la matriz de transición P con parámetros α_i y β_i e identifique el estado absorbente (falla).
(b) Calcule $E^0[T_{\{3\}}]$ (tiempo esperado hasta la falla en ausencia de mantenimiento: $\beta_i = 0$).
(c) Con mantenimiento ($\beta_i > 0$), calcule la medida estacionaria π del sistema (sin estado de falla absorbente) y el porcentaje de tiempo en el que el sistema está operativo.
(d) Optimice los parámetros β_i para minimizar el costo total por periodo $\sum_i \pi(i)c_i$, donde c_i es el costo de mantenimiento en el estado i.

Confiabilidad y Disponibilidad

En este modelo, el estado 3 no suele tener mantenimiento preventivo ($\beta_3 = 0$) porque ya ha fallado; en su lugar, requeriría un mantenimiento correctivo (reparación) para volver a 0. La disponibilidad del sistema es la suma de las probabilidades estacionarias de los estados operativos $\{0, 1, 2\}$.

Solución (a): Matriz de Transición y Absorción. Basándonos en las reglas de transición, la matriz P de 4×4 es:

$$P = \begin{pmatrix} 1-\alpha_0-\beta_0 & \alpha_0 & 0 & 0 \\ \beta_1 & 1-\alpha_1-\beta_1 & \alpha_1 & 0 \\ \beta_2 & 0 & 1-\alpha_2-\beta_2 & \alpha_2 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Estado Absorbente: El estado **3 (falla)** es absorbente ya que $p(3, 3) = 1$. Una vez que el sistema entra en falla, no puede salir de ella mediante degradación o mantenimiento preventivo ordinario (según la definición del problema). □

Solución (b): Tiempo Esperado hasta la Falla. En ausencia de mantenimiento, establecemos $\beta_i = 0$ para todo i. La matriz se convierte en una cadena de saltos hacia adelante:

$$P = \begin{pmatrix} 1-\alpha_0 & \alpha_0 & 0 & 0 \\ 0 & 1-\alpha_1 & \alpha_1 & 0 \\ 0 & 0 & 1-\alpha_2 & \alpha_2 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Sea $v_i = E^i[T_{\{3\}}]$. Aplicando el análisis del primer paso:

$$v_i = 1 + \sum_j p_{ij} v_j$$

Para $i = 2$: $v_2 = 1 + (1-\alpha_2)v_2 + \alpha_2(0) \implies \alpha_2 v_2 = 1 \implies v_2 = 1/\alpha_2$. Para $i = 1$: $v_1 = 1 + (1-\alpha_1)v_1 + \alpha_1 v_2 \implies \alpha_1 v_1 = 1 + \alpha_1(1/\alpha_2) \implies v_1 = \frac{1}{\alpha_1} + \frac{1}{\alpha_2}$.

Por inducción, el tiempo esperado iniciando desde "nuevo"($i = 0$) es la suma de los tiempos medios de estancia en cada nivel de degradación:

$$\mathbf{E^0[T_{\{3\}}] = \frac{1}{\alpha_0} + \frac{1}{\alpha_1} + \frac{1}{\alpha_2}}$$

□

Solución (c): Medida Estacionaria y Operatividad. Para que el sistema tenga una medida estacionaria, el estado 3 debe dejar de ser absorbente (por ejemplo, asumiendo una reparación inmediata $p(3,0) = 1$). Si $\beta_i > 0$, el sistema fluye constantemente de regreso a 0.

Planteamos el balance de flujo para π:

- Para el estado 1: $\pi_0\alpha_0 = \pi_1(\beta_1 + \alpha_1)$ (Flujo de entrada desde 0 = Flujo de salida a 0 o 2).
- Para el estado 2: $\pi_1\alpha_1 = \pi_2(\beta_2 + \alpha_2)$.

Esto permite expresar cada π_i en términos de π_0:

$$\pi_1 = \pi_0 \frac{\alpha_0}{\alpha_1 + \beta_1}, \quad \pi_2 = \pi_1 \frac{\alpha_1}{\alpha_2 + \beta_2} = \pi_0 \frac{\alpha_0\alpha_1}{(\alpha_1 + \beta_1)(\alpha_2 + \beta_2)}$$

Usando la normalización $\sum \pi_i = 1$, despejamos π_0. El **porcentaje de tiempo operativo** es la probabilidad de no estar en falla:

$$\text{Disponibilidad} = \boldsymbol{\pi_0 + \pi_1 + \pi_2 = 1 - \pi_3}$$

□

Solución (d): Optimización de Costos. Queremos minimizar $C(\beta_1, \beta_2) = \pi_0 c_0 + \pi_1 c_1 + \pi_2 c_2 + \pi_3 c_3$. Sustituimos las expresiones de π_i obtenidas en el inciso anterior. Notamos que:

- Si β_i es muy alto, π_0 aumenta (el sistema está siempre nuevo), pero el costo total sube porque c_i (costo de mantenimiento) se paga con mucha frecuencia.
- Si β_i es muy bajo, π_3 aumenta (el sistema falla), y si el costo de reparación c_3 es muy alto, el costo total también sube.

El valor óptimo β_i^* se encuentra derivando la función de costo respecto a cada β_i e igualando a cero:

$$\frac{\partial C}{\partial \beta_1} = 0, \quad \frac{\partial C}{\partial \beta_2} = 0$$

Esto resulta en un sistema de ecuaciones donde el mantenimiento preventivo óptimo debe equilibrar el **costo marginal de mantenimiento** con el **ahorro marginal por evitar la falla**. □

6.16. Modelo de compartimentos farmacocinéticos

Ejercicio 6.17. Modelo de compartimentos farmacocinéticos

Un medicamento se distribuye entre dos compartimentos: sangre (C_1) y tejido (C_2). Sea (X_t, Y_t) las concentraciones en C_1 y C_2. A nivel estocástico discreto, las moléculas de fármaco se mueven entre compartimentos con tasas k_{12} (sangre→tejido) y k_{21} (tejido→sangre), y se eliminan de la sangre con tasa k_{10}.
(a) Modele el número de moléculas en cada compartimento como una cadena de Markov a tiempo continuo y escriba el generador.
(b) Derive las ecuaciones diferenciales (deterministas) para las concentraciones medias $\mu_1(t) = E[X_t]$ y $\mu_2(t) = E[Y_t]$: $\dot{\mu}_1 = -(k_{12} + k_{10})\mu_1 + k_{21}\mu_2$, $\dot{\mu}_2 = k_{12}\mu_1 - k_{21}\mu_2$.
(c) Calcule $\mu_1(t)$ y $\mu_2(t)$ para la condición inicial $\mu_1(0) = D$, $\mu_2(0) = 0$ (dosis única).
(d) Determine el área bajo la curva $AUC = \int_0^\infty \mu_1(t)dt$ y exprésela en función de los parámetros.

Linealidad y Superposición

Este modelo es de "primer orden", lo que significa que la tasa de cambio es proporcional a la cantidad presente. En sistemas estocásticos lineales, las ecuaciones para las esperanzas coinciden exactamente con las ecuaciones cinéticas deterministas clásicas.

Solución (a): Modelado y Generador. El estado del sistema es el par $(n_1, n_2) \in \mathbb{N}_0^2$ que representa el número de moléculas en cada compartimento. Las tasas de transición son:

- Infección/Migración $1 \to 2$: $q((n_1, n_2), (n_1 - 1, n_2 + 1)) = k_{12}n_1$.
- Migración $2 \to 1$: $q((n_1, n_2), (n_1 + 1, n_2 - 1)) = k_{21}n_2$.
- Eliminación: $q((n_1, n_2), (n_1 - 1, n_2)) = k_{10}n_1$.

El generador $\mathcal{A}$ actuando sobre una función $f(n_1, n_2)$ es:

$$\mathcal{A}f = k_{12}n_1[f(n_1 - 1, n_2 + 1) - f] + k_{21}n_2[f(n_1 + 1, n_2 - 1) - f] + k_{10}n_1[f(n_1 - 1, n_2) - f]$$

□

Solución (b): Ecuaciones de la Media. Usamos la propiedad $\frac{d}{dt}E[f(X_t)] = E[\mathcal{A}f(X_t)]$. Para $\mu_1(t)$, sea $f(n_1, n_2) = n_1$:

$$\dot{\mu}_1 = E[k_{12}X_t(-1) + k_{21}Y_t(1) + k_{10}X_t(-1)] = -(\mathbf{k_{12}} + \mathbf{k_{10}})\boldsymbol{\mu_1} + \mathbf{k_{21}}\boldsymbol{\mu_2}$$

Para $\mu_2(t)$, sea $f(n_1, n_2) = n_2$:

$$\dot{\mu}_2 = E[k_{12}X_t(1) + k_{21}Y_t(-1)] = \mathbf{k_{12}}\boldsymbol{\mu_1} - \mathbf{k_{21}}\boldsymbol{\mu_2}$$

□

Solución (c): Resolución del Sistema. El sistema matricial es $\dot{\vec{\mu}} = M\vec{\mu}$ con $M = \begin{pmatrix} -(k_{12} + k_{10}) & k_{21} \\ k_{12} & -k_{21} \end{pmatrix}$.
Los valores propios λ_1, λ_2 son las raíces del polinomio característico:

$$\lambda^2 + (k_{12} + k_{10} + k_{21})\lambda + k_{10}k_{21} = 0$$

Ambas raíces son negativas. La solución general para la sangre es una suma de exponenciales (disposición biexponencial):

$$\boldsymbol{\mu_1(t)} = \mathbf{A}\mathbf{e}^{\boldsymbol{\lambda_1 t}} + \mathbf{B}\mathbf{e}^{\boldsymbol{\lambda_2 t}}$$

donde $A + B = D$. Para el tejido, $\mu_2(t)$ sube desde 0 hasta un máximo y luego decae. □

Solución (d): Área Bajo la Curva (AUC). Integramos la primera ecuación diferencial de (b) desde 0 a ∞:

$$\int_0^\infty \dot{\mu}_1 dt = -(k_{12} + k_{10}) \int_0^\infty \mu_1 dt + k_{21} \int_0^\infty \mu_2 dt$$

Sabemos que $\mu_1(\infty) = 0$ y $\mu_1(0) = D$, por lo que el lado izquierdo es $-D$. De la segunda ecuación en equilibrio de integrales (donde $\int \dot{\mu}_2 = 0$):

$$k_{12} \int \mu_1 dt = k_{21} \int \mu_2 dt \implies \int \mu_2 dt = \frac{k_{12}}{k_{21}} AUC$$

Sustituyendo en la primera integral:

$$-D = -(k_{12} + k_{10}) AUC + k_{21} \left(\frac{k_{12}}{k_{21}} AUC \right)$$

$$-D = -k_{12} AUC - k_{10} AUC + k_{12} AUC \implies D = k_{10} AUC$$

$$\mathbf{AUC} = \frac{\mathbf{D}}{\mathbf{k_{10}}}$$

Interpretación: El AUC depende únicamente de la dosis y la tasa de eliminación, no de cómo se distribuya internamente el fármaco. □

6.17. Ley de Benford y caminatas en grupos abelianos

Ejercicio 6.18. Ley de Benford y caminatas en grupos abelianos

La ley de Benford afirma que el primer dígito significativo de muchos conjuntos de datos naturales tiene distribución $P(D = d) = \log_{10}(1 + 1/d)$ para $d = 1, \ldots, 9$.
(a) Considere la caminata aleatoria en $\mathbb{Z}_{10}$ (enteros módulo 10) con pasos i.i.d. uniformes. Calcule la medida estacionaria y el tiempo de mezcla.
(b) Sea (X_n) una cadena de Markov en el conjunto de los primeros dígitos $\{1, \ldots, 9\}$ inducida por la operación $X_{n+1} = \text{primer_digito}(X_n \cdot U_n)$, donde U_n son factores aleatorios. Explique por qué la ley de Benford es la medida estacionaria cuando los factores se distribuyen en escala logarítmica.
(c) Calcule la entropía $H = -\sum_{d=1}^{9} \pi(d) \log \pi(d)$ de la ley de Benford y compárela con la de la uniforme.
(d) Use el teorema ergódico para justificar que la proporción de primeros dígitos iguales a d en una secuencia larga converge a $\pi(d)$.

Invarianza de Escala

La Ley de Benford es la única distribución del primer dígito que es invariante ante cambios de escala. Si mides una lista de longitudes en metros y cumple Benford, al convertirlas a pies seguirá cumpliendo Benford. Esta propiedad está ligada a que la mantisa de los logaritmos de los datos se distribuye uniformemente.

Solución (a): Caminata en $\mathbb{Z}_{10}$. En el grupo abeliano $\mathbb{Z}_{10}$, consideramos una caminata aleatoria donde en cada paso sumamos un incremento $U \sim \text{Uniforme}\{0, \ldots, 9\}$. La matriz de transición P tiene entradas $p_{ij} = 1/10$ para todo $i, j \in \{0, \ldots, 9\}$.

Al ser P una matriz con todas sus entradas iguales y positivas (matriz de rango 1), se cumplen dos cosas:

1. **Medida estacionaria:** Como P es doblemente estocástica, la medida estacionaria es la uniforme:
$$\boldsymbol{\pi(\mathbf{j}) = \frac{1}{10} \quad \forall \mathbf{j} \in \{0, \ldots, 9\}}$$
2. **Tiempo de mezcla:** Dado que $p_{ij} = \pi(j)$ para todo i, j, la cadena alcanza el equilibrio exactamente en $n = 1$ paso. La distancia en variación total $d(1) = 0$. Por lo tanto:
$$\mathbf{t_{\text{mix}} = 1}$$

□

Solución (b): Justificación de la Ley de Benford. Sea $Y = \log_{10}(X)$. El primer dígito de un número X está determinado únicamente por la parte fraccionaria (mantisa) de su logaritmo decimal: $M = \log_{10} X \pmod 1$. Un número tiene primer dígito d si y solo si:
$$\log_{10}(d) \leq M < \log_{10}(d + 1)$$

La operación multiplicativa $X_{n+1} = X_n \cdot U_n$ se transforma en el dominio logarítmico en una caminata aleatoria aditiva:
$$\log_{10} X_{n+1} = \log_{10} X_n + \log_{10} U_n \pmod 1$$

Como vimos en el inciso (a), una caminata aditiva en un grupo (en este caso el círculo unitario $\mathbb{R}/\mathbb{Z}$ de las mantisas) converge a la **medida uniforme** bajo condiciones de mezcla. Si la mantisa M se distribuye uniformemente en $[0, 1)$, la probabilidad de observar el dígito d es la longitud del intervalo $[\log_{10} d, \log_{10}(d + 1))$:
$$P(D = d) = \log_{10}(d + 1) - \log_{10}(d) = \boldsymbol{\log_{10}\left(1 + \frac{1}{d}\right)}$$

Esta es precisamente la medida de Benford. □

Solución (c): Comparación de Entropías. **1. Distribución Uniforme ($\pi_u(d) = 1/9$):** Para 9 estados, la entropía es máxima:

$$H_u = \log_2(9) \approx \mathbf{3{,}17} \text{ bits}$$

2. Distribución de Benford (π_B): Sustituimos $\pi_B(d) = \log_{10}(1 + 1/d)$ en la fórmula de Shannon:

$$H_B = -\sum_{d=1}^{9} \log_{10}\left(1 + \frac{1}{d}\right) \log_2\left(\log_{10}\left(1 + \frac{1}{d}\right)\right) \approx \mathbf{2{,}88} \text{ bits}$$

Comparación: $H_B < H_u$. Esto es consistente con el principio de que la distribución uniforme maximiza la entropía. La Ley de Benford tiene menor entropía porque es una distribución "sesgada"(el 1 es mucho más probable que el 9), lo que implica que hay menos incertidumbre sobre cuál será el primer dígito en un sistema Benfordiano que en uno puramente aleatorio. □

Solución (d): Aplicación del Teorema Ergódico. Sea (X_n) la cadena de los primeros dígitos. Si la cadena es irreducible y aperiódica (lo cual se cumple si los factores U_n tienen suficiente dispersión logarítmica), el **Teorema Ergódico** garantiza que para la función indicadora $f(x) = \mathbf{1}_{\{x=d\}}$:

$$\lim_{n\to\infty} \frac{1}{n} \sum_{k=0}^{n-1} \mathbf{1}_{\{X_k=d\}} = E^{\pi}[\mathbf{1}_{\{X=d\}}] = \pi(d) \quad \text{casi seguramente.}$$

Esto significa que si tomamos una secuencia de datos generada por un proceso multiplicativo (como el crecimiento de una cuenta bancaria o una población), la frecuencia relativa con la que aparece el dígito d al inicio de los números convergerá inevitablemente a los valores predichos por la Ley de Benford. □

6.18. Modelo de recombinación genética

Ejercicio 6.19. Modelo de recombinación genética: cadena en $\{0,1\}^L$

En genética de poblaciones, se estudia la propagación de L loci biálicos en una población grande. Sea $X_n \in \{0,1\}^L$ el haplotipo de un individuo al azar en la generación n.
(a) Bajo el modelo de recombinación libre, los loci evolucionan independientemente. Modele la cadena y calcule la medida estacionaria $\pi(x) = \prod_{\ell=1}^{L} p_\ell^{x_\ell}(1-p_\ell)^{1-x_\ell}$.
(b) Con mutación a tasa μ por locus y generación, escriba las probabilidades de transición de un locus y calcule la medida estacionaria marginal.
(c) Calcule el tiempo de mezcla para que la distribución del haplotipo se aproxime a π, y muestre que crece como $\mathcal{O}(1/\mu)$.
(d) Interprete el equilibrio de mutación-selección cuando el locus ℓ tiene un factor de selección s_ℓ que favorece el alelo 1.

El Hipercubo Genético

El espacio de estados es un hipercubo de dimensión L. Con la recombinación libre, los alelos se "mezclan"tan eficientemente que el estado del sistema en la siguiente generación es simplemente una muestra aleatoria basada en las frecuencias alélicas actuales, rompiendo las correlaciones (desequilibrio de ligamiento).

Solución (a): Recombinación Libre y Producto de Medidas. Bajo recombinación libre infinita, cada locus $\ell \in \{1,\dots,L\}$ en la generación $n+1$ se hereda independientemente de la población. Sea p_ℓ la frecuencia del alelo '1' en el locus ℓ.

La probabilidad de observar un haplotipo $x = (x_1, x_2, \dots, x_L)$ es el producto de las probabilidades de observar cada alelo de forma independiente:

$$P(X = x) = P(X_1 = x_1) \cdot P(X_2 = x_2) \cdots P(X_L = x_L)$$

Como cada locus es una variable Bernoulli con parámetro p_ℓ:

$$\pi(\mathbf{x}) = \prod_{\ell=1}^{\mathbf{L}} \mathbf{p}_\ell^{\mathbf{x}_\ell}(\mathbf{1}-\mathbf{p}_\ell)^{\mathbf{1}-\mathbf{x}_\ell}$$

Esta medida se conoce como el **Equilibrio de Ligamiento**. □

Solución (b): Mutación y Medida Marginal. Consideremos un solo locus ℓ. La mutación a tasa μ implica que un alelo 0 puede cambiar a 1 con probabilidad μ, y viceversa. La matriz de transición marginal P_ℓ es idéntica a la del canal simétrico binario (Ejercicio 6.14):

$$P_\ell = \begin{pmatrix} 1-\mu & \mu \\ \mu & 1-\mu \end{pmatrix}$$

Como demostramos anteriormente para matrices simétricas, la medida estacionaria marginal para cada locus es la **uniforme**:

$$\pi_\ell(\mathbf{0}) = \pi_\ell(\mathbf{1}) = \mathbf{1/2}$$

(Esto asume que la mutación es simétrica. Si fuera asimétrica con tasas μ_{01} y μ_{10}, la medida sería $\pi(1) = \mu_{01}/(\mu_{01}+\mu_{10})$). □

Solución (c): Tiempo de Mezcla. Para un solo locus, vimos en el Ejercicio 6.14 que el segundo valor propio es $\lambda_2 = 1 - 2\mu$. El salto espectral es:

$$\text{gap} = 1 - \lambda_2 = 2\mu$$

El tiempo de relajación para un locus es $t_{\text{rel}} = 1/\text{gap} = 1/(2\mu)$.

En una cadena compuesta por L componentes independientes (el hipercubo), el tiempo de mezcla para alcanzar la medida total π está dominado por el componente más lento y el tamaño del sistema. Para el hipercubo con mutaciones independientes, el tiempo de mezcla escala como:

$$t_{\text{mix}} \approx \frac{1}{2\mu} \ln(L)$$

Claramente, para una tasa de mutación pequeña, el tiempo necesario para que la población pierda el sesgo de su estado inicial y alcance el equilibrio genético es inversamente proporcional a μ:

$$\mathbf{t}_{\text{mix}} \in \mathcal{O}(\mathbf{1}/\mu)$$

□

Solución (d): Equilibrio Mutación-Selección. Si introducimos un factor de selección $s_\ell > 0$ que favorece al alelo 1, la probabilidad de que un alelo 1 sobreviva y se reproduzca es mayor que la del alelo 0.

- La **selección** empuja la frecuencia p_ℓ hacia 1 (fijación del alelo ventajoso).
- La **mutación** empuja la frecuencia hacia 1/2 (entropía máxima/ruido).

El equilibrio mutación-selección ocurre cuando ambas fuerzas se cancelan. En el límite de mutación débil, la frecuencia estacionaria del alelo deletéreo (el '0' en este caso) se estabiliza en un valor proporcional a μ/s_ℓ.

Interpretación: El sistema no alcanza la perfección genética (todos '1') porque la mutación actúa como un ruido térmicoçonstante que reintroduce variantes menos aptas, manteniendo una diversidad residual en la población. □

6.19. Red de colas de Jackson

Ejercicio 6.20. Red de colas de Jackson

Una red de K colas: los clientes llegan a la cola k desde afuera con tasa λ_k, reciben servicio con tasa μ_k y se enrutan a la cola j con probabilidad r_{kj} (o salen con probabilidad $1 - \sum_j r_{kj}$). Sea $X_t = (X_t^{(1)}, \dots, X_t^{(K)})$ el vector de longitudes.

Solución

(a) Tasas de llegada efectiva Λ_k

Las tasas efectivas de llegada a cada cola satisfacen las ecuaciones de balance de flujo:

$$\Lambda_k = \lambda_k + \sum_{j=1}^{K} \Lambda_j \, r_{jk}, \qquad k = 1, \dots, K.$$

En forma matricial, con $\mathbf{\Lambda} = (\Lambda_1, \dots, \Lambda_K)^T$, $\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_K)^T$ y $R = (r_{jk})$, se tiene

$$\mathbf{\Lambda} = \boldsymbol{\lambda} + R^T \mathbf{\Lambda} \quad \Longrightarrow \quad (I - R^T)\mathbf{\Lambda} = \boldsymbol{\lambda}.$$

Para una red abierta (existe probabilidad positiva de abandonar el sistema desde cada cola), la matriz $I - R^T$ es invertible y la solución es única.

(b) Teorema de Jackson

Teorema 6.1. Teorema de Jackson (red abierta)

Si las tasas efectivas Λ_k satisfacen las ecuaciones anteriores y se cumple la condición de estabilidad

$$\rho_k = \frac{\Lambda_k}{\mu_k} < 1 \quad \text{para todo } k = 1, \dots, K,$$

entonces la cadena de Markov $\{X_t\}$ es ergódica y su distribución estacionaria es producto de distribuciones geométricas independientes:

$$\pi(\mathbf{x}) = \prod_{k=1}^{K} (1 - \rho_k) \, \rho_k^{x_k}, \qquad \mathbf{x} = (x_1, \dots, x_K) \in \mathbb{N}_0^K.$$

(c) Verificación explícita para $K = 2$, $\lambda_1 = \lambda_2 = \lambda$, $\mu_1 = \mu_2 = \mu$, $r_{12} = r_{21} = 0$

Dado que $r_{12} = r_{21} = 0$, no hay enrutamiento entre colas; todos los clientes abandonan el sistema al terminar su servicio. Las ecuaciones de flujo se reducen a

$$\Lambda_1 = \lambda_1 = \lambda, \qquad \Lambda_2 = \lambda_2 = \lambda.$$

La condición de estabilidad exige $\rho = \lambda/\mu < 1$. El teorema de Jackson predice entonces

$$\pi(x_1, x_2) = (1 - \rho)\rho^{x_1} \cdot (1 - \rho)\rho^{x_2} = (1 - \rho)^2 \rho^{x_1 + x_2}.$$

Verifiquemos directamente las ecuaciones de balance global. Para un estado (x_1, x_2) con $x_1 > 0, x_2 > 0$, la tasa de salida es

$$\pi(x_1, x_2)\big(2\lambda + 2\mu\big).$$

La tasa de entrada proviene de:

- llegada externa a cola 1 desde $(x_1 - 1, x_2)$: $\lambda \, \pi(x_1 - 1, x_2)$;
- llegada externa a cola 2 desde $(x_1, x_2 - 1)$: $\lambda \, \pi(x_1, x_2 - 1)$;
- fin de servicio en cola 1 desde $(x_1 + 1, x_2)$: $\mu \, \pi(x_1 + 1, x_2)$;

- fin de servicio en cola 2 desde (x_1, x_2+1): $\mu\,\pi(x_1, x_2+1)$.

Sumando: $\lambda\big[\pi(x_1-1, x_2) + \pi(x_1, x_2-1)\big] + \mu\big[\pi(x_1+1, x_2) + \pi(x_1, x_2+1)\big]$.

Sustituyendo $\pi(x_1, x_2) = c^2\rho^{x_1+x_2}$ con $c = 1-\rho$, se obtiene:

$$\lambda \cdot 2c^2\rho^{x_1+x_2-1} + \mu \cdot 2c^2\rho^{x_1+x_2+1} = 2c^2\rho^{x_1+x_2-1}\big(\lambda + \mu\rho^2\big).$$

Usando $\lambda = \mu\rho$, se tiene $\lambda + \mu\rho^2 = \mu\rho(1+\rho)$. El lado izquierdo de la ecuación de balance es

$$c^2\rho^{x_1+x_2}(2\lambda + 2\mu) = 2c^2\rho^{x_1+x_2}\mu(1+\rho).$$

Comparando:

$$2c^2\rho^{x_1+x_2-1} \cdot \mu\rho(1+\rho) = 2c^2\rho^{x_1+x_2}\mu(1+\rho),$$

que es una identidad. Los casos con alguna coordenada nula se verifican análogamente. Por tanto, la forma producto satisface el balance, confirmando el teorema.

(d) Tiempo medio de un cliente en el sistema usando la Ley de Little

Ley de Little: Para un sistema de colas estable, el número medio de clientes L, la tasa media de llegadas Λ y el tiempo medio de estancia W cumplen $L = \Lambda\, W$.

Aplicamos la ley a cada cola k. El número medio de clientes en la cola k (distribución geométrica) es

$$L_k = \frac{\rho_k}{1-\rho_k} = \frac{\Lambda_k/\mu_k}{1-\Lambda_k/\mu_k}.$$

Por la Ley de Little, $L_k = \Lambda_k\, W_k$, de donde el tiempo medio en la cola k es

$$W_k = \frac{L_k}{\Lambda_k} = \frac{1}{\mu_k - \Lambda_k}.$$

Sea $\Lambda_0 = \sum_{i=1}^{K} \lambda_i$ la tasa total de llegadas externas. Un cliente externo visita en promedio $v_k = \Lambda_k/\Lambda_0$ veces la cola k. Por tanto, el tiempo total medio en el sistema es

$$W_{\text{sistema}} = \sum_{k=1}^{K} v_k\, W_k = \sum_{k=1}^{K} \frac{\Lambda_k}{\Lambda_0} \cdot \frac{1}{\mu_k - \Lambda_k}.$$

Alternativamente, aplicando la Ley de Little a todo el sistema: $L_{\text{sistema}} = \sum_k L_k$ y $\Lambda_0\, W_{\text{sistema}} = L_{\text{sistema}}$, se obtiene la misma expresión:

$$W_{\text{sistema}} = \frac{1}{\Lambda_0} \sum_{k=1}^{K} \frac{\Lambda_k}{\mu_k - \Lambda_k}.$$

$$\boxed{W_{\text{sistema}} = \frac{1}{\sum_{i=1}^{K} \lambda_i} \sum_{k=1}^{K} \frac{\Lambda_k}{\mu_k - \Lambda_k}}.$$

7. Bibliografía de referencia

Referencias

[1] G. F. Lawler, *Introduction to Stochastic Processes*, 2.ª ed., Chapman & Hall/CRC, 2006.

[2] S. M. Ross, *Introduction to Probability Models*, 12.ª ed., Academic Press, 2019.

[3] D. A. Levin y Y. Peres, *Markov Chains and Mixing Times*, 2.ª ed., American Mathematical Society (AMS), 2017.

[4] P. Brémaud, *Markov Chains: Gibbs Fields, Monte Carlo Simulation and Queues*, Springer Graduate Texts in Mathematics, 2020.

[5] J. R. Norris, *Markov Chains*, Cambridge Series in Statistical and Probabilistic Mathematics, 1998.

[6] G. Grimmett y D. Stirzaker, *Probability and Random Processes*, 3.ª ed., Oxford University Press, 2001.

[7] Gemini 3 Flash (Google AI), *Asistencia técnica y resolución de problemas de Procesos Estocásticos*, Edición para la Facultad de Estudios Superiores Acatlán, UNAM, 2026.